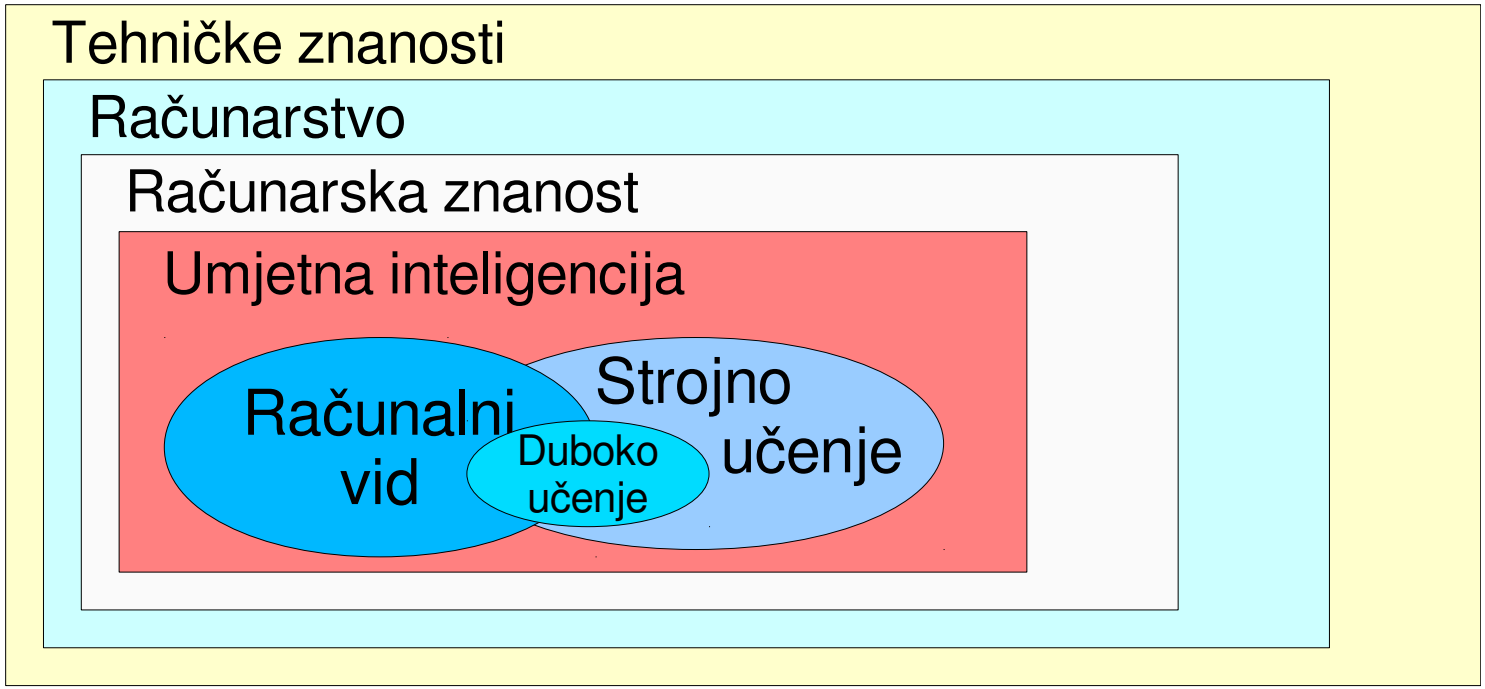
Računalni vid

Uvodno predavanje

Siniša Šegvić
Uredio: Josip Šarić
UniZg-FER D307
Sveučilište u Zagrebu

O predmetu: karta pojmova



Umjetna inteligencija:

- tehnički sustavi za poslove koje ljudi obavljaju bolje od strojeva

Računalni vid:

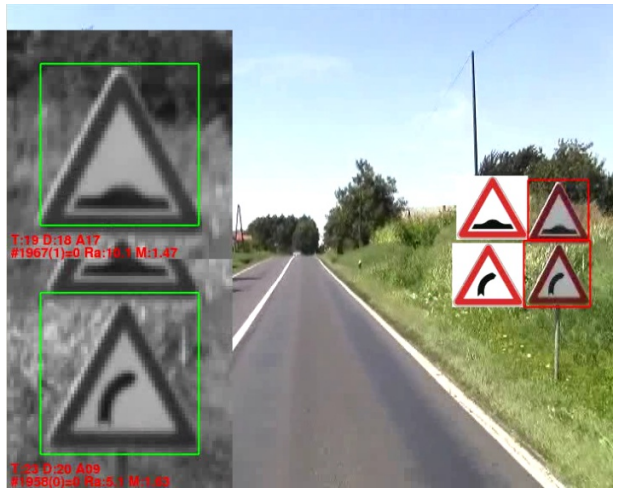
- razumjeti procese strojne percepcije i spoznaje
- stvoriti novu vrijednost kroz napredne usluge

O predmetu: računalni vid

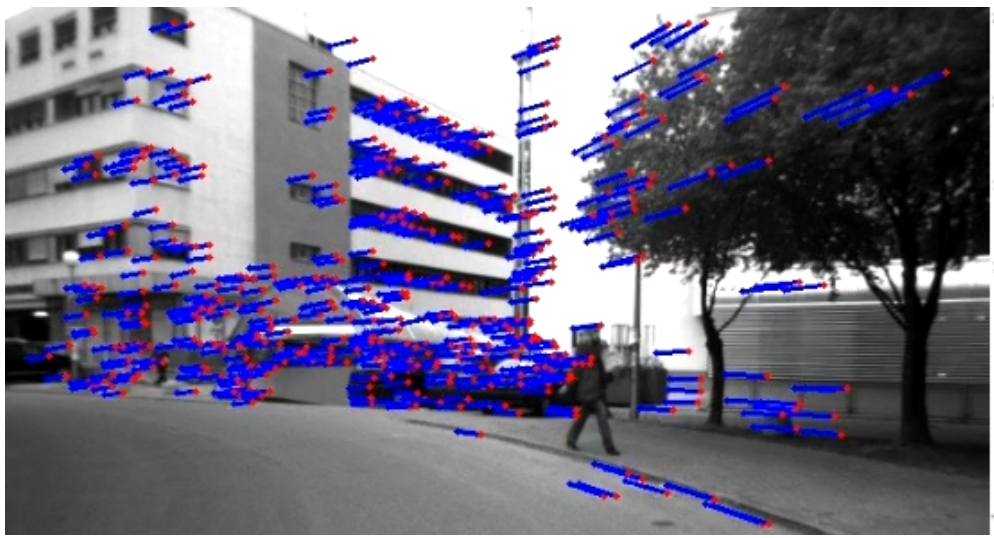
Proučavamo tehnike za izlučivanje korisnih informacija iz slika

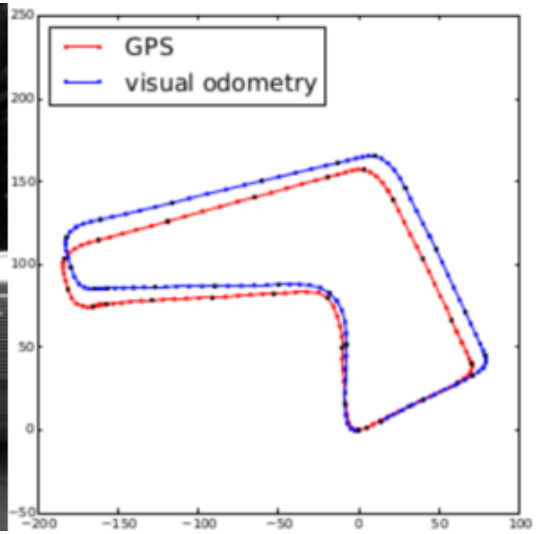
Nekoliko glavnih pristupa prema tom cilju:

- **raspoznavanje**: izlučiti semantičku informaciju: što je u slici i gdje?
- **rekonstrukcija**: procijeniti geometrijsku informaciju: ključne točke, gibanje u slici, položaj kamere, strukturu scene...



[segvic14mva]





O predmetu: metode

Oba pristupa temelje se na optimizaciji:

- **raspoznavanje**: izlučiti semantiku naučenim modelom
  - kriterij: gubitak na skupu za učenje (+ regularizacija...)
  - optimizacija tijekom učenja, (relativno) jednostavno zaključivanje
  - klasificiranje slika, pronalaženje objekata, segmentacija slika
  - krajnji cilj kognitivnog vida: razumjeti sliku
- **rekonstrukcija**: optimirati geometrijski model
  - kriterij: slaganje s mjerenjima u slici
  - klasični pristup: nema učenja, optimizacija pri svakom zaključivanju
  - danas metode raspoznavanja koristimo i za rekonstrukciju (npr. dubina, optički tok)

Od 2012. svjedočimo ekspanziji **raspoznavanja**:

- ključ: izlučiti kvalitetne slikovne reprezentacije
- danas ih **učimo** dubokim modelima na velikim skupovima

O predmetu: vrijeme

Sve donedavno, raspoznavanje u "divljini" je bilo akademska disciplina

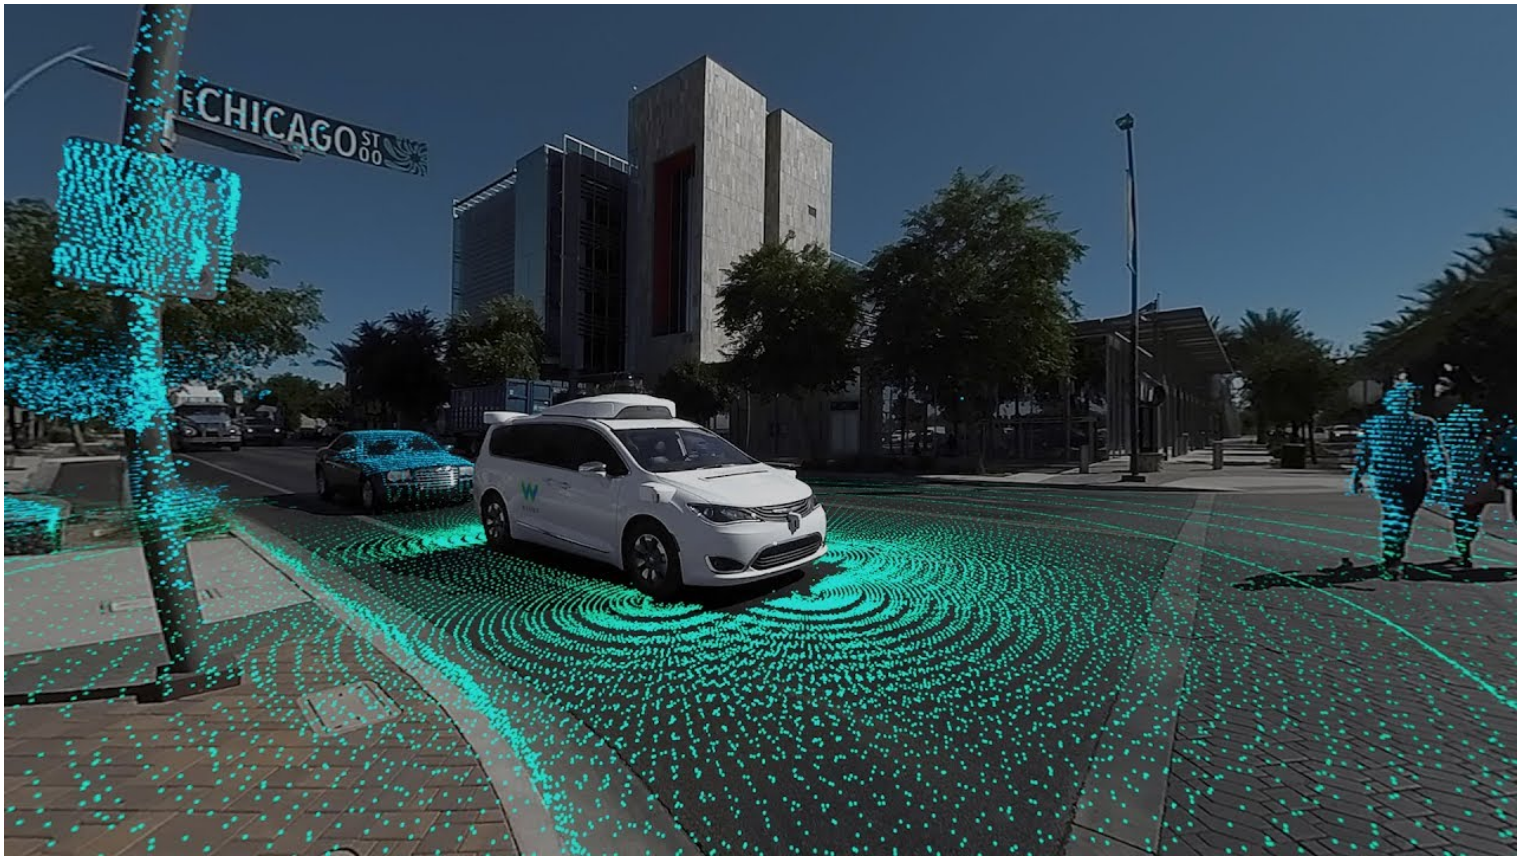
- primjenljivi rezultati dobivani su samo u laboratorijskim uvjetima
- međutim, vrijedan rad doveo je do fascinantnog napretka

Danas je kognitivni vid tehnologija s jasnom industrijskom vrijednošću

- Google, Meta, Intel, Microsoft, Nvidia, i mnogi kineski giganti u područje ulažu milijarde dolara
- Google kupio DeepMind za 0.6 B$ (2014)
- Intel kupio Mobileye za 15.3 B$ (2017)
- Nvidia: tržišna vrijednost preko 4000 B$ (2025), ponajviše zahvaljujući GPU-ima za učenje

Pogledajmo zašto je kognitivni vid toliko zanimljiv!

Primjene: autonomna vozila



https://www.youtube.com/watch?v=B8R148hFxPw

Društvo automobilskih inženjera (SAE) definira 6 razina autonomije (2014)

- Nekoliko tvrtki testira uslugu robotaxija razine 4 na javnim cestama.

Primjene: dijagnostika bez liječnika

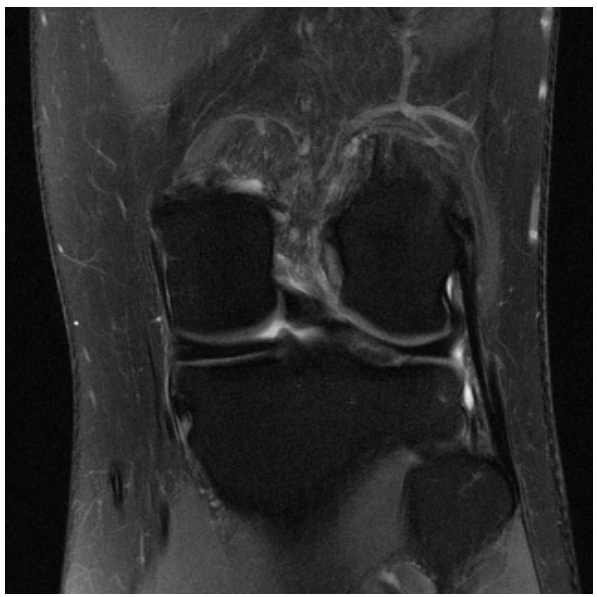


http://www.nature.com/nature/journal/v542/n7639/abs/nature21056.html

Esteva et al. Dermatologist-level classification of skin cancer with deep neural networks. Nature 542, 115–118 (02 February 2017)

Primjene: brže snimanje magnetskom rezonancijom

Duboki modeli omogućuju **nekoliko puta brže** MR snimanje: snimimo manje podataka, a model rekonstruira sliku.



potpuno snimanje



brže, bez učenja



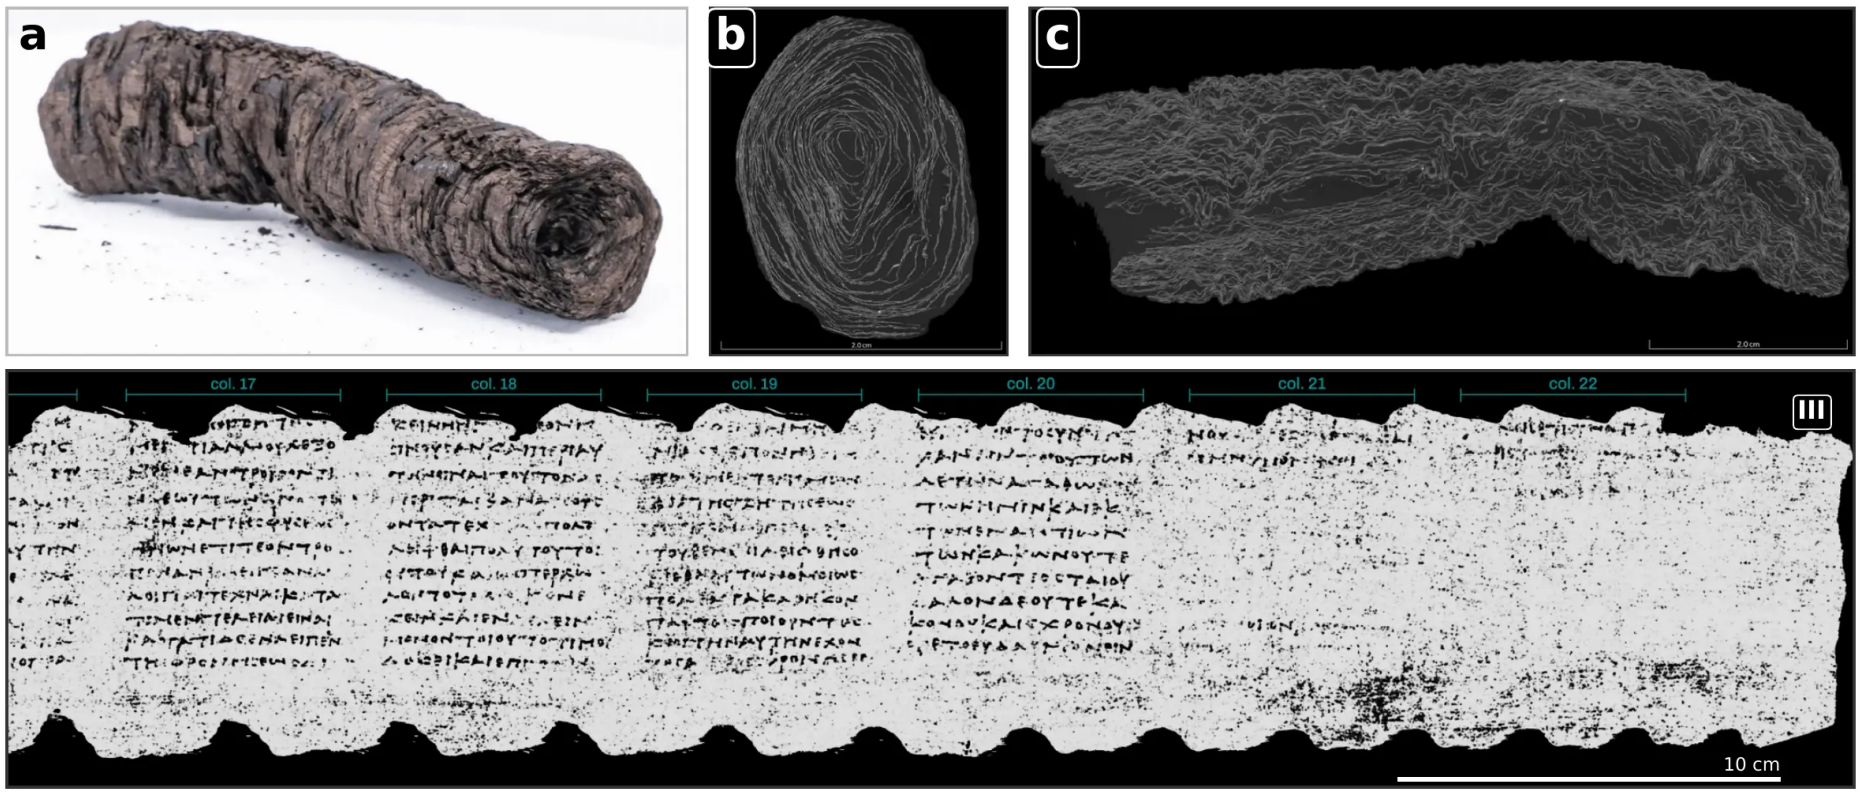
brže, **duboki model**

[zbontar18arxiv]

Primjene: čitanje neotvorenih svitaka

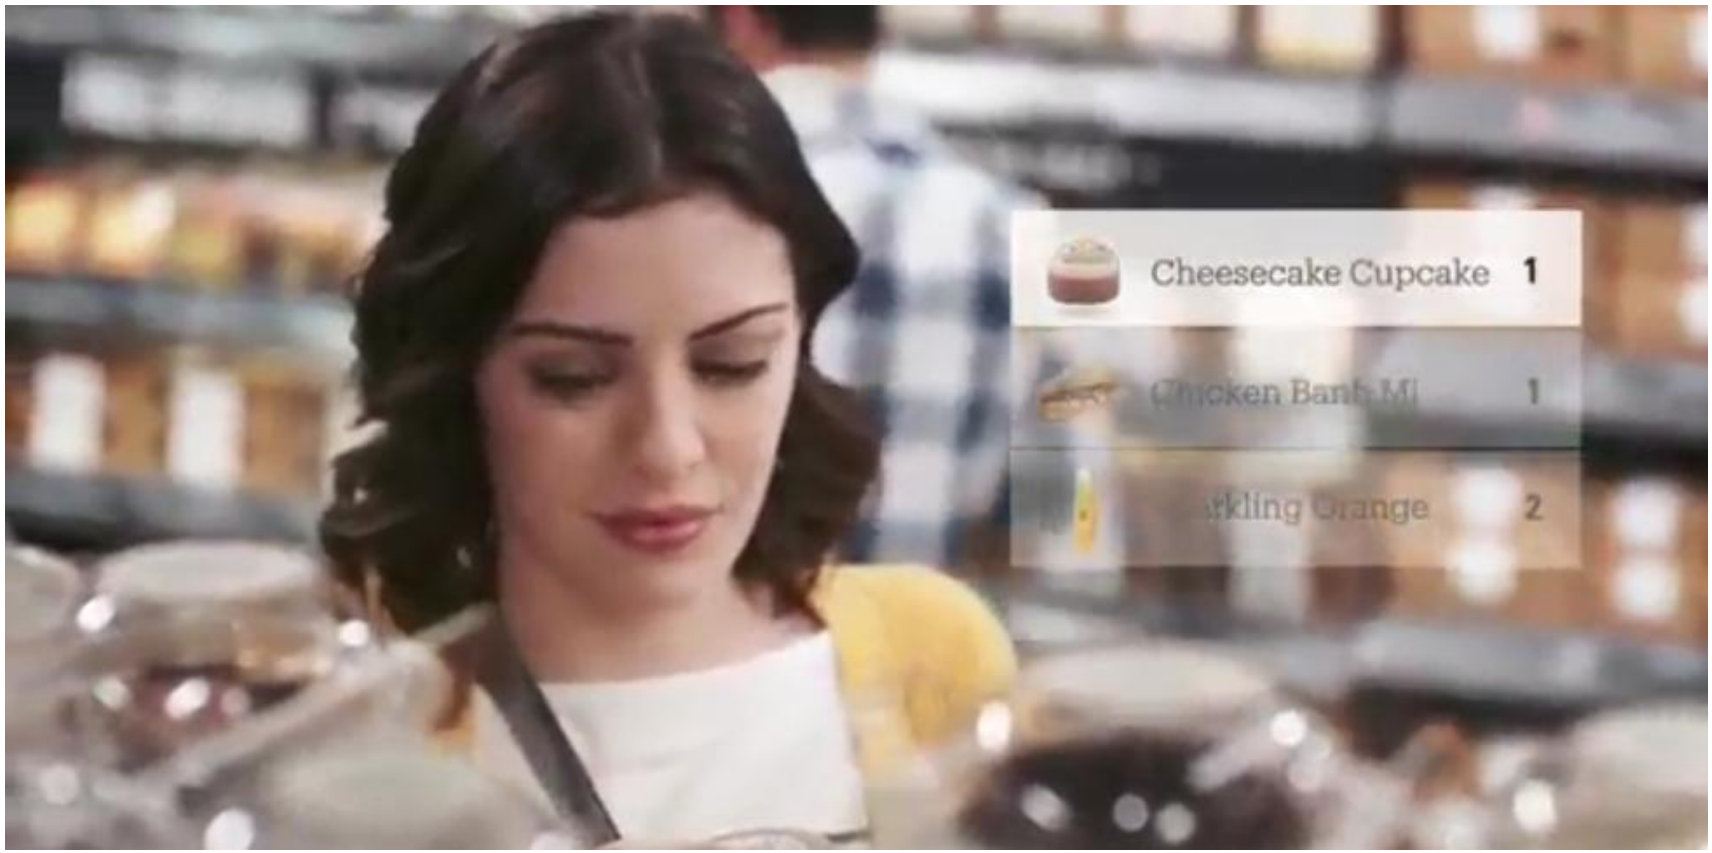
Erupcija Vezuva (79.) pougljenila je stotine papirusa u Herculaneumu

- svitci se ne mogu odmotati bez uništavanja
- rješenje: rendgenska tomografija, virtualno odmotavanje i **naučena detekcija tinte**



https://scrollprize.org/firstscroll (CC BY-NC 4.0)

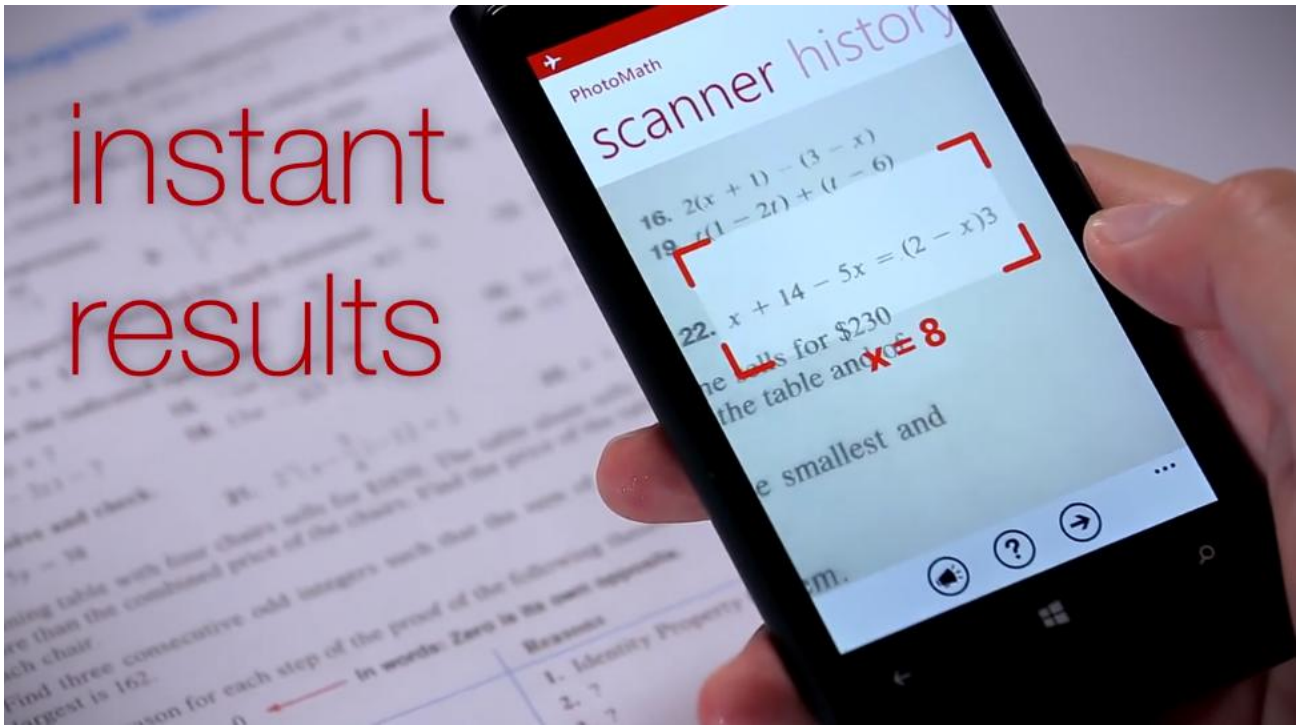
Primjene: dućan bez blagajni

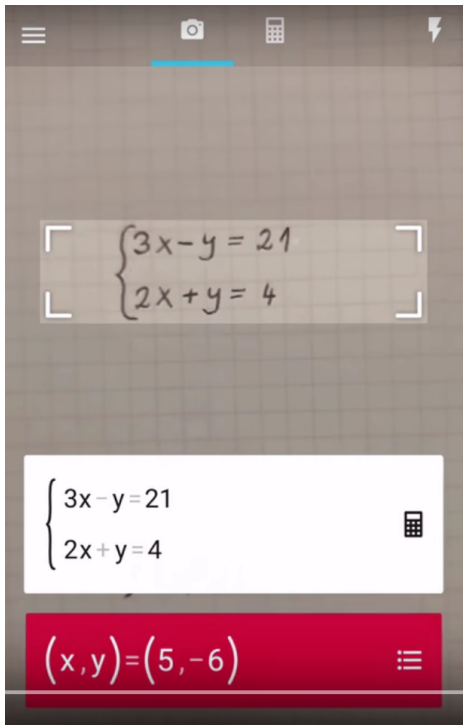


https://www.youtube.com/watch?v=Jg0pQaV44I8

Amazon Go, 2131 7th Ave, Seattle, WA.

Primjene: uplatnice bez šaltera...





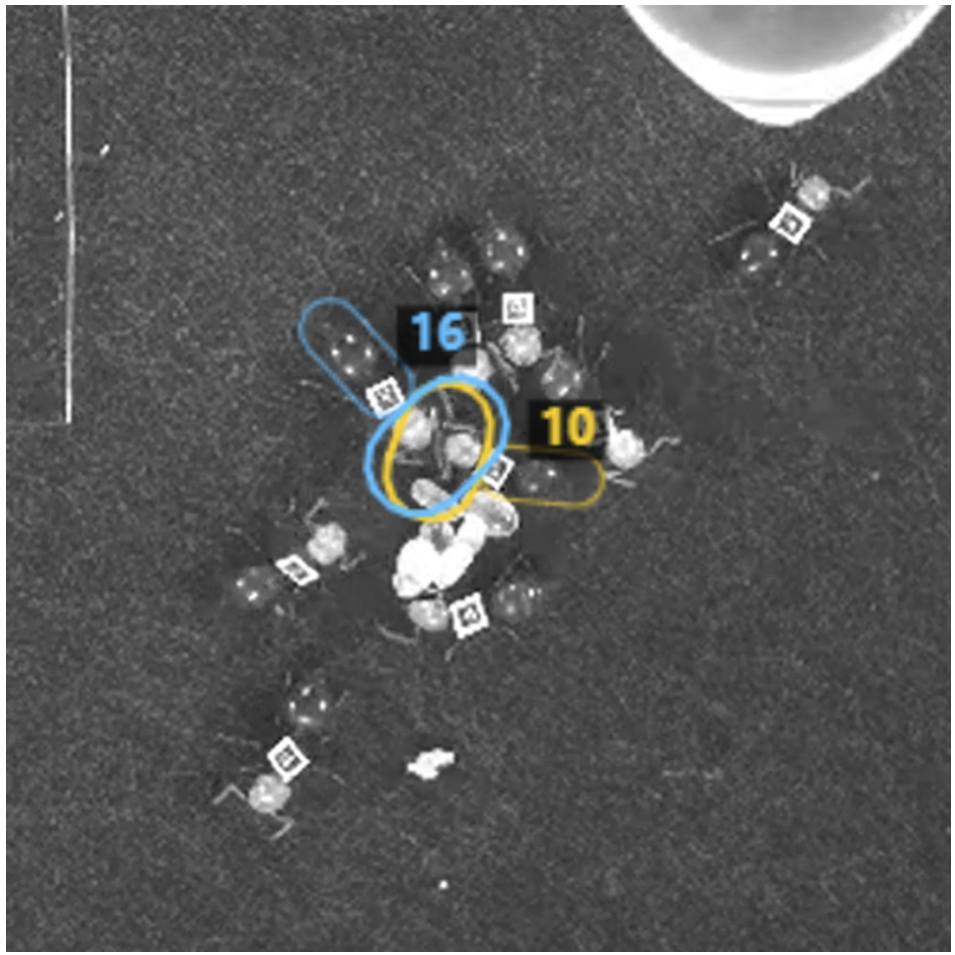
https://www.youtube.com/watch?v=oXn9NuUmhDM

https://www.youtube.com/watch?v=XlbVB50mIh4

...i rješavanje matematičkih zadataka (s postupkom!)

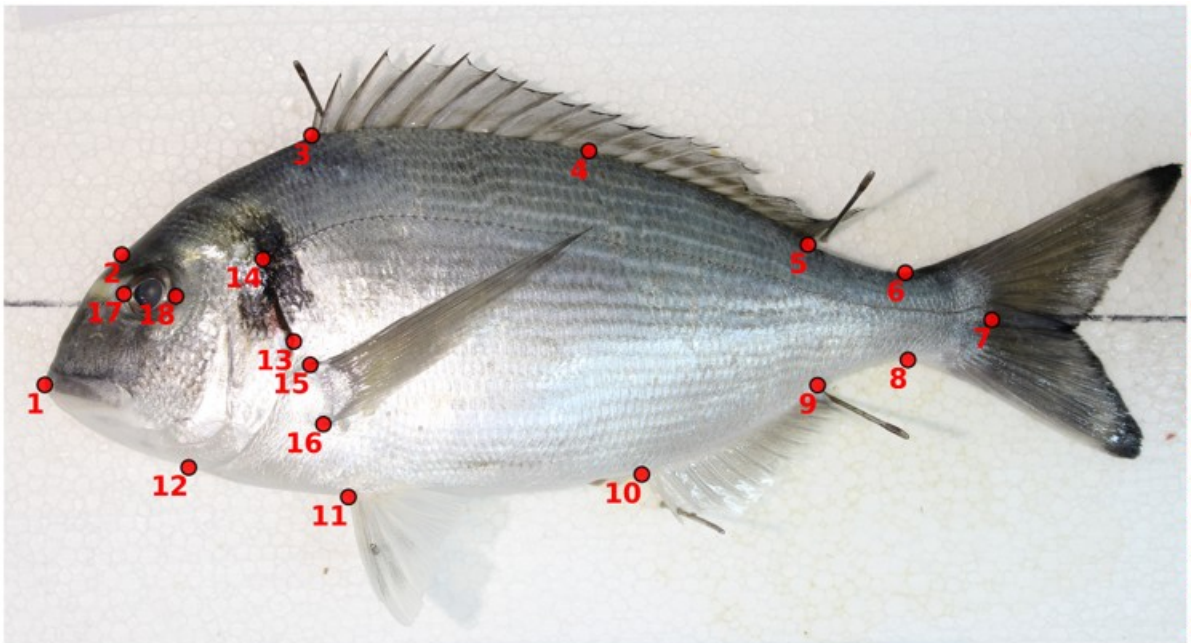
Primjene: Istraživanje u drugim znanstvenim disciplinama

U biologiji za analizu ponašanja mrava...



Primjene: Istraživanje u drugim znanstvenim disciplinama

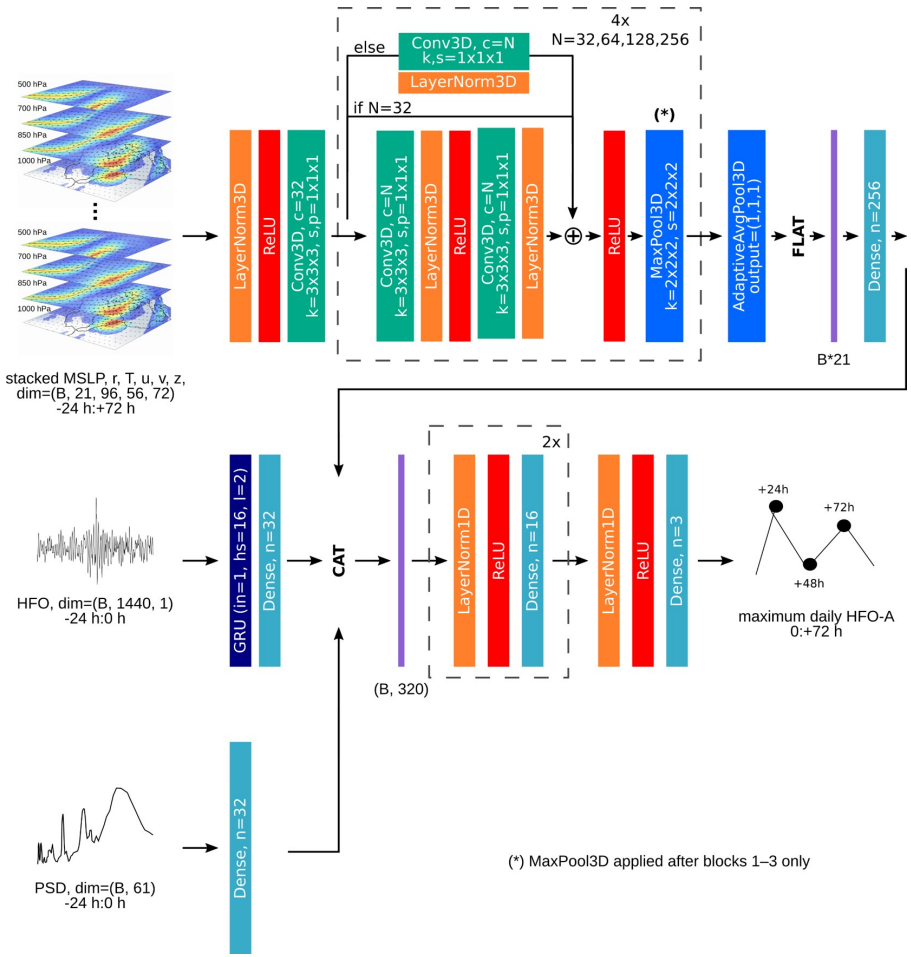
U biologiji za analizu podrijetla ribe...



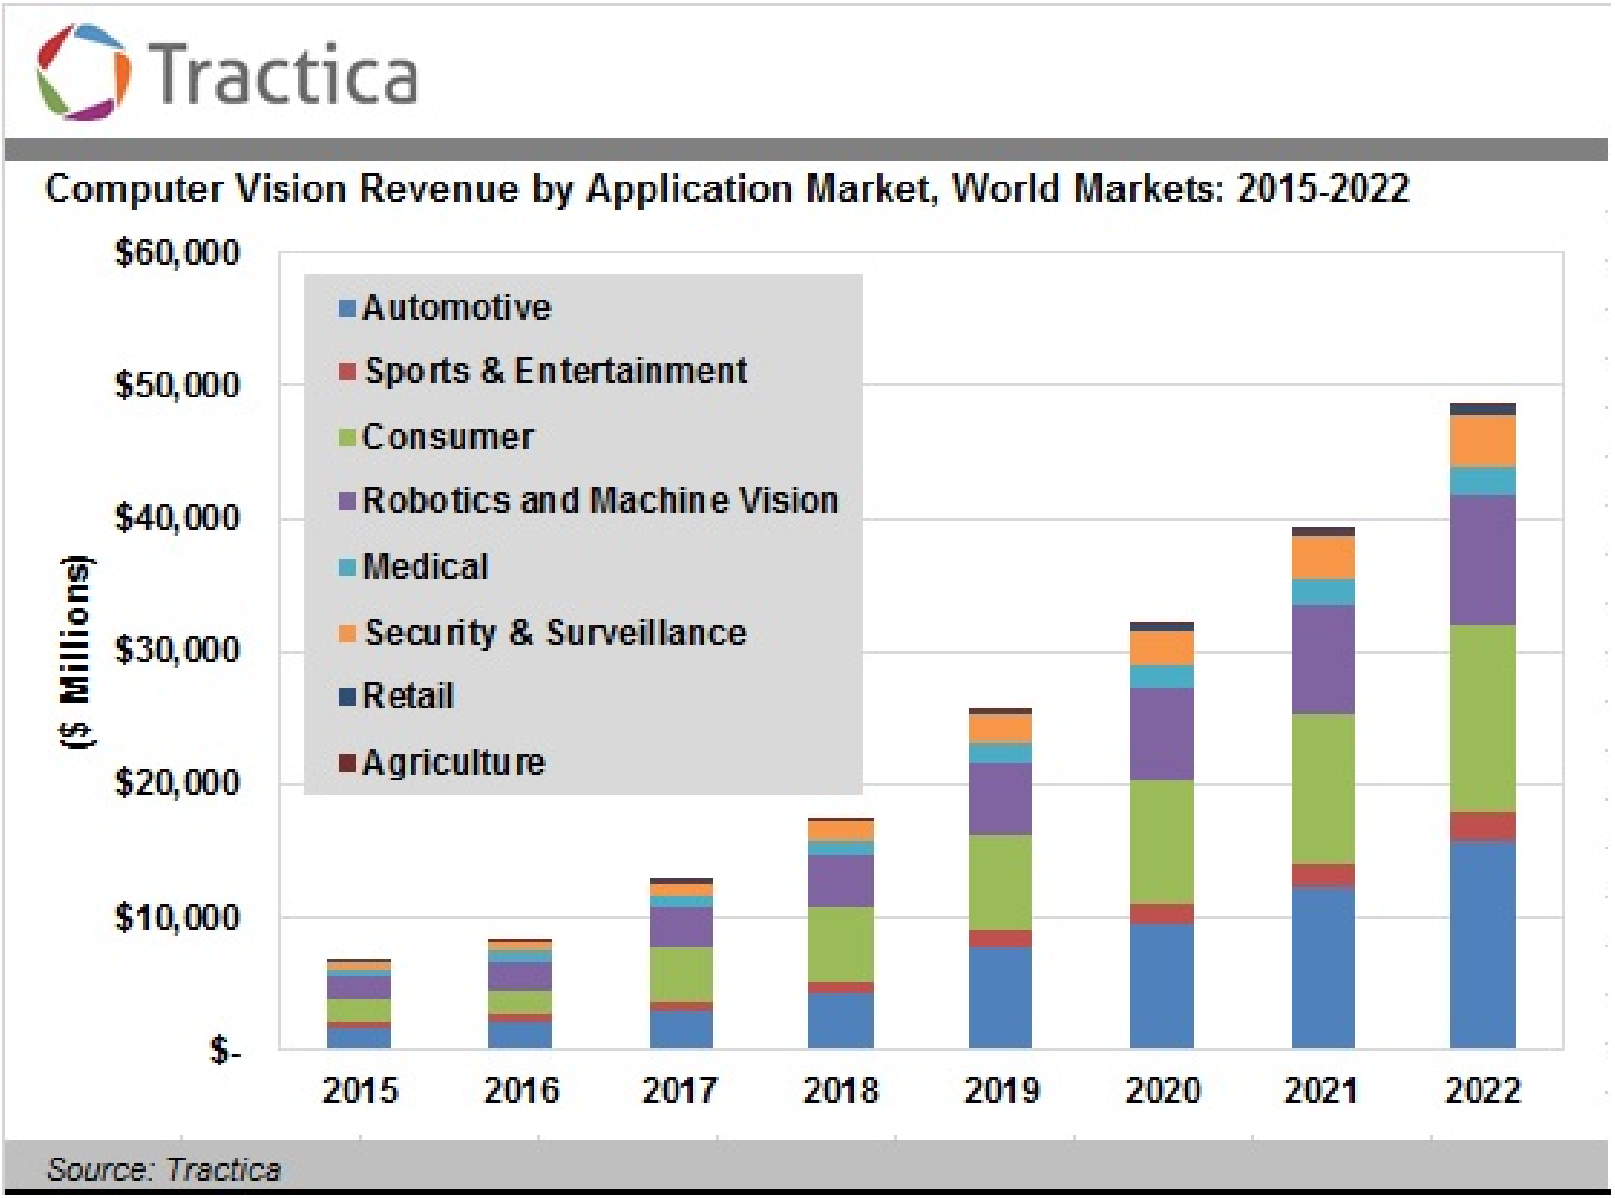
1. anterior tip of snout at the upper jaw
2. vertical point above the most anterior point in the eye
3. anterior insertion of the dorsal fin
4. last spiny ray of the dorsal fin
5. posterior insertion of the dorsal fin
6. dorsal point at the least depth of the caudal peduncle
7. posterior body extremity
8. ventral point at the least depth of the caudal peduncle
9. posterior insertion of the anal fin
10. anterior insertion of the anal fin
11. insertion of the pelvic fin
12. ventral tip of the insertion of the operculum on the lateral profile
13. point of maximum extension of the operculum on the lateral profile
14. anterior extremity of the lateral line on the head profile
15. dorsal insertion of the pectoral fin
16. ventral insertion of the pectoral fin
17. the most anterior point in the eye
18. the most posterior point in the eye

Primjene: Istraživanje u drugim znanstvenim disciplinama

U geofizici za predviđanje meteotsunamija...



Primjene: projekcije i prognoze



https://www.tractica.com/

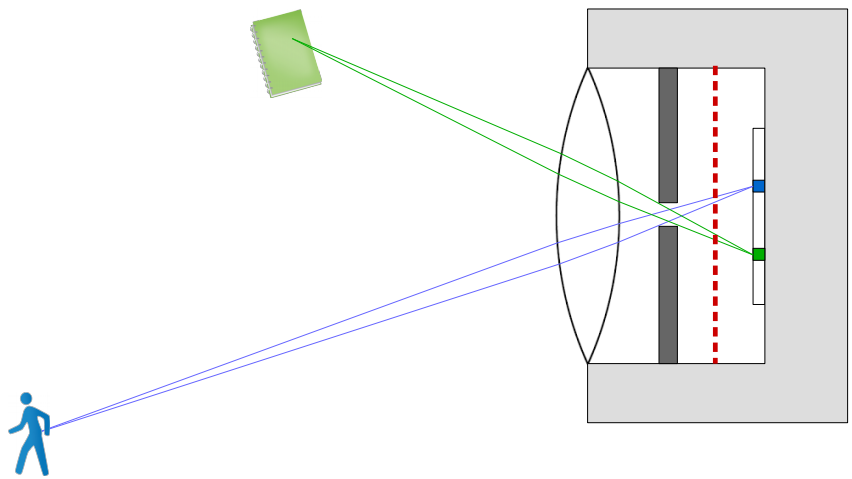
Plan

1. Uvod i motivacija
   - pristupi strojnog gledanja, primjene
2. Osnove računalnog vida
   - o digitalnim slikama, pogled unatrag
3. Provedbeni plan
   - teme, predavanja, laboratorijske vježbe

Digitalne slike: stvaranje

Digitalna kamera ima četiri glavna elementa:

1. senzor: a pravokutno polje osjetilnih elemenata ($\rightarrow$ **pixeli**!)
2. otvor: rupica koja propušta svjetlost na senzor
   - osjetilne elemente pobuđuju odgovarajući uski snopovi svjetlosti
3. leća: uređaj za prikupljanje svjetla (osigurava jači signal)
4. zatvarač: osigurava da ekspozicija traje djelić sekunde



Za slike u boji treba nam malo složeniji sustav

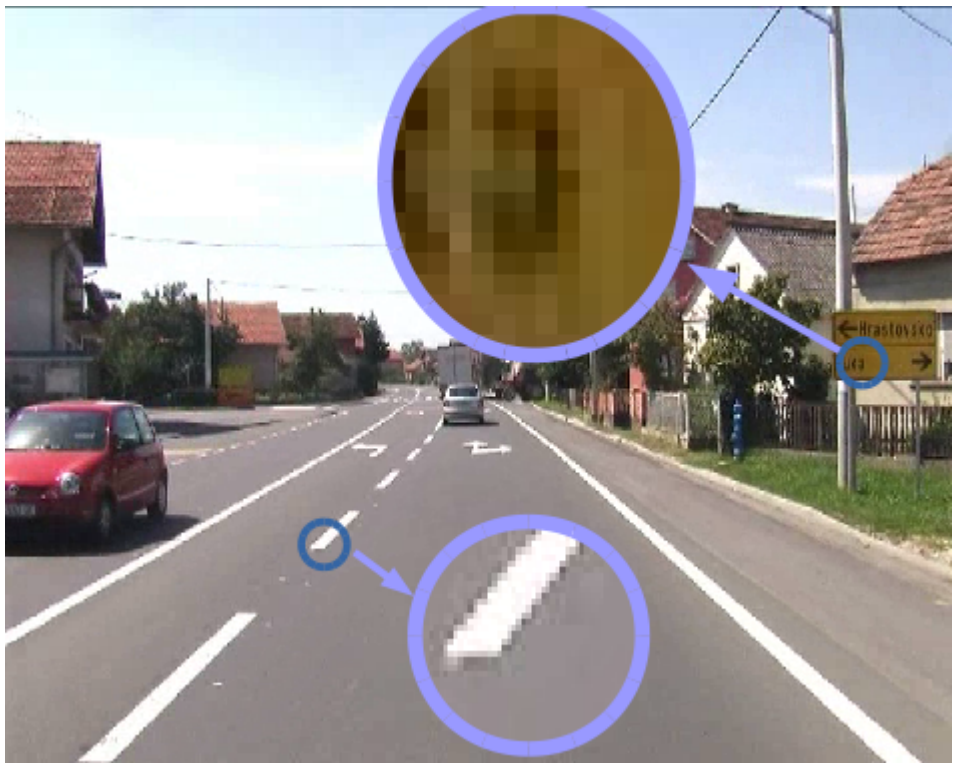
- npr. tri prepletena filtra, tri senzora i sustav ogledala

Digitalne slike

Tako, svaka digitalna slika je pravokutno polje piksela

- dimenzije (retci $\times$ stupci) ovise o senzoru

Ako sliku dovoljno povećamo, pikseli postaju vidljivi:

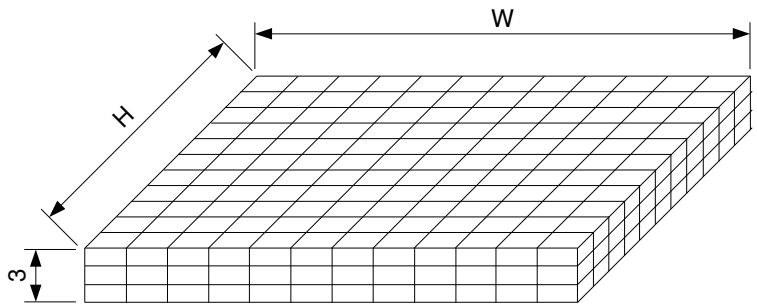


Ako se to ne dogodi, znači da vas program za prikazivanje slika vara :-)

Digitalne slike: struktura

Ako se radi o slici u boji, svaku piknju opisujemo trojkom (R, G, B).

Takve slike predstavljamo tenzorom $H \times W \times 3$:



Ispeglani tenzor možemo smjestiti u memoriju kao polje $H \cdot W \cdot 3$ brojeva:

R_{11}	G_{11}	B_{11}	R_{12}	G_{12}	B_{12}	...	...	...	R_{HW}	G_{HW}	B_{HW}

Sliku od 200×200 piksela možemo predstaviti 120000-D vektorom.

Pogled unatrag: početak (1966)

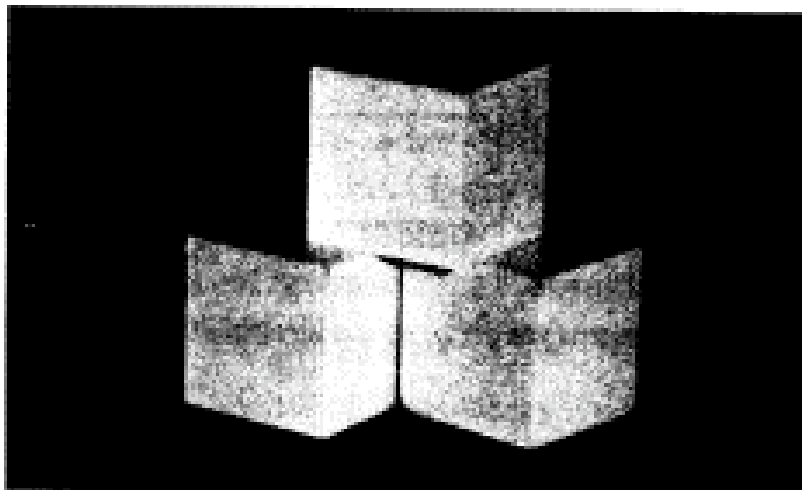
Odmah nakon pojave digitalnih slika postavilo se logično pitanje:

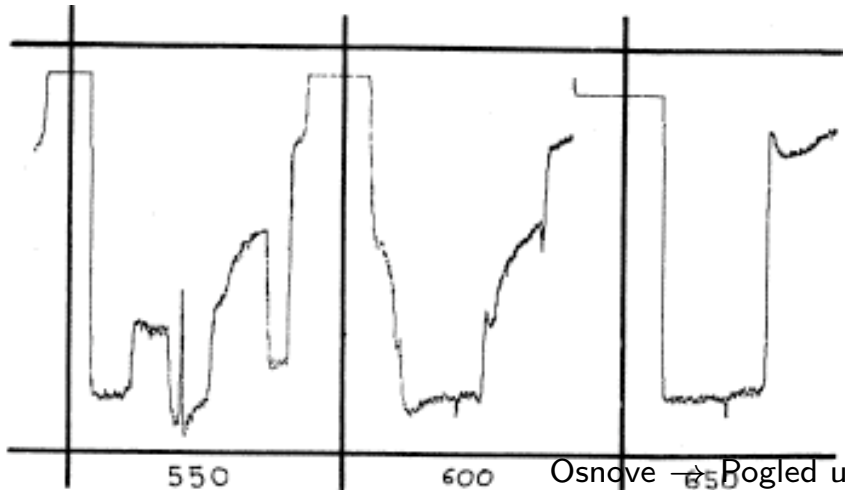
- može li računalo analizirajući sliku razumjeti svijet?

1966 godina: jedan američki profesor predlaže diplomandu da napiše program koji će ispisati što ima u slici.

Taj zadatak je bio ispred svog vremena: problem je mnogo godina ostao neriješen unatoč vrijednom radu mnogih ljudi...

Razumijevanje problema raslo je polako ali ustrajno, ukratko ćemo ponoviti glavna postignuća

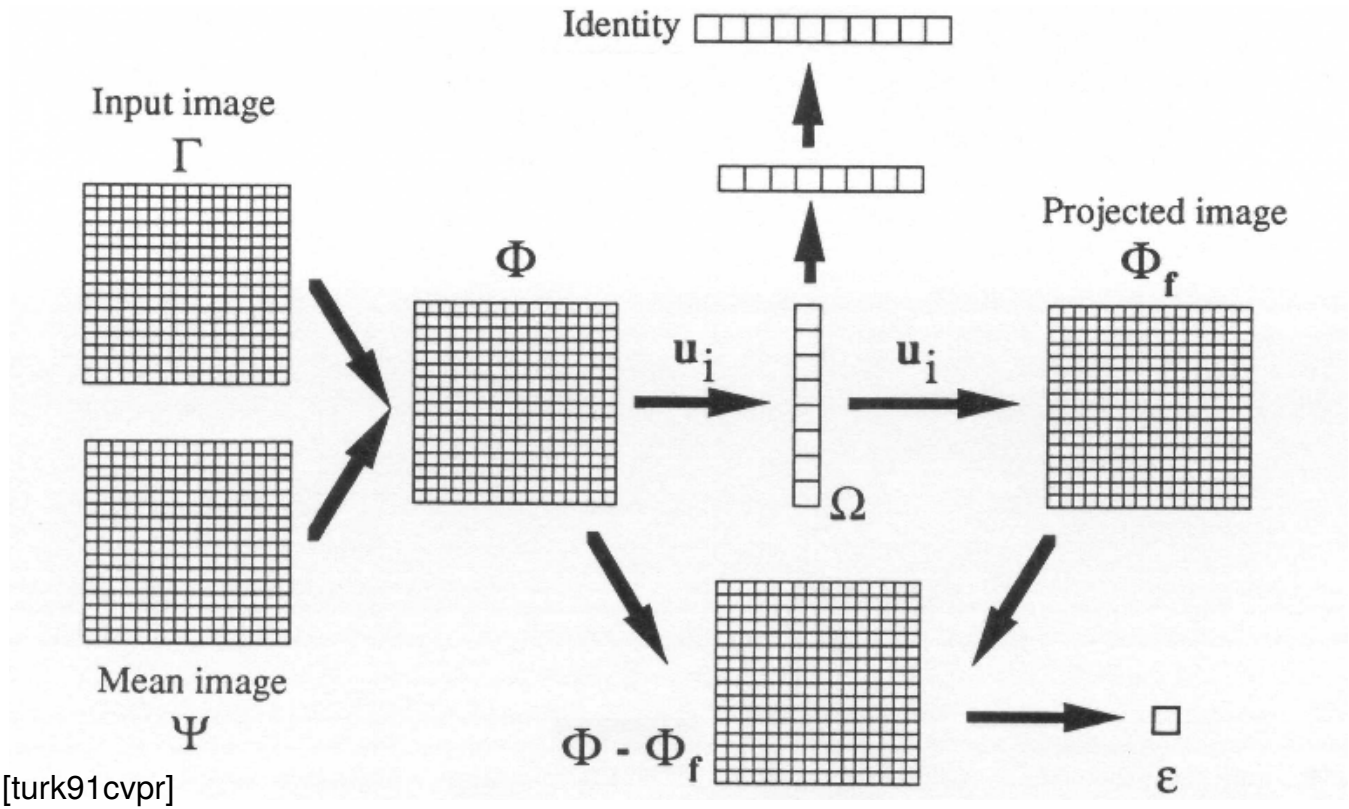




Pogled unatrag: klasifikacija objekata (1991)

Recept za klasificiranje poravnatih slika lica [turk91cvpr]:

- slike se tretiraju kao visokodimenzionalni podatci
- hypotetizira se da slike nastanjuju nižedimenzionalni **prostor lica**
- uči se linearna projekcija na prostor lica (podatci za učenje!)
- provodi se raspoznavanje na reprezentaciji slike u prostoru lica



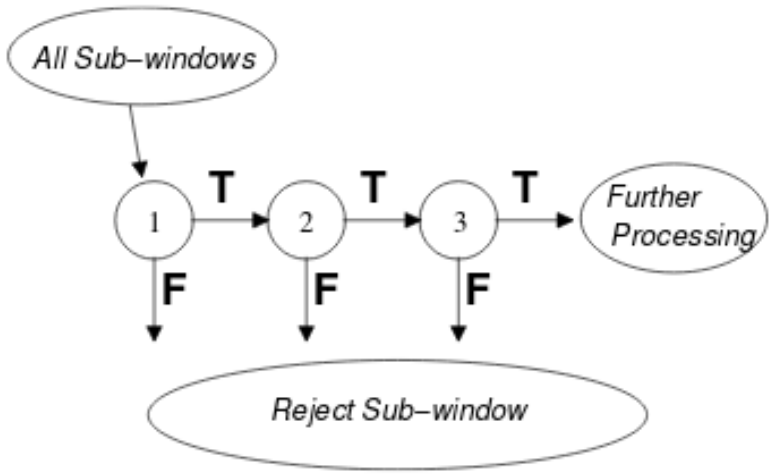
[turk91cvpr]

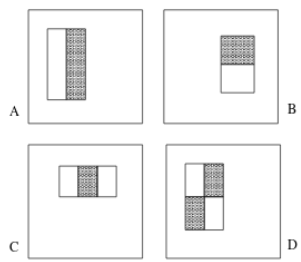
Pogled unatrag: pronalaženje objekata (2001)

Jednostavni objekti, stvarno vrijeme [viola01cvpr]:

- pronalaženje se tretira kao binarna klasifikacija u pomičnom oknu
- klasifikator se uči kao kaskada sve strožih detektora
- pojedine razine kaskade kombiniraju **jednostavne** značajke
- mogućnost klasificiranja preko 100000 okana na 25 Hz











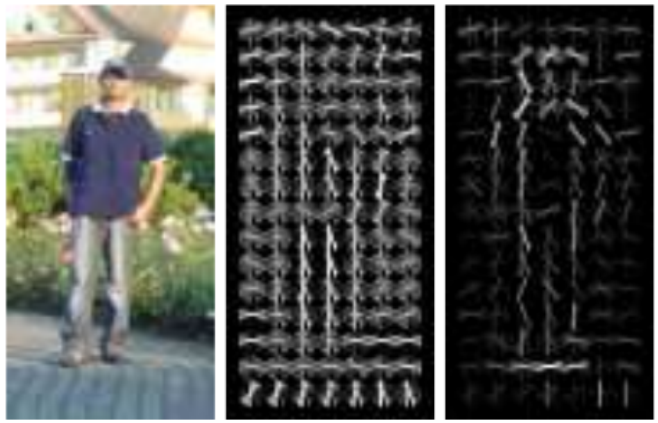


[viola01cvpr]

Pogled unatrag: pronalaženje objekata (2005)

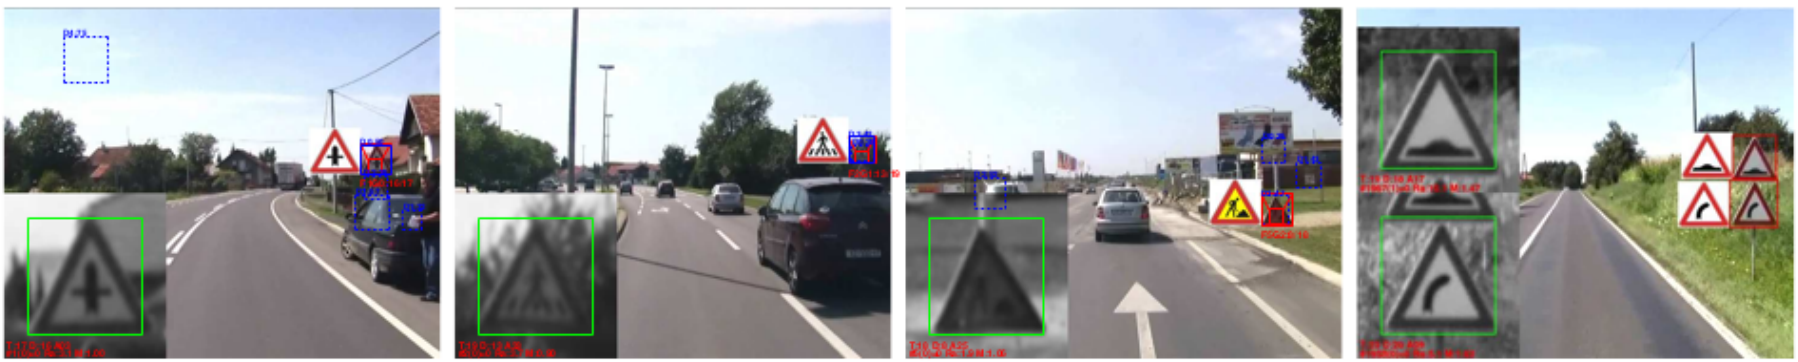
Nešto složeniji objekti [dalal05cvpr]:

- reprezentirati okna ručno dizajniranim lokalnim opisnikom (HOG)
- linearna klasifikacija okana
- moćniji i sporiji od [viola01cvpr]



[dallal05cvpr]

Povezivanje posljednjih dvaju pristupa omogućava pouzdano pronalaženje prometnih znakova:

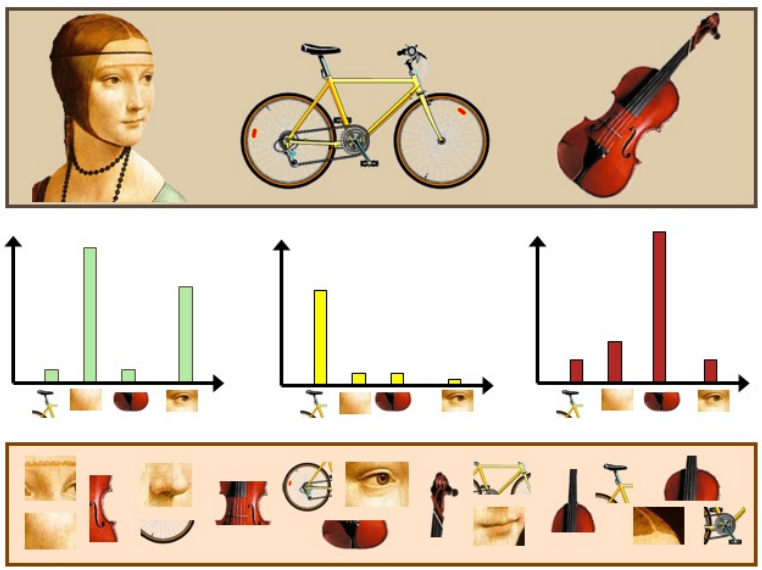


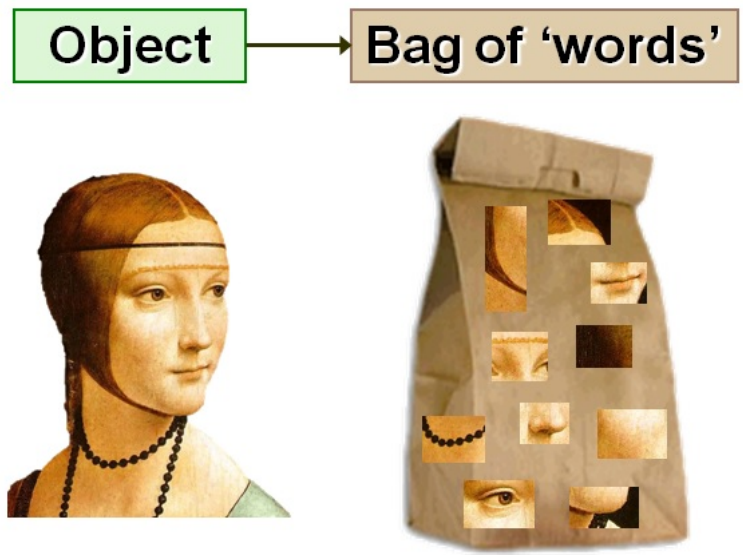
[segvic14mva]

Pogled unatrag: klasifikacija slika (2004)

Recept za raspoznavanje neporavnatih slika [csurka04eccv]:

- kodirati izgled okana ručno dizajniranim značajkama (SIFT)
- naučiti diskretni rječnik opisnika okana (slikovne riječi)
- reprezentirati slike kao histograme slikovih riječi
- klasificirati slikovne reprezentacije plitkim klasifikatorom





[fergus09iccv]

Moderno vrijeme: 2014: misija nemoguća?

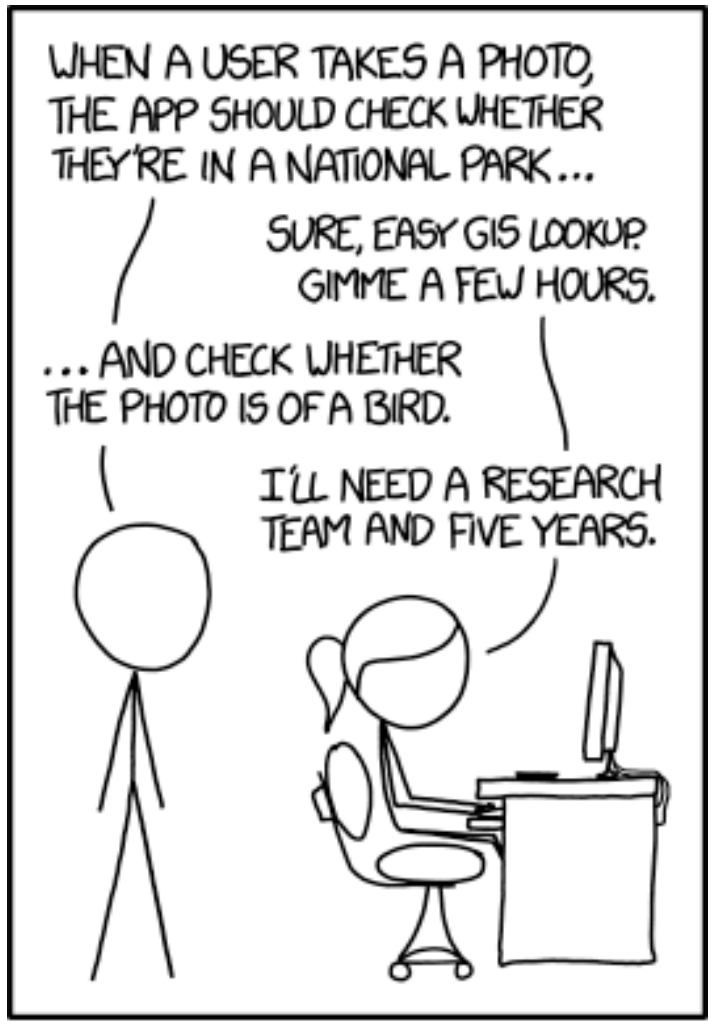
Konačno, svi su saznali da je vid težak...

2014: popularna kultura predstavlja računalni vid kao nemoguću misiju...

- zaključiti sadrži li slika pticu?
- pa, s istraživačkom ekipom i pet godina - možda...

Međutim, od 1966 smo prevalili veliki put:

- pouzdana detekcija ptica moguća još 2010 (s istraživačkom ekipom)
- današnja metodologija i alati omogućuju nam da takve probleme riješimo kod kuće!

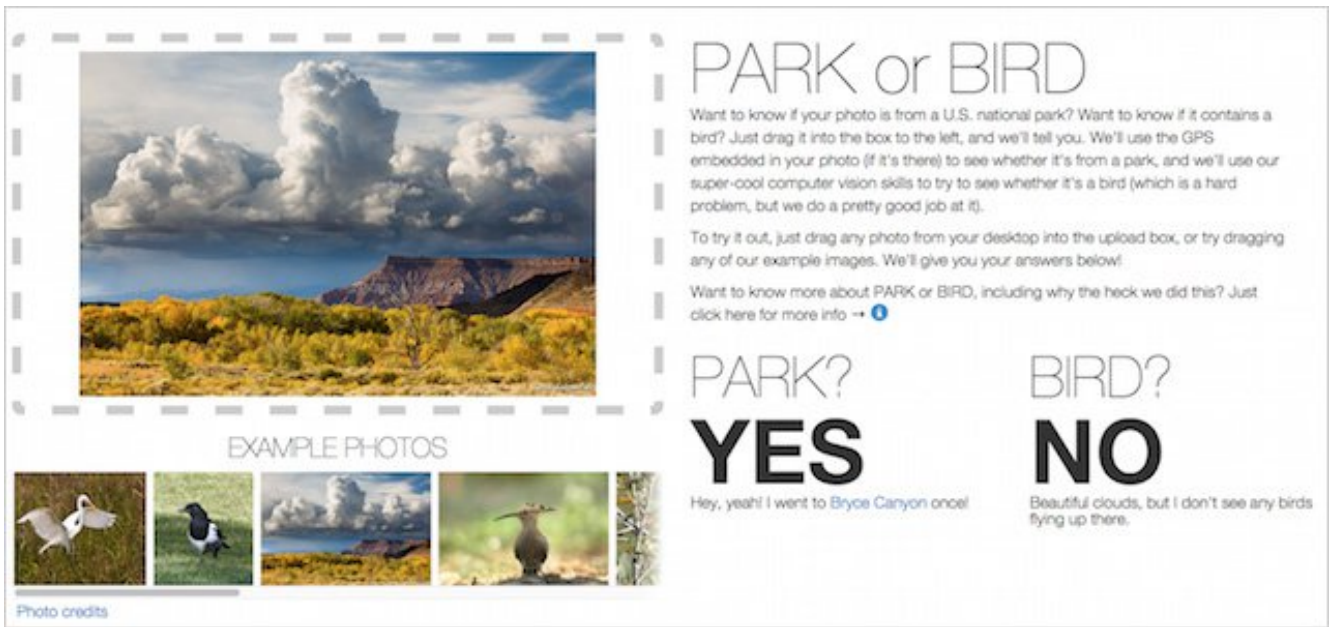


https://xkcd.com/1425 24.09.2014

Moderno vrijeme: 2014: mjesec dana kasnije

Tako, mjesec dana nakon XKCD 1425, Flickr ponosno javlja:

- riješili smo problem "park or bird"...
- ...u manje od pet godina :-)



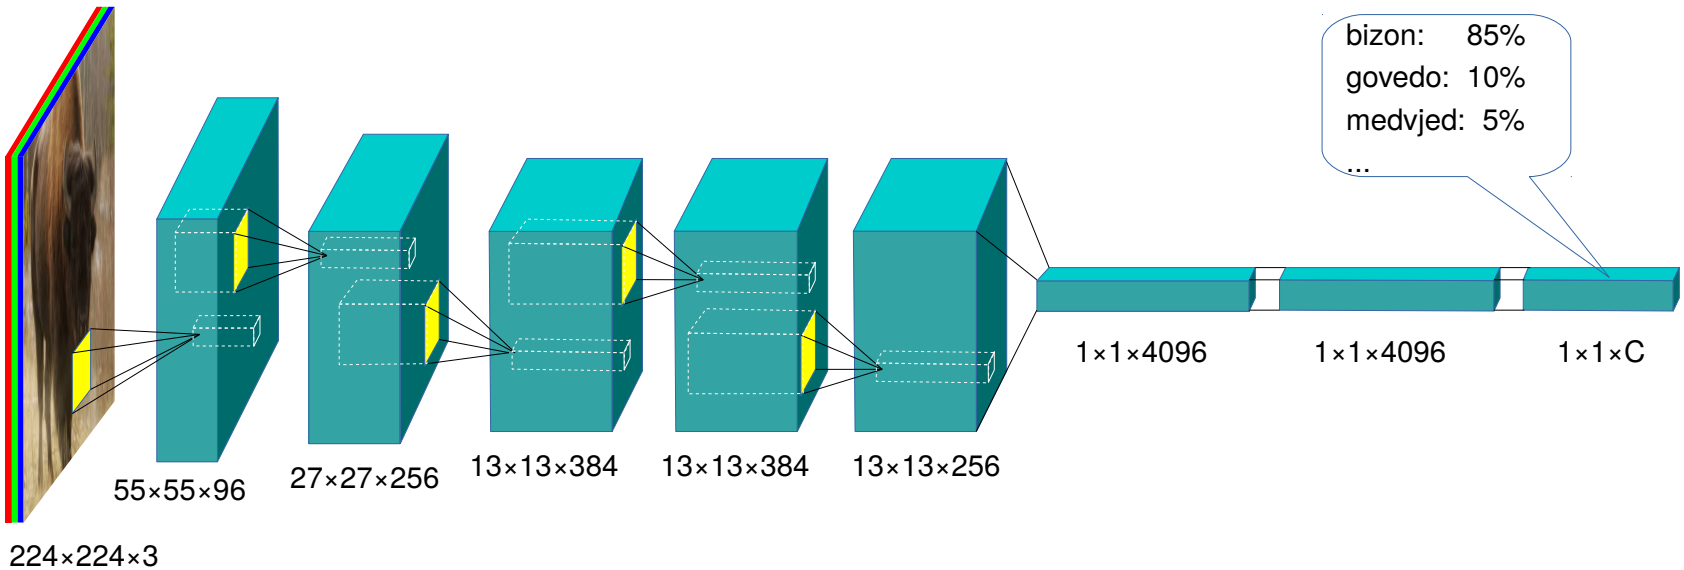
https://code.flickr.net/2014/10/20/introducing-flickr-park-or-bird/

Probleme u računarskoj znanosti lako je i potcijeniti i precijeniti :-)

Moderno vrijeme: duboko učenje (2012)

Reprezentacije više ne dizajniramo ručno, nego ih **učimo** [krizhevsky12nips]:

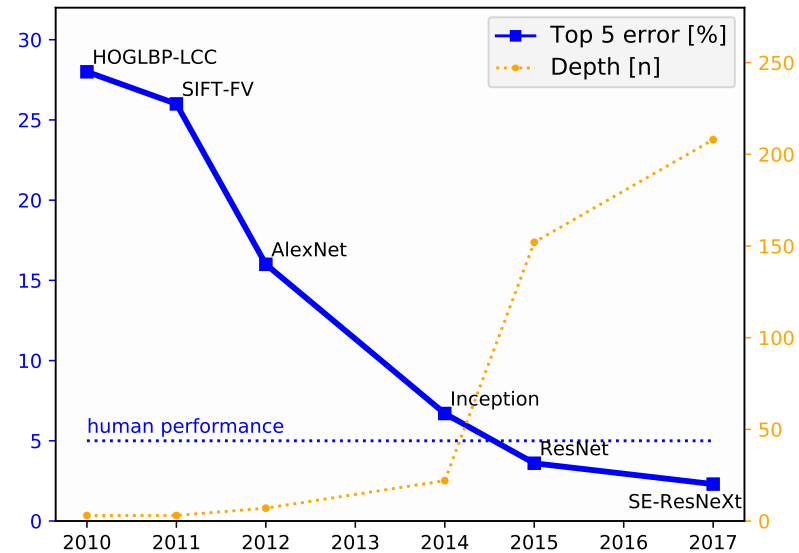
- duboki konvolucijski modeli (AlexNet)
- velik skup označenih slika (ImageNet, 1.2M slika, 1000 razreda)
- učenje na grafičkim procesorima (GPU)

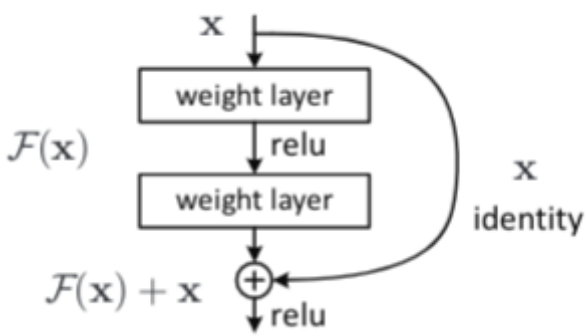


Moderno vrijeme: rezidualni modeli (2015)

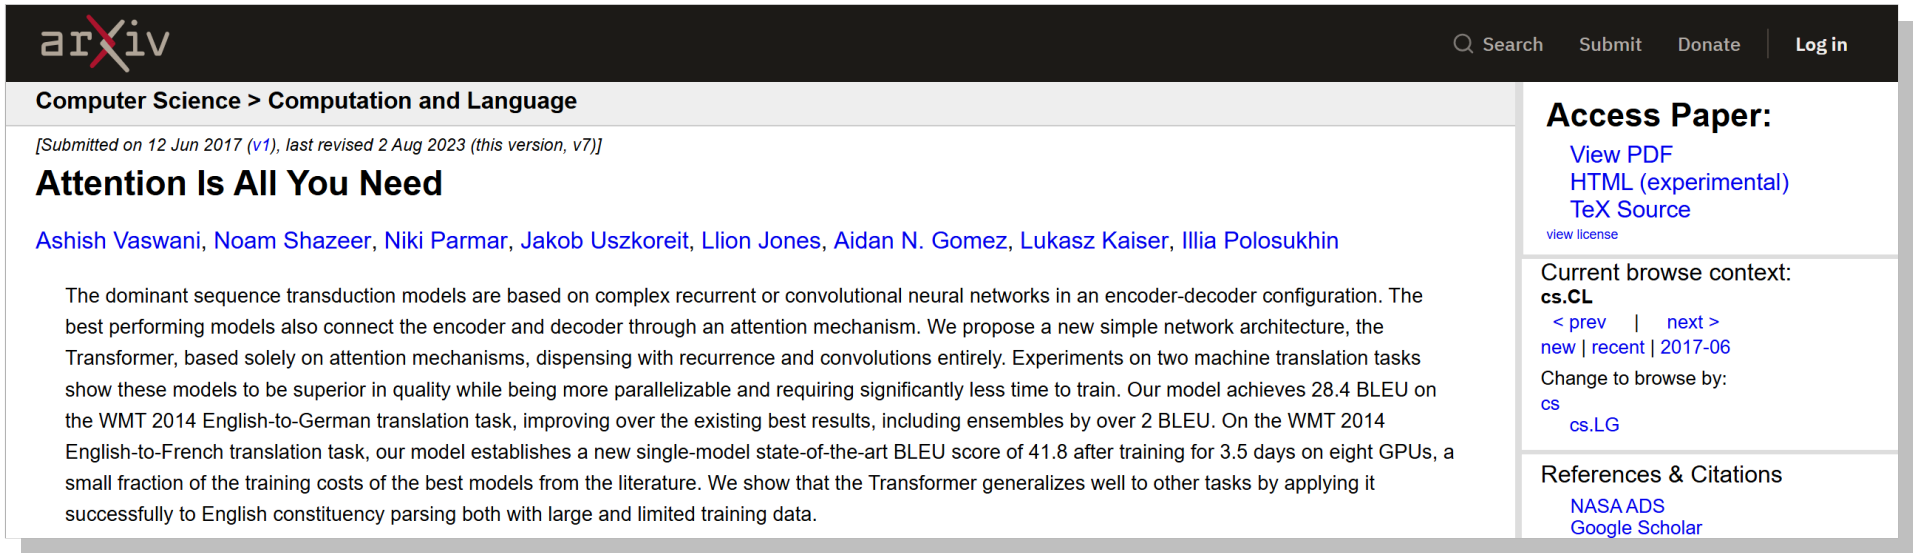
Dublji modeli bolje raspoznaju, ali ih je teško učiti [he16cvpr]

- rezidualna veza: blok uči samo popravak $\mathcal{F}(\mathbf{x})$ svog ulaza
- dubina raste: 8 slojeva (AlexNet) $\rightarrow$ **100+ slojeva** (ResNet)
- pogreška na ImageNetu pada **ispod ljudske razine**





Moderno vrijeme: u međuvremenu, u obradi teksta...



arXiv Search Submit Donate Log in

Computer Science > Computation and Language

[Submitted on 12 Jun 2017 (v1), last revised 2 Aug 2023 (this version, v7)]

Attention Is All You Need

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks in an encoder-decoder configuration. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

Access Paper:
View PDF
HTML (experimental)
TeX Source
view license

Current browse context:
cs.CL
< prev | next >
new | recent | 2017-06
Change to browse by:
cs
cs.LG

References & Citations
NASA ADS
Google Scholar

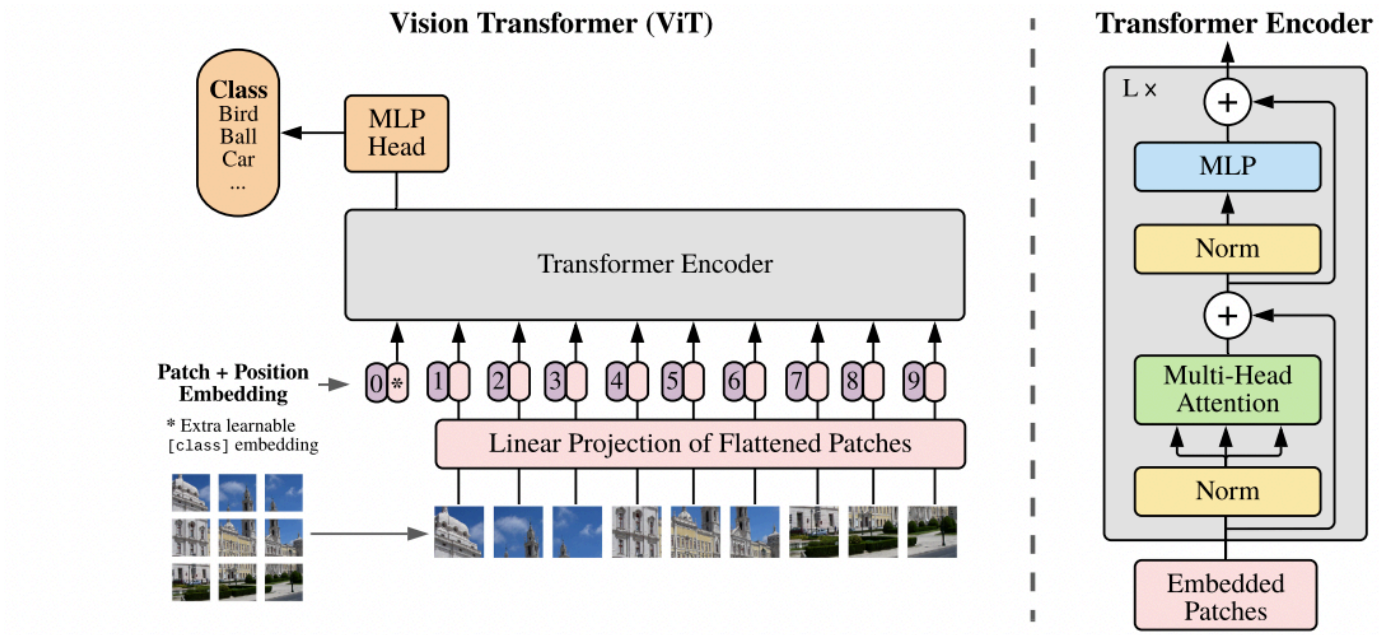
https://arxiv.org/abs/1706.03762

- 2017: **transformer** - model izgrađen samo od slojeva pažnje
  - svaka riječ izravno gleda sve ostale
  - lako se paralelizira i skalira

Moderno vrijeme: transformeri u vidu (2020)

Isti model primjenjujemo na slike [dosovitskiy21iclr]:

- slika se reže na isječke 16×16 piksela koje tretiramo kao riječi
- pažnja: svaki isječak ima interakciju sa svim ostalim
- uz dovoljno podataka nadmašuje konvolucijske modele

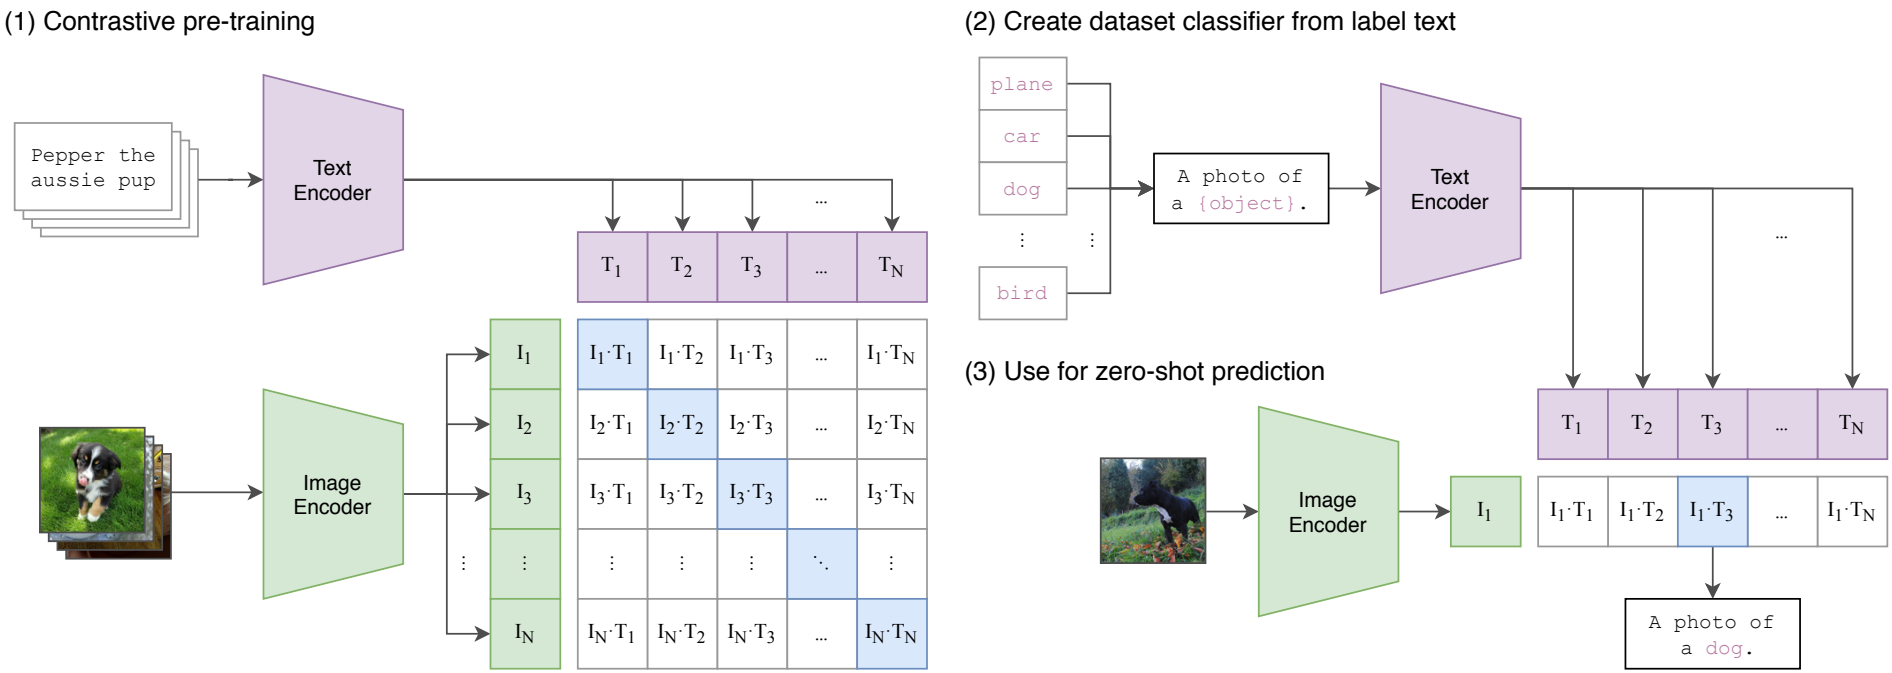


[dosovitskiy21iclr]

Moderno vrijeme: jezik i slika (2021)

CLIP uči iz 400M parova slika i opisa s weba [radford21icml]

- slika i tekst preslikavaju se u zajednički prostor
- razrede zadajemo tekstom: raspoznavanje **bez primjera za učenje**

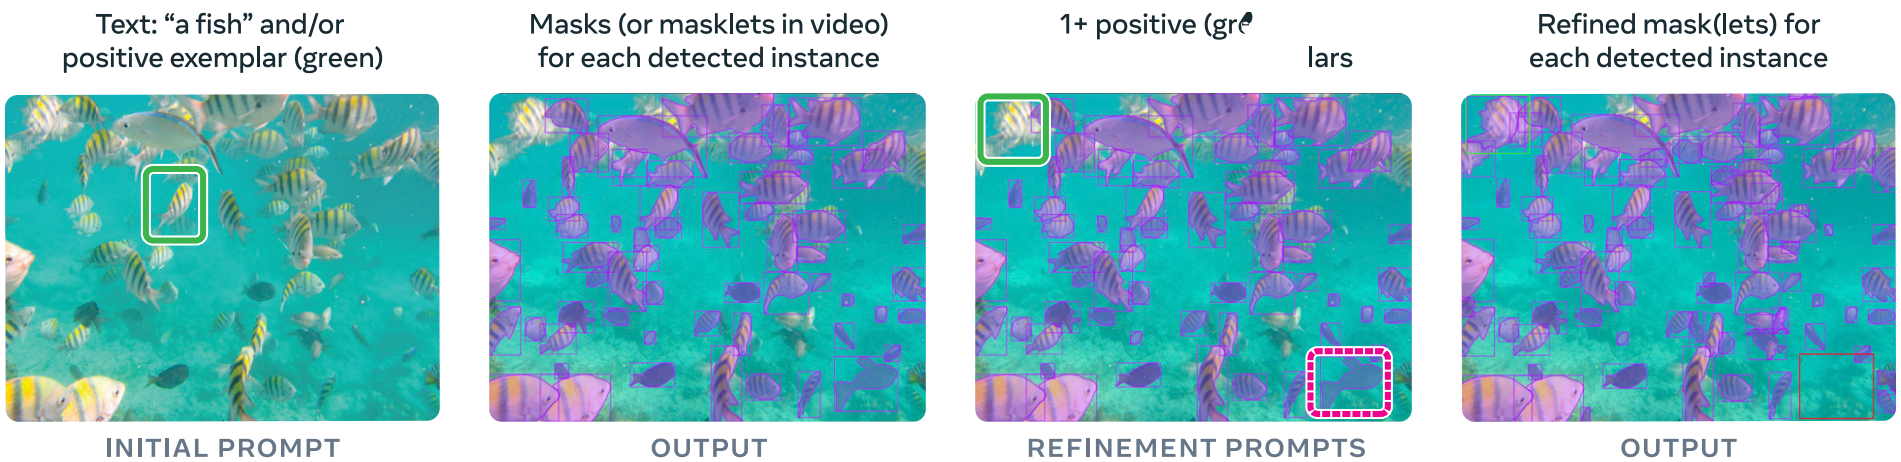


[radford21icml]

Moderno vrijeme: segmentacija bilo čega (2025)

SAM 3 [carion25arxiv]:

- zadajemo pojam: kratak tekst ("a fish") ili primjer u slici
- model pronalazi, segmentira i prati **sve** pojave tog pojma u slici ili videu



[carion25arxiv]

`https://aidemos.meta.com/segment-anything`

`https://jovanavidenovic.github.io/dam-4-sam/`

Moderno vrijeme: 3D iz slika u jednom prolazu (2025)

VGGT [wang25cvpr]: iz jedne ili stotinu slika, jedna mreža u sekundi procjenjuje kamere, dubinu i 3D oblak točaka



[wang25cvpr]

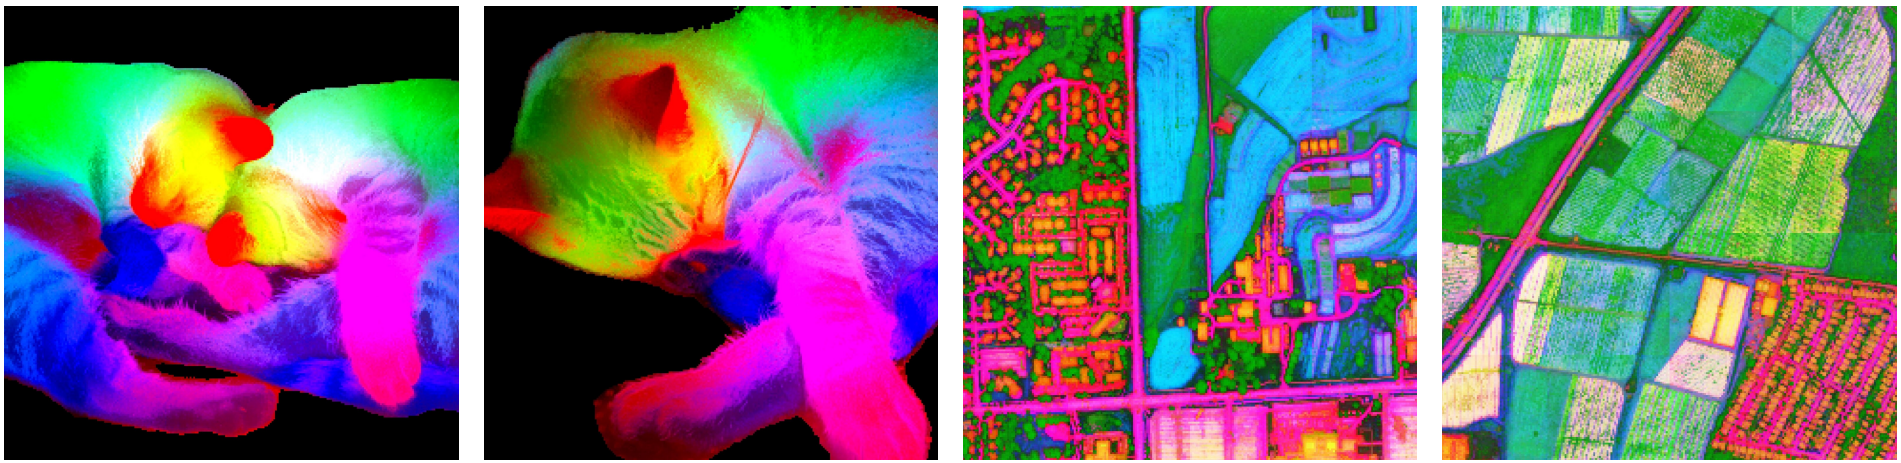
Najbolji rad CVPR 2025.

`https://huggingface.co/spaces/facebook/vggt`

Moderno vrijeme: općenite reprezentacije slika (2025)

DINOv3 [simeoni25arxiv]:

- učenje bez oznaka na 1.7 milijardi slika
- jedna zamrznuta mreža nadmašuje specijalizirane modele u detekciji, segmentaciji i procjeni dubine



značajke vizualizirane bojama (PCA) [simeoni25arxiv]

Moderno vrijeme: generiranje slika (2024)

Iz tekstnog opisa nastaje slika za nekoliko sekundi (FLUX.1 [schnell])

"Croatian football team in checkered jerseys flying on broomsticks, playing quidditch"

`https://huggingface.co/spaces/black-forest-labs/FLUX.1-schnell`



Sadržaj: Predavanja

1. uvodno predavanje
2. geometrijske transformacije slika
3. detekcija rubova i kuteva
4. ključne točke u prostoru mjerila
5. analiza kretanja u slikovnoj ravnini
6. diskusija: detekcija lica u stvarnom vremenu [viola04ijcv]
7. diskusija: semiglobalno stereo uparivanje [hirschmuller07tpami]

8.–9. (međuispiti)

10. konvolucijski modeli za klasifikaciju slika
11. detekcija objekata i semantička segmentacija
12. generativni modeli slika
13. duboki modeli utemeljeni na pažnji
14. diskusija: samonadzirani vizualni transformeri (DINO) [caron21iccv]
15. diskusija: učenje vizualnih modela iz prirodnog jezika (CLIP) [radford21pmlr]

Sadržaj: Laboratorijske vježbe

1. obrada slika, detekcija rubova i Houghova transformacija
2. detekcija kutova i geometrijske deformacije slika
3. detekcija objekata
4. normalizirajući tokovi

Neslužbene stranice predmeta:

`https://unizg-fer-d307.github.io/compvis/`

Sadržaj: uvjeti, bodovi

Aktivnosti: predavanja, laboratorijske vježbe (Python), međuispit, završni ispit, klasični ispit

Kalendar nastave:

kraj listopada:	L1
sredina studenog:	L2
kraj studenog:	MI
sredina siječnja:	L3
kraj siječnja:	L4
početak veljače:	ZI

Kontinuirana provjera:

laboratorij:	20
ispiti:	40 (MI), 40 (ZI)
bonus:	5 (sudjelovanje na diskusijama)
preduvjet:	50% laboratorija

Klasični ispit:

ispit:	100
preduvjet:	50% laboratorija

Ocjenjivanje. 2: 50%, 3: 63%, 4: 76%, 5: 89%.

Sadržaj: pravila - vježbe

1. Zadatke iz laboratorijskih vježbi rješavate samostalno. **Nije dozvoljeno** korištenje asistenata za kodiranje temeljenih na umjetnoj inteligenciji (ChatGPT, Claude, Gemini, Copilot i sl.).
   - 1.1 Plagirana rješenja ocijenit ćemo s 0 bodova, a autore prijaviti povjerenstvu za stegovnu odgovornost studenata.
   - 1.2 Programsko rješenje potrebno je do zadanog roka (obično početak prvog termina odgovarajuće vježbe) učitati na Ferko.
2. Bodovi za laboratorijsku vježbu ostvaruju se na dodijeljenom terminu obranom pred asistentom. Riješena vježba samo je preduvjet za ostvarivanje bodova!
3. Obavezan je dolazak u dodijeljeni termin vježbe. Burza grupa bit će otvorena tjedan-dva prije odgovarajuće vježbe (pratite oglase!).
4. Nema nadoknada vježbi.
   - 4.1 Osim u iznimnim situacijama poput bolesti, ali samo **jednom** u semestru. Tada treba uz liječničku ispričnicu doći u vlastiti termin sljedeće vježbe i zamoliti asistenta za nadoknadu propuštene vježbe i to za max. 80% bodova. Nije potrebno slati mail!

Sadržaj: Podsjetnik na pravila FER-a

1. U prostorima Fakulteta treba se ponašati poštivajući kućni red.
2. Korištenje alata umjetne inteligencije mora biti u skladu s Politikom primjerenog korištenja umjetne inteligencije na FER-u. Za dodatnu pomoć pročitajte Vodič za studente: Kako (ne) koristiti umjetnu inteligenciju na FER-u.
3. Broj zadataka u ispitu i format ispita (npr. zaokruživanjem ponuđenih odgovora ili rješavanje zadataka bez ponuđenih odgovora) može varirati između ispitnih rokova.
4. Na ispitima je zabranjeno držanje nastavnih materijala ili elektroničkih naprava (čak i isključenih) kod sebe ili pored sebe, osim u slučajevima kada su oni eksplicitno dozvoljeni, u skladu s Pravilnikom o stegovnoj odgovornosti studenata.

Sadržaj: Nastavnici

Predavanja:

- Tomislav Hrkać
- Josip Šarić
- Marin Oršić
- Zoran Kalafatić

Vježbe:

- Josip Šarić
- Petra Bevandić
- Marin Oršić
- Ivan Martinović
- Anja Delić

ZAHVALA

Ova predavanja proizišla su iz istraživanja koje je financirala Hrvatska zaklada za znanost projektom ADEPT.

http://adept.zemris.fer.hr