Računalni vid

Elementarne slikovne značajke

Siniša Šegvić
doradili Marin Oršić, Josip Šarić
UniZg-FER D307
Sveučilište u Zagrebu

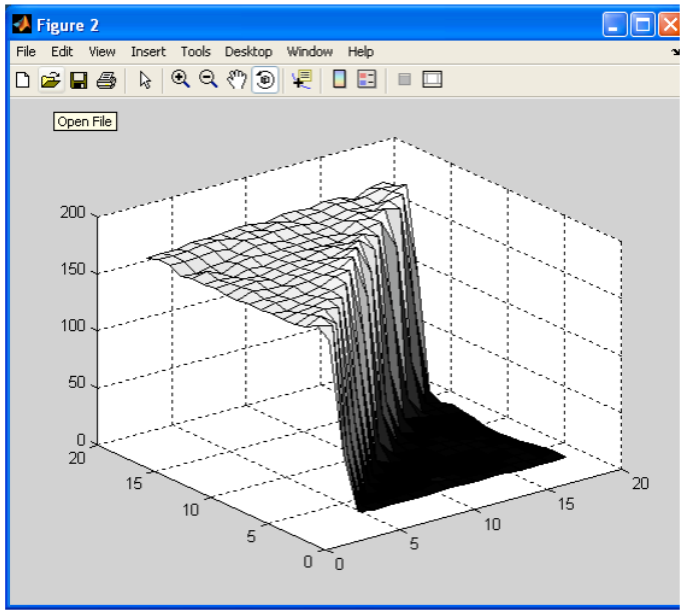
Plan

1. Gradijenti i glađenje
2. Rubovi
3. Houghova transformacija
4. Ključne točke

Gradijent: slika kao funkcija

Slike često tretiramo kao kontinuirane funkcije





[collins07cse486]

Prednost: analiza primjenom alata matematičke analize

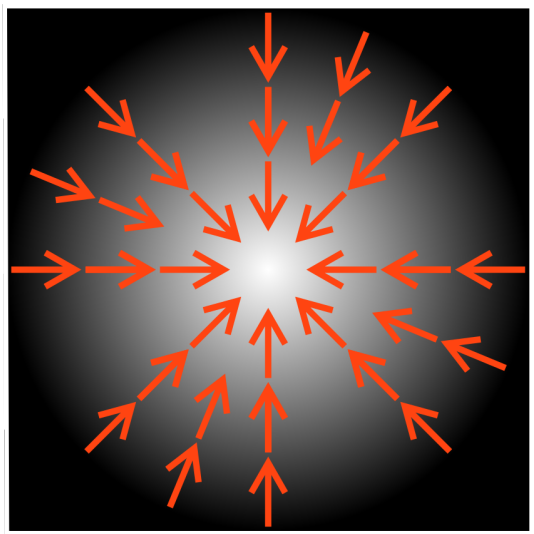
- rubovi objekata imaju veliki gradijent
- okna s "nejednolikim" gradijentom pogodna za **korespondenciju**
- u drugoj slici iste scene, lakat ćemo lakše prepoznati od nadlaktice

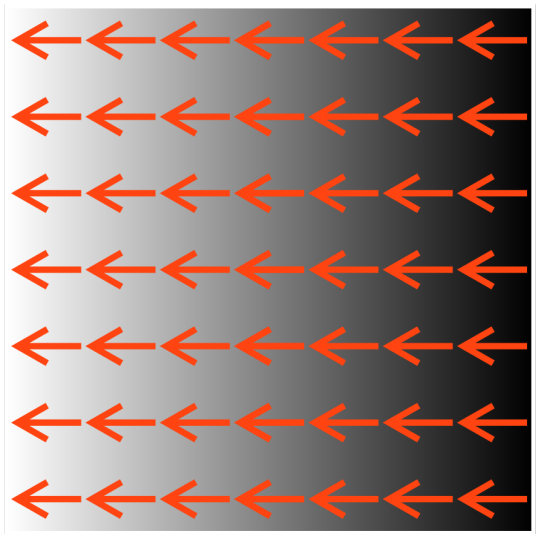
Gradijent: formulacija

Gradijent kontinuirane skalarne funkcije dvije varijable:

$$\nabla I(\mathbf{q}) = \partial I / \partial \mathbf{q} = [I_x(\mathbf{q}), I_y(\mathbf{q})]$$

Gradijent možemo interpretirati kao smjer najbržeg rasta sive razine:

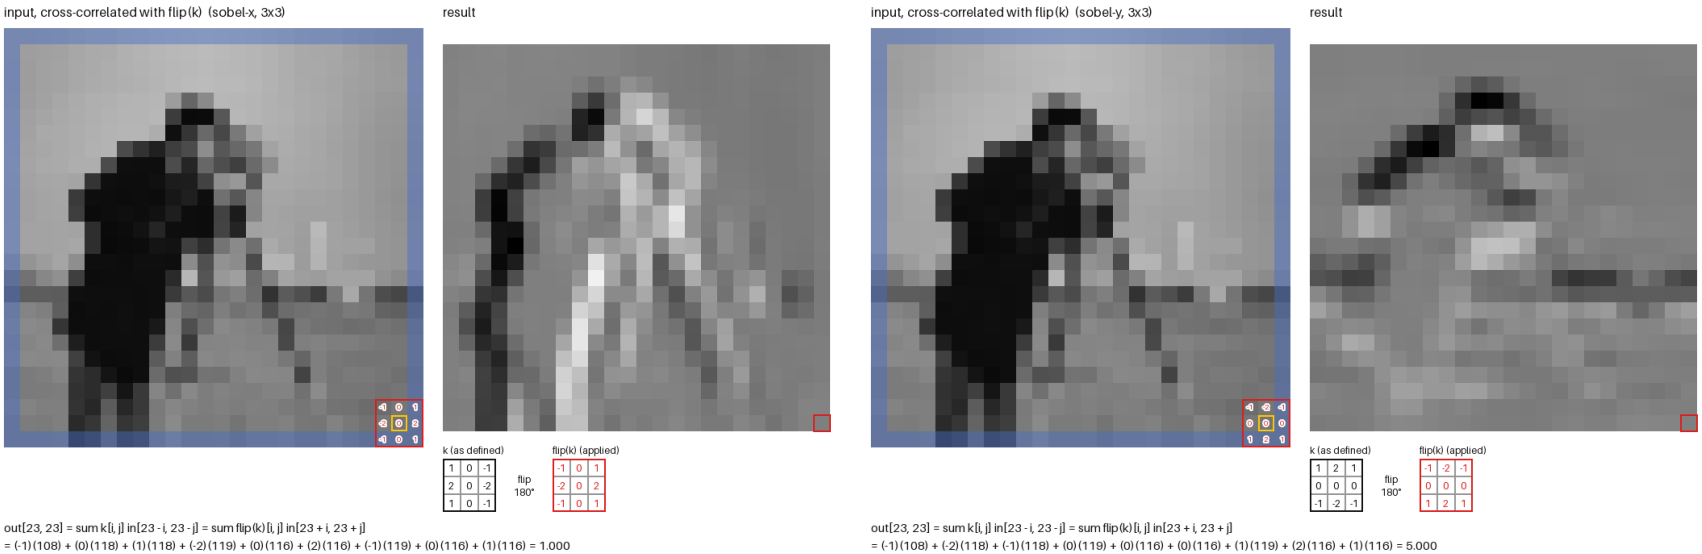




[Wikipedia]

Gradijent: Podsjetnik: konvolucija

$$h(\mathbf{q}) = (\mathbf{w} * \mathbf{I})(\mathbf{q}) = \sum_{\tau \in \mathcal{D}(\mathbf{w})} \mathbf{w}(\tau)\mathbf{I}(\mathbf{q} - \tau)$$

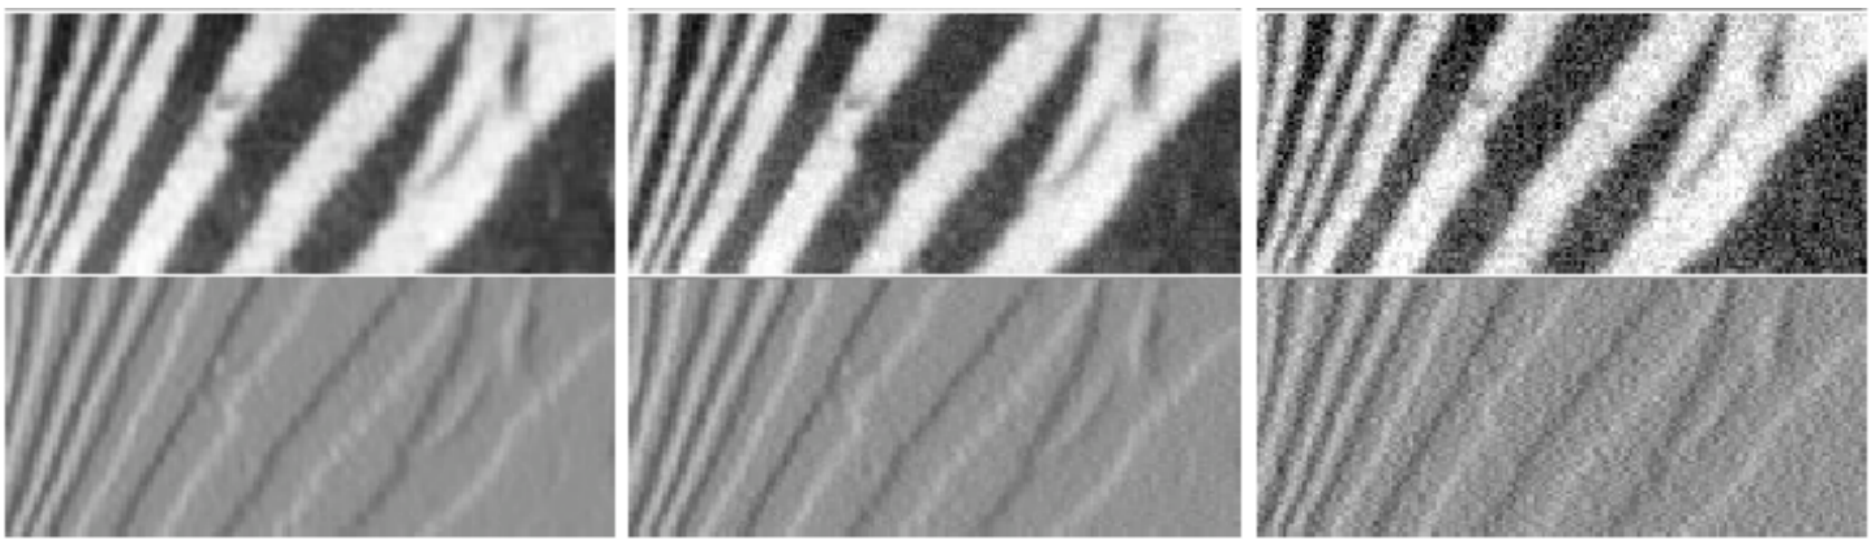


Za razliku od unakrsne korelacije, konvolucija je asocijativna i komutativna: $(\mathbf{w} * (\mathbf{y} * \mathbf{I}))(\mathbf{q}) = ((\mathbf{w} * \mathbf{y}) * \mathbf{I})(\mathbf{q}) = ((\mathbf{y} * \mathbf{w}) * \mathbf{I})(\mathbf{q})$

Gradijent: šum

Međutim, deriviranje se loše ponaša u prisustvu šuma

- prvi redak: slike s rastućim udjelom šuma
- drugi redak: aproksimacija negativnog horizontalnog gradijenta konačnim razlikama



[ponce12book]

Vidimo da deriviranje naglašava šum

- zbog toga prije deriviranja obično primjenjujemo glađenje

Gradijent: glađenje

Jače glađenje tolerira više šuma ali i gubi fine detalje



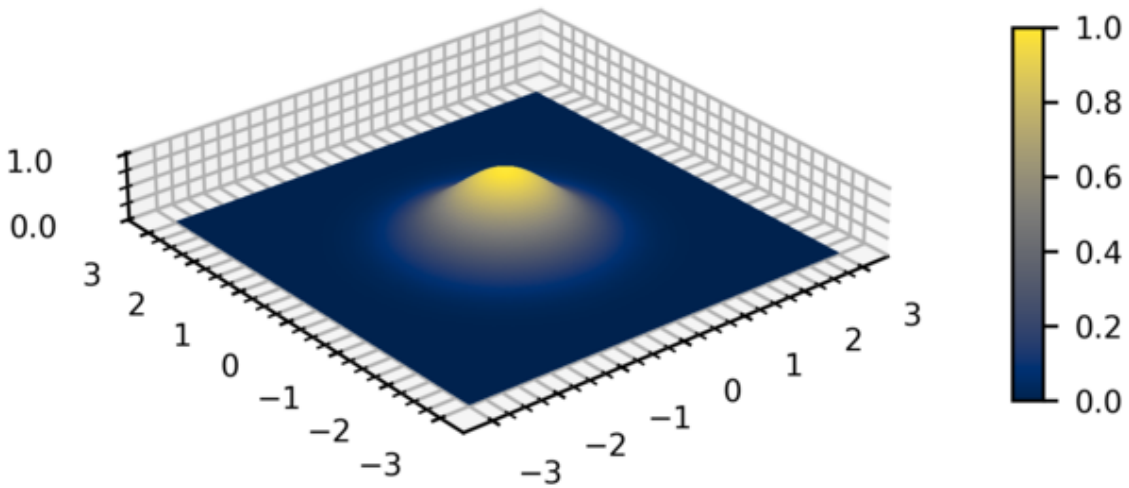
[lindeberg08wiley]

Gradijent: Gauss

Optimalnu detekciju rubova osigurava glađenje koje možemo aproksimirati konvolucijom s dekoreliranim Gaussom [canny86pami]

- svaki piksel mijenjamo s prosjekom njegovog susjedstva
- bliži susjedi su važniji
- važno svojstvo: separabilnost

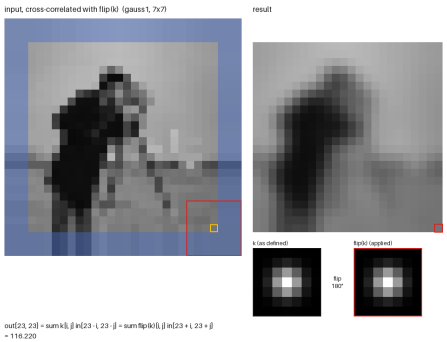
$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

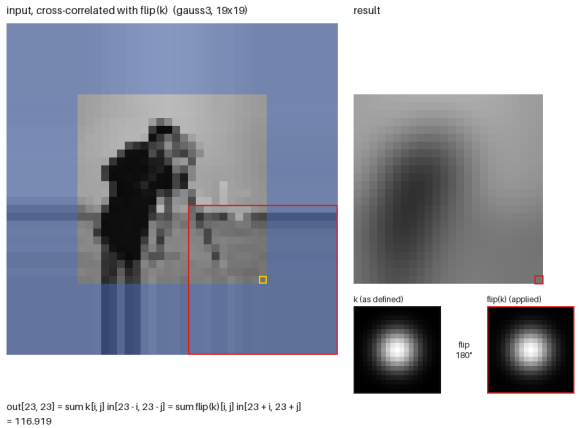


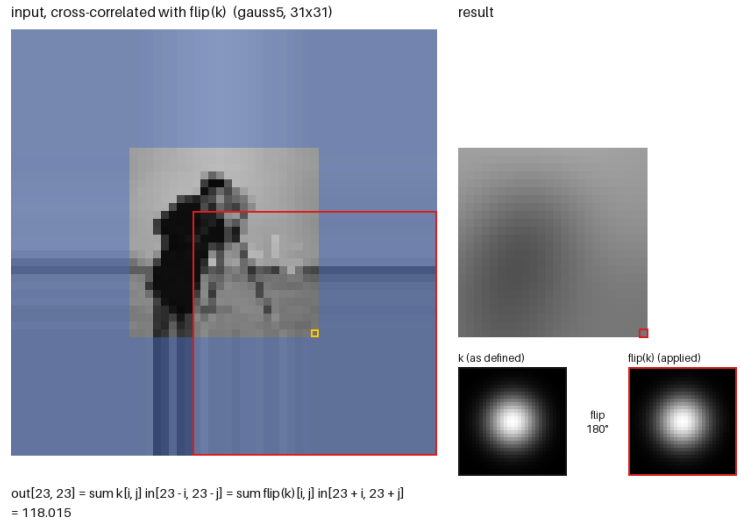
[Wikipedia]

Gradijent: Gauss (2)

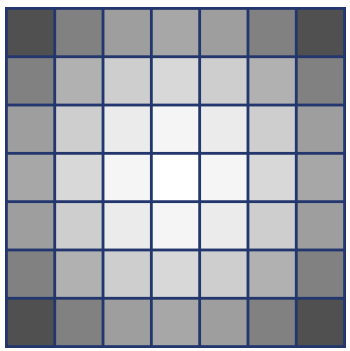
Prilikom računanja elemenata jezgre, veličinu jezgre postavljamo na $2\lceil 3\sigma \rceil + 1$.

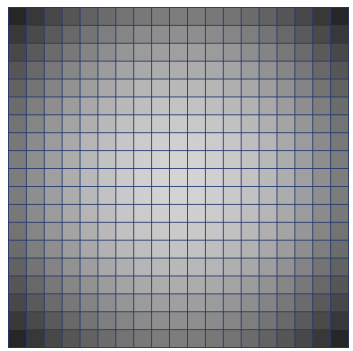


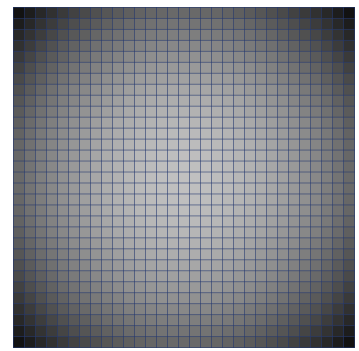




$\sigma = 1$ $\sigma = 3$ $\sigma = 5$





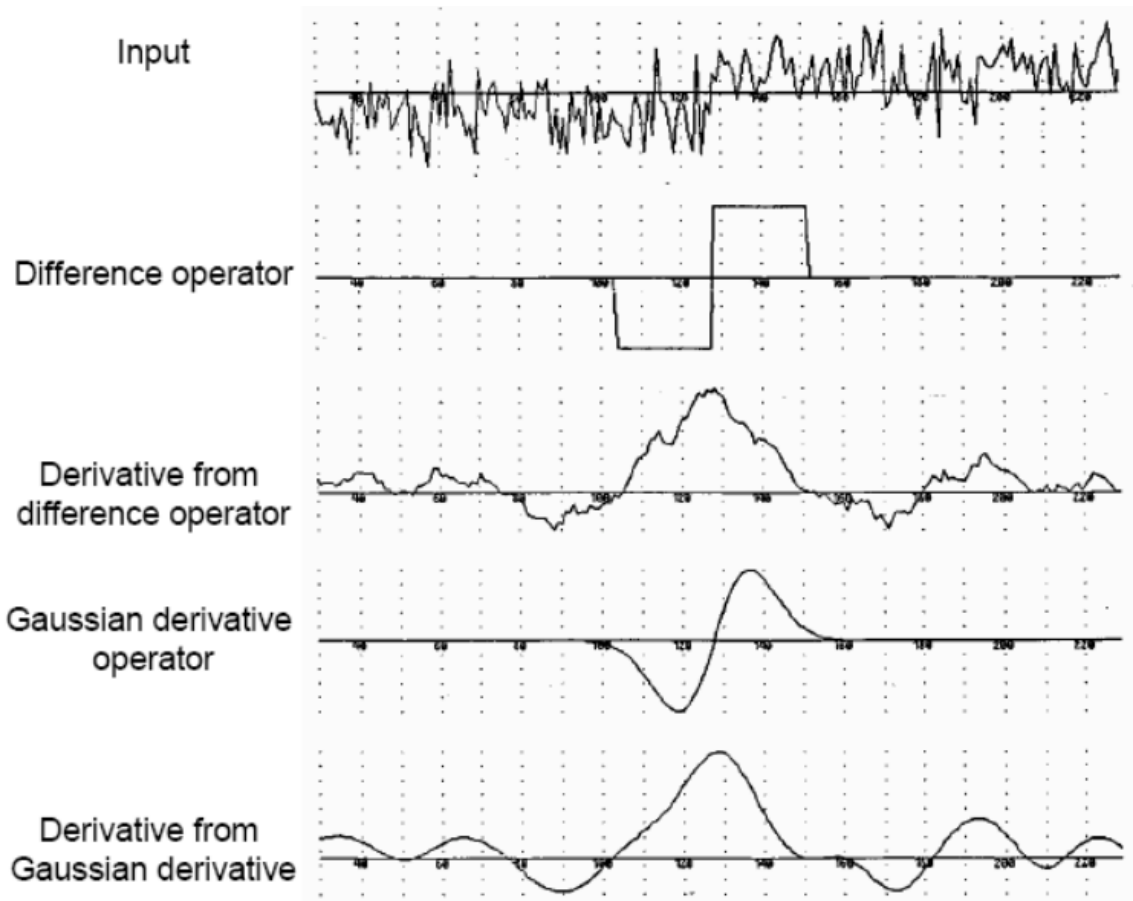


7×7 19×19 31×31

Gradijent: recept

Aproksimirati gradijente konvolucijom s derivacijom Gaussovog filtra

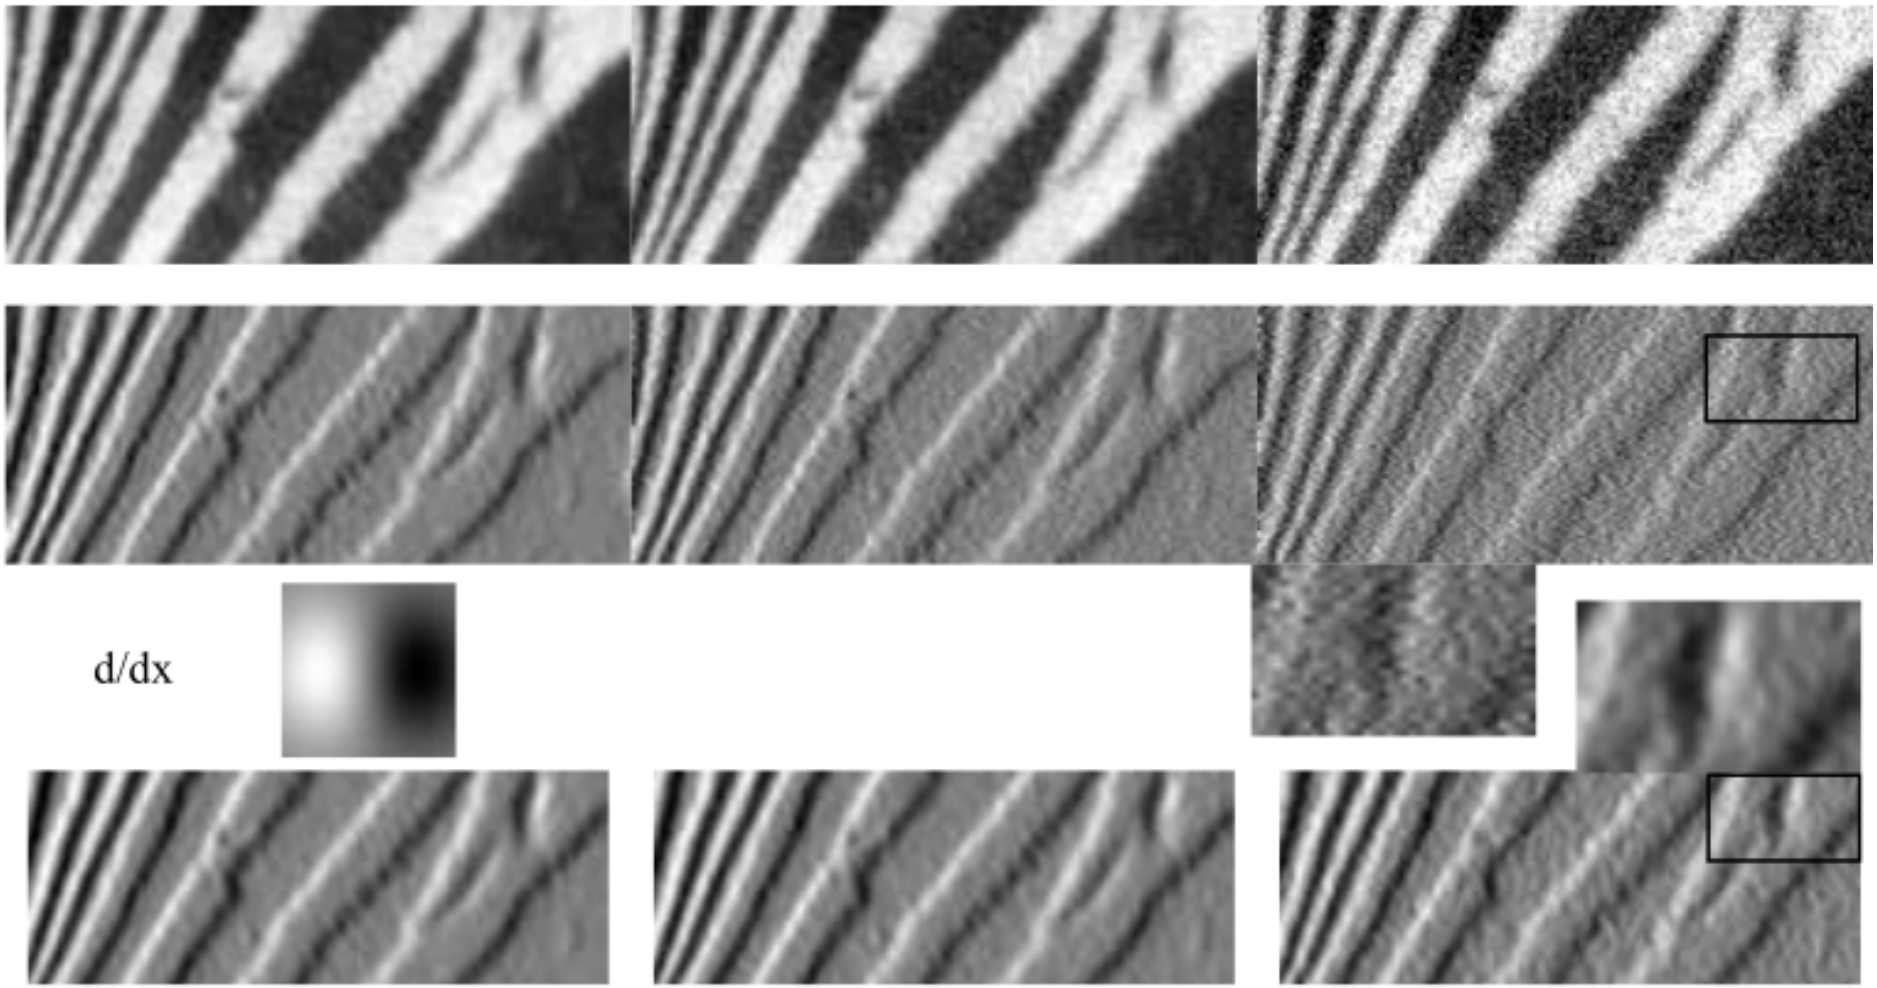
- dva koraka mogu se stopiti u jedan
- konvolucije i derivacije su asocijativne



[canny86pami]

Gradijent: recept (2)

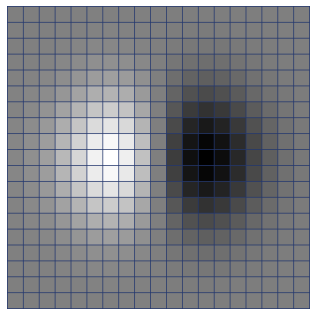
Gradijente je bolje aproksimirati konvolucijom s derivacijom Gaussa nego konačnim diferencijama



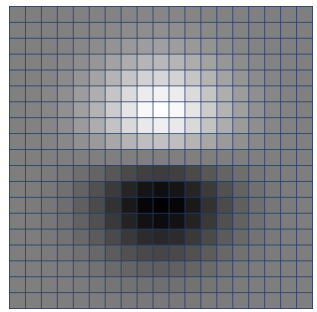
[ponce12book]

Gradijent: recept (3)

Derivacije Gaussa: $\frac{\partial G}{\partial x} = -\frac{x}{\sigma^2}\, G(x,y), \qquad \frac{\partial G}{\partial y} = -\frac{y}{\sigma^2}\, G(x,y)$



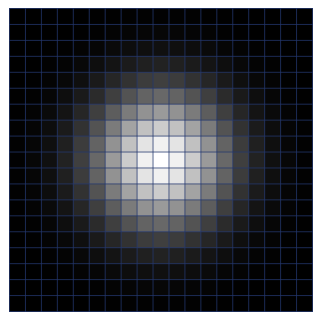
$\partial G/\partial x$



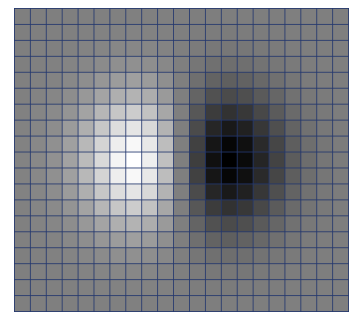
$\partial G/\partial y$

Konvolucija konačnih razlika i Gaussa daje (do na faktor 2) sličnu jezgru:

$$\frac{1}{2}\begin{bmatrix} 1 & 0 & -1 \end{bmatrix} \quad * \quad$$



$$=$$



D (konačne razlike) G (glađenje) $\frac{1}{2} D * G \approx \partial G/\partial x$

Gradijent: separabilna izvedba

I gauss i derivirani Gauss su separabilni 2D filtri: 2D konvolucija s takvim filtrima može se izvesti uz pomoć dvije 1D konvolucije.

Ako nam se žuri, gradijente možemo aproksimirati i konačnim razlikama u zaglađenoj slici.

Jako važno za primjene u stvarnom vremenu, posebno ako postupak koristi slikovne piramide.

Gaussov filtar može se aproksimirati rekurzivnim binomnim filtrom (dodatno ubrzanje).

Gradijent: separabilna izvedba (2)

Konačne razlike u zaglađenoj slici, samo 1D jezgre:



I

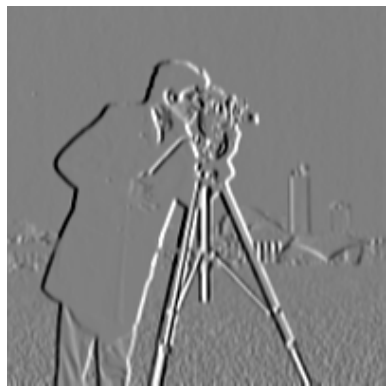
$* \; g_y \longrightarrow$



$g_y * I$

$\begin{bmatrix} 1 & 0 & -1 \end{bmatrix}$

$* \; D_x \longrightarrow$



$I_x \approx D_x * (g_y * I)$



I

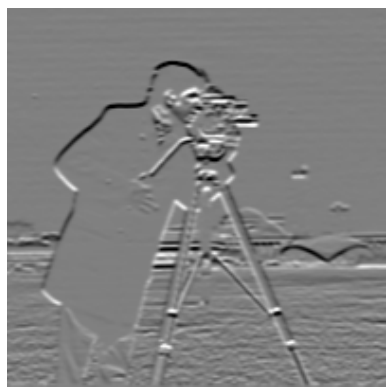
$* \; g_x \longrightarrow$



$g_x * I$

$\begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$

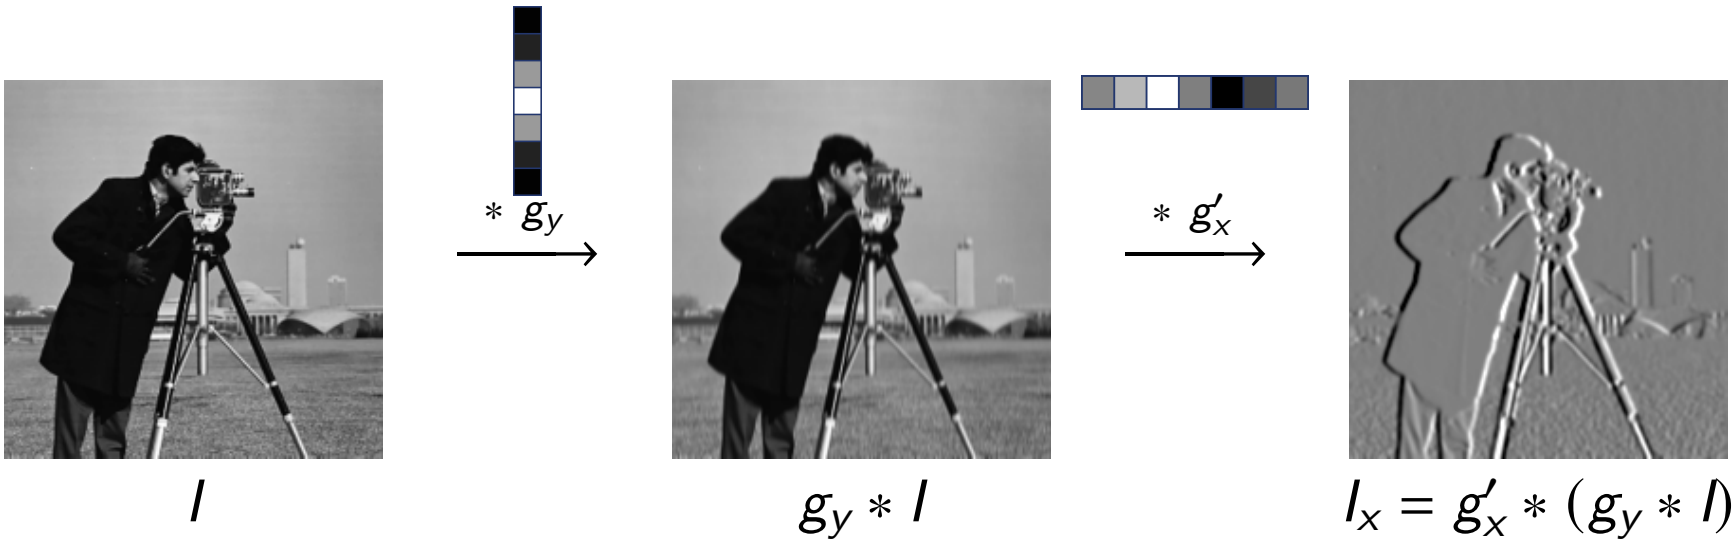
$* \; D_y \longrightarrow$



$I_y \approx D_y * (g_x * I)$

Gradijent: separabilna izvedba (3)

Separabilni filtar derivacije Gaussa: $g'_x * (g_y * I) = \frac{\partial G}{\partial x} * I$



Rubovi

Rubovi upućuju na granice objekata:

- **oblik**: inherentno svojstvo objekta
- teže ga je sakriti od **teksture**
- organizmi koji vide oblik imaju evolucijsku prednost

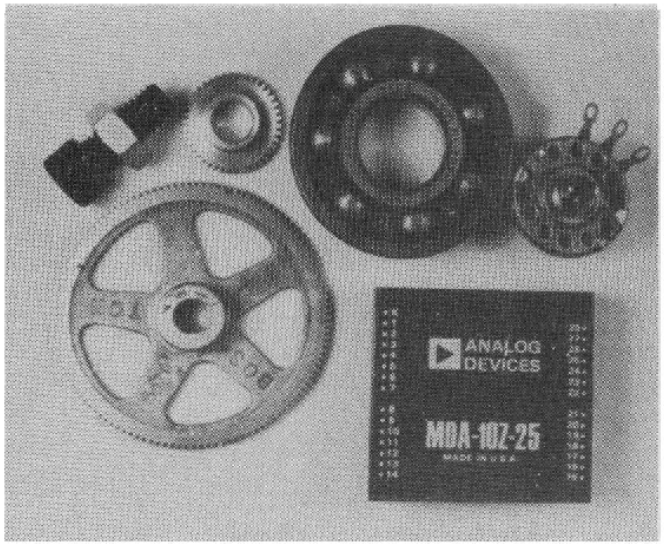


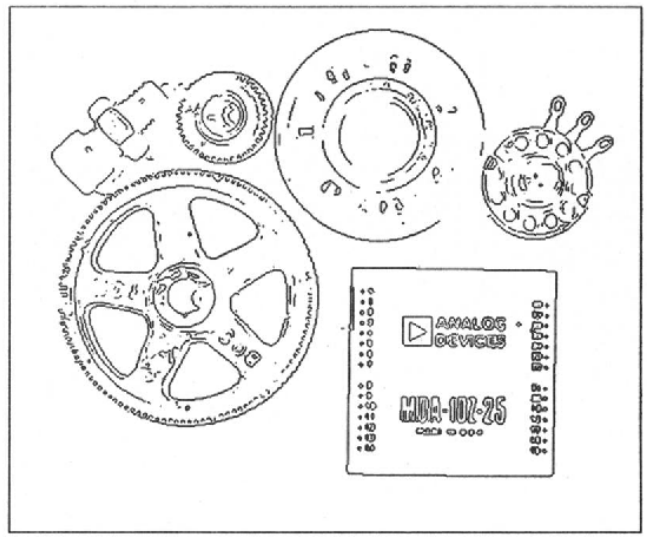


[biologyonline,flickr]

Rubovi: motivacija

Rane metode iz romantičarske faze računalnog vida imale su ambiciju detektirati objekte analizom rubova:





[canny86pami]

- kasnije smo spoznali da to ipak ne bi išlo samo tako :-)
- da bi znao iscrtati rub objekta - moraš razumjeti gdje je objekt (ne pripadaju svi rubovi u slici istom objektu)
- gradijent je presirova informacija za tako zahtjevan zadatak
- ipak, stečena iskustva mogu dati korisnu intuiciju pri razvoju

Rubovi: Cannyjev algoritam

Jedan od najstarijih i najdosljednijih detektora rubova

Glavni koraci algoritma:

1. računanje gradijenta konvolucijom s deriviranim Gaussom
   - možemo i aproksimirati konačnim razlikama u zaglađenoj slici
   - ne puno lošije, do 2× brže
2. stanjivanje rubova potiskivanjem ne-maksimalnih odziva u smjeru pružanja gradijenta
   - ideja je rubove smjestiti u točkama infleksije profila sive razine uzduž smjera gradijenta
   - dobro za lokalizaciju rubova
3. (opcionalno) potisnuti rubove s malenim gradijentom usporedbom s unaprijed zadanim histereznim pragom

Rubovi: Cannyjev algoritam (2)

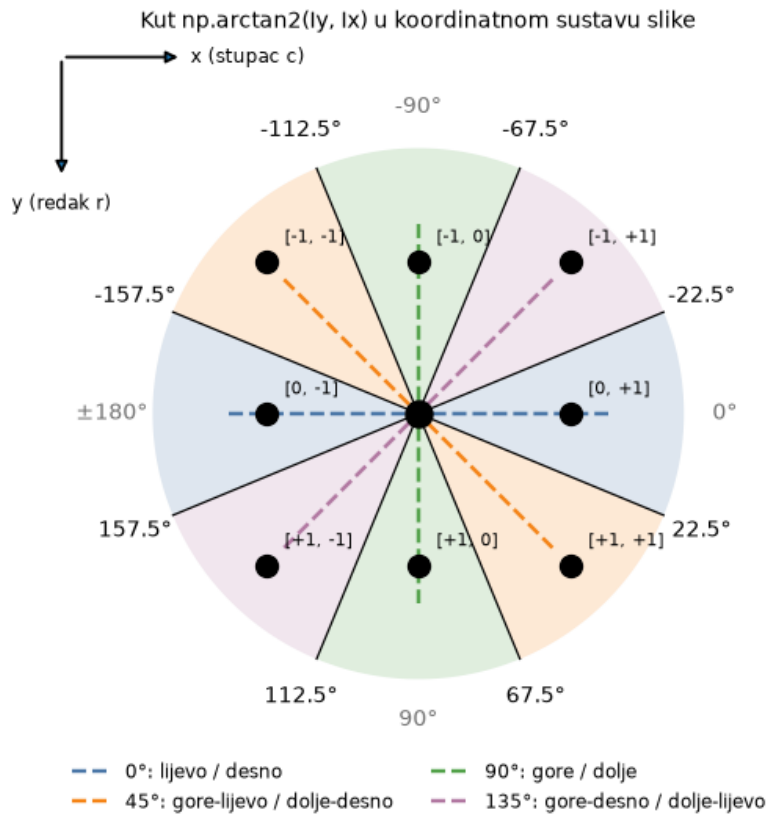
1. Računanje gradijenta slike
   - tipično - Sobelov operator uz prethodno zaglađivanje

S_x

1	0	-1
2	0	-2
1	0	-1

S_y

1	2	1
0	0	0
-1	-2	-1



rezultat: matrice gradijenata u x i y smjeru

$$I_x = S_x * I, \quad I_y = S_y * I$$

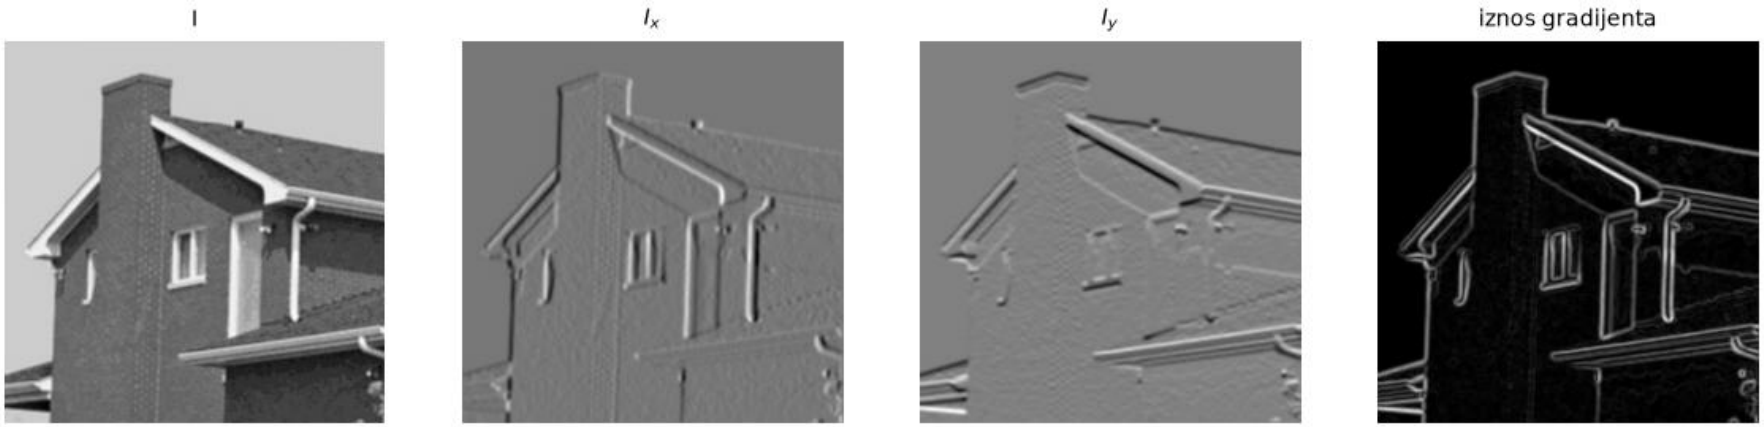
iznos i smjer gradijenta:

$$|G| = \sqrt{I_x^2 + I_y^2}$$

$$\theta = \text{atan2}(I_y, I_x)$$

Rubovi: Cannyjev algoritam (3)

1. Računanje gradijenta konvolucijom s deriviranim Gaussom (2)
   - primjer na slici kuće: izvorna slika, I_x, I_y, $|G|$

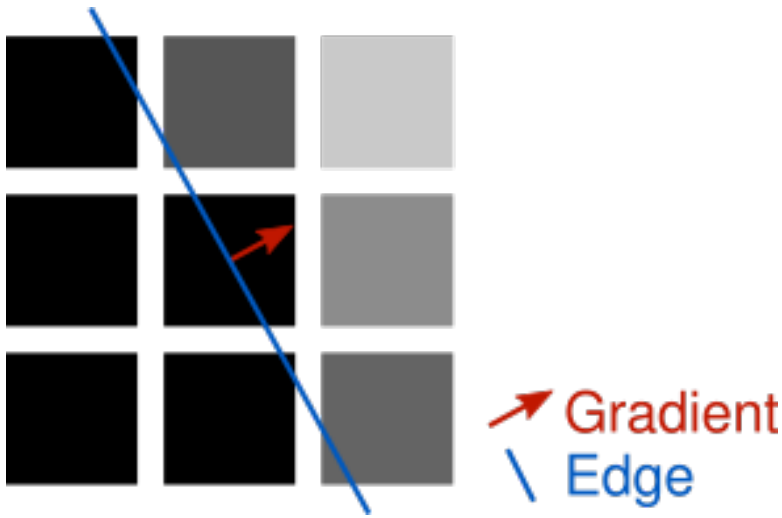


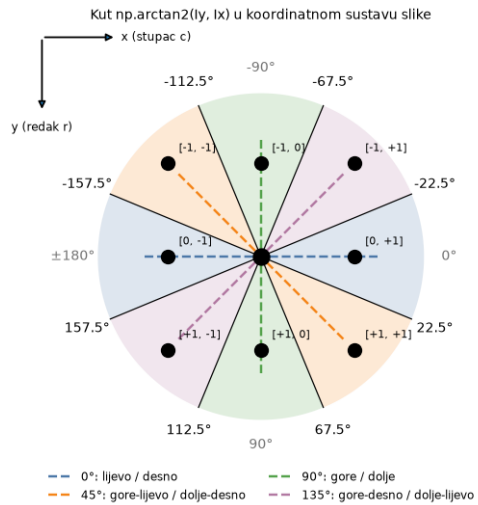
I_x i I_y imaju predznak: siva odgovara gradijentu 0, svjetlije je porast, a tamnije pad intenziteta

Rubovi: Cannyjev algoritam (4)

2. Stanjivanje rubova potiskivanjem ne-maksimalnih odziva u smjeru pružanja gradijenta

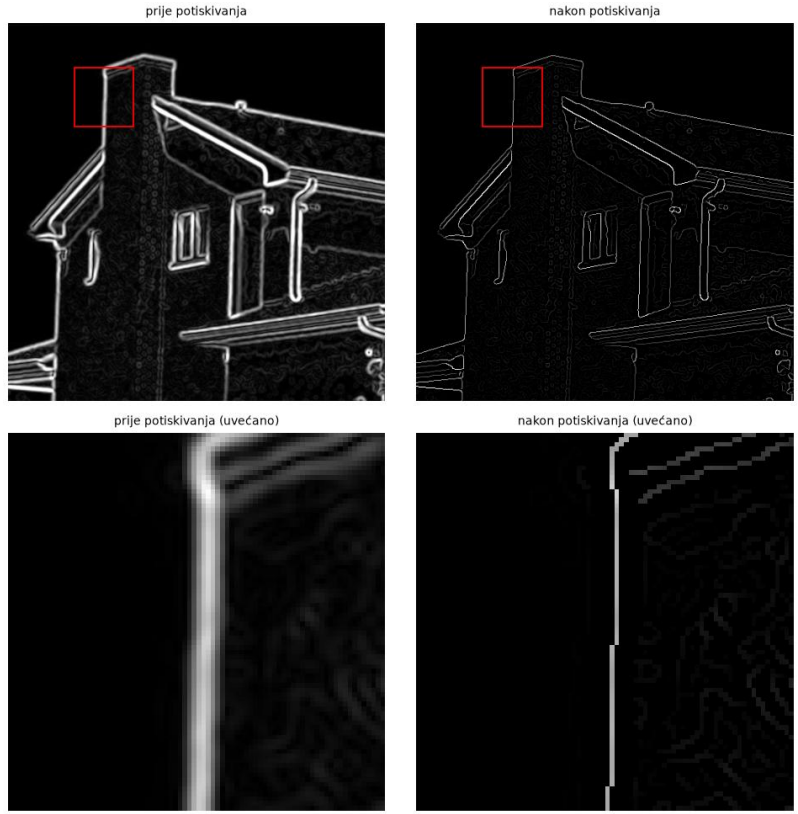
- rezultat računanja gradijenata je slika rubova, ali često širokih i nekoliko piksela (neprecizna lokalizacija)
- težimo preciznijoj lokalizaciji značajki
- ideja: svaki položaj u $|G|$ usporediti s njegova dva susjeda u smjeru gradijenta i zadržati samo one koji imaju veći iznos gradijenta od svojih susjeda





Rubovi: Cannyjev algoritam (5)

2. Stanjivanje rubova potiskivanjem ne-maksimalnih odziva u smjeru pružanja gradijenta (8 diskretnih smjerova)



Rubovi: Cannyjev algoritam (6)

3. Potiskivanje rubova s malenim gradijentom usporedbom s unaprijed zadanim histereznim pragom

- binarizacija rubova usporedbom s pragovima
- $|G| > T_2$ - sigurno rub ("jaki rubovi")
- $T_1 \geq |G| \geq T_2$ - potencijalno rub (slabi rubovi)
- $|G| < T_1$ - sigurno nije rub









$\sigma = 1.5$, $T_1 = 10$, $T_2 = 90$

Rubovi: Cannyjev algoritam (7)

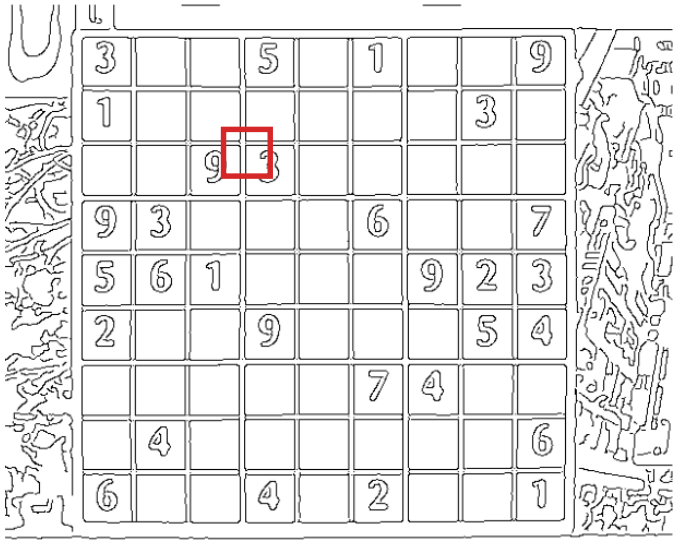
Literatura: https://ieeexplore.ieee.org/document/4767851

Detalji: https://unizg-fer-d307.github.io/compvis/lab/lab1/

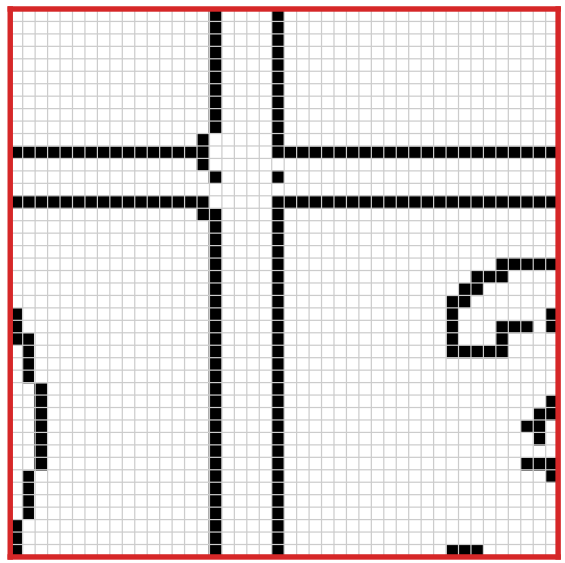
Houghova transformacija: motivacija

Izlaz Cannyjevog detektora iz 1. laboratorijske vježbe:

Canny



uvećano



(x, y):

```
(222, 118)
(227, 118)
(222, 119)
(227, 119)
(222, 120)
(227, 120)
(222, 121)
(227, 121)
(222, 122)
(227, 122)
(222, 123)
(227, 123)
(222, 124)
(227, 124)
...
```

[]

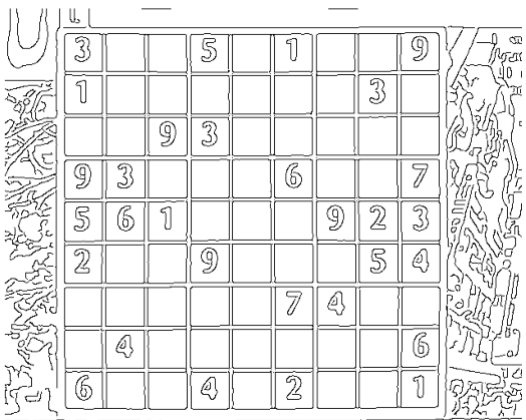
- Cannyevim algoritmom dobijemo samo popis piksela koji čine rubove
- ne znamo koji pikseli pripadaju istom pravcu, kružnici ili nekom drugom obliku

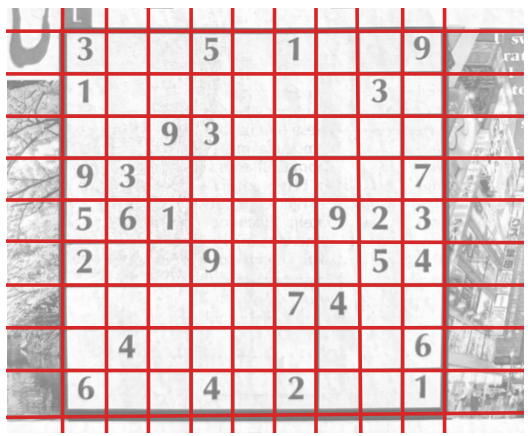
Houghova transformacija: motivacija

Iz rubnih piksela želimo izlučiti geometrijske entitete

- pravce, segmente, kružnice, elipse, oblike

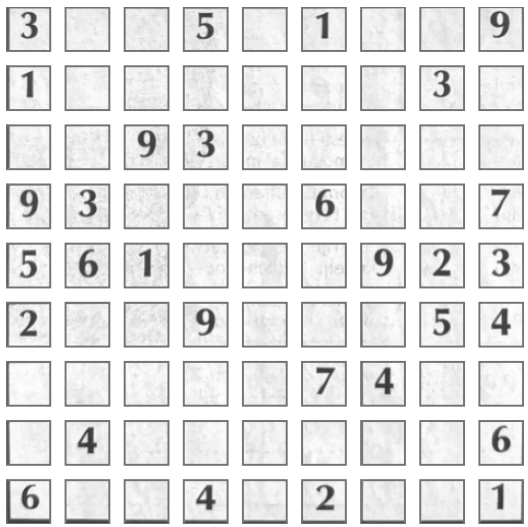
Canny





Hough

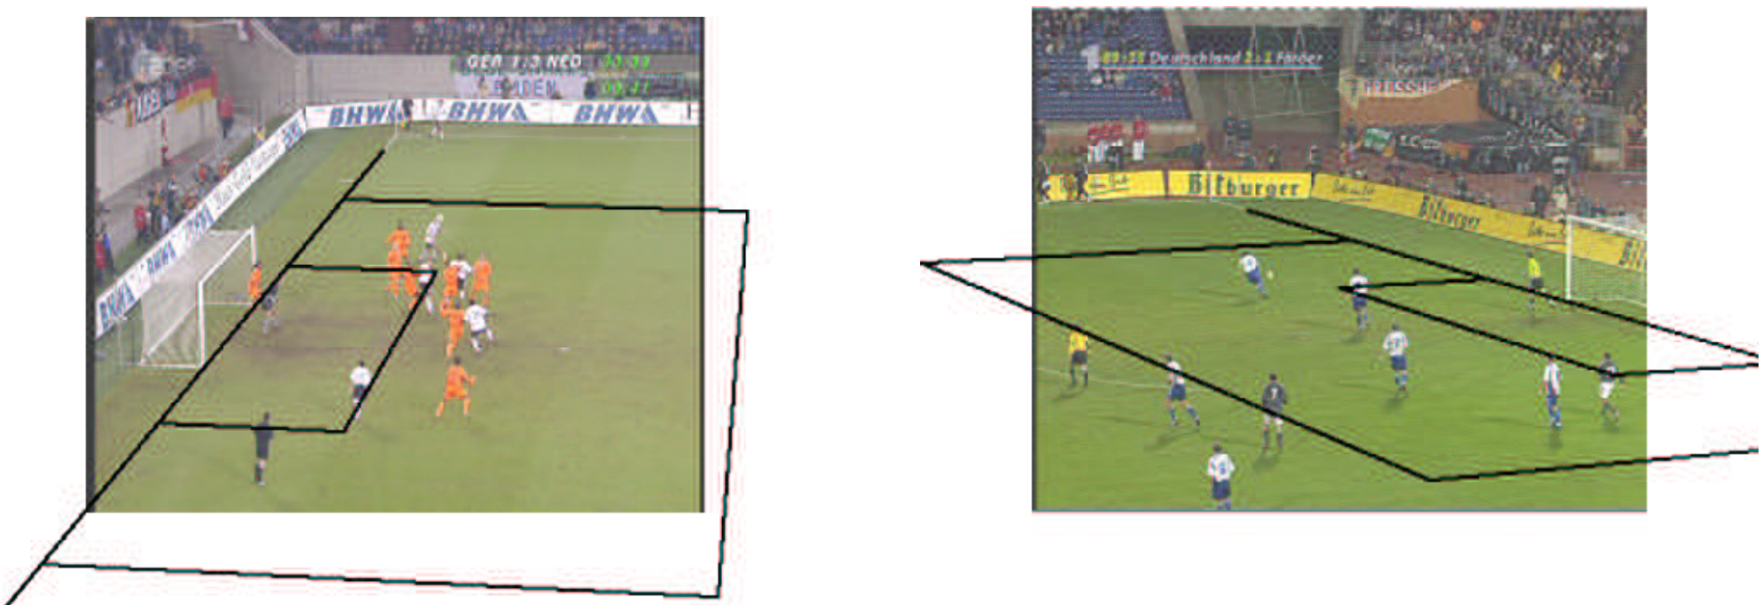
ćelije



Houghova transformacija: motivacija

Kalibracija kamere iz televizijskog prijenosa [farin04spie]: linije igrališta imaju poznat položaj na terenu

- primjena: položaj igrača u slici preslikamo u njegov položaj na terenu (u metrima)



[farin04spie]

Houghova transformacija: Izazovi

Zadatak: grupirati rubne elemente u instance parametarskog modela

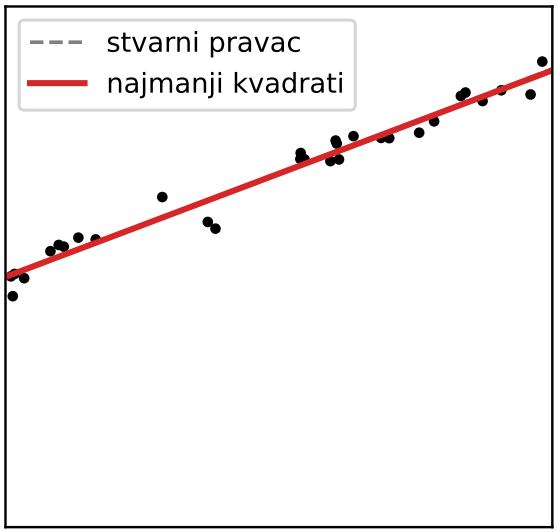
Poteškoće:

- šum: pikseli rubova ne leže točno na modelu
- stršeće vrijednosti (engl. outliers): većina elemenata ruba ne pripada nijednoj instanci
- prekidi: zakloni i slab kontrast razbijaju instancu na dijelove
- više instanci: ne znamo koliko ih ima niti koja točka pripada kojoj

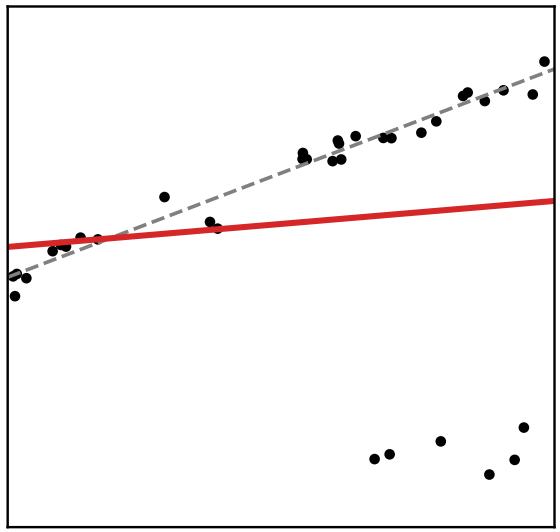
Houghova transformacija: najmanji kvadrati?

Klasična prilagodba pravca: $\min_{k,l} \sum_i (y_i - kx_i - l)^2$

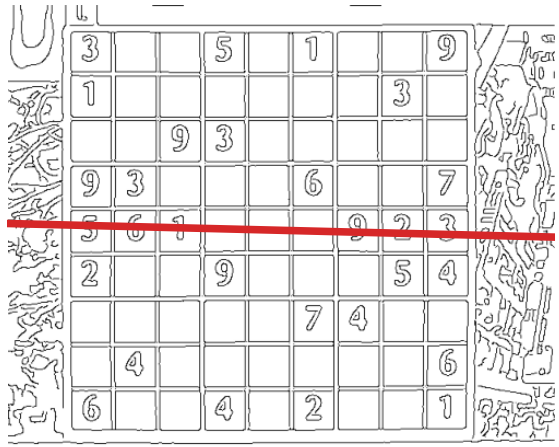
jedan pravac + šum



+ 6 stršećih točaka



svi rubni pikseli sudokua



- radi kad sve točke pripadaju **jednom** pravcu
- stršeće točke jako utječu na rješenje
- kako pronaći više pravaca? koje točke pripadaju kojem pravcu?

Houghova transformacija: glasanje

Kako pronaći pravce kad ne znamo koje točke idu zajedno?

Očit pristup: **generiraj i provjeri**

- pravac kroz svaki par točaka, prebroji točke koje ga podržavaju
- računski zahtjevno, previše hipoteza

Glasanje: obrnemo smjer

- hipoteze ne gradimo iz kombinacija točaka, nego svaka točka **neovisno** glasa za sve pravce koji kroz nju prolaze
- pravci za koje glasa puno točaka su detekcije
- grupiranje dobijemo besplatno: točke koje su glasale za isti pravac idu zajedno

Izvorno: tragovi čestica u mjehuričastoj komori [hough62patent]

Houghova transformacija: zašto glasanje radi

- stršeće točke glasaju nekonzistentno: **glasovi im se raspršuju** po različitim pravcima
- točke s iste instance glasaju složno: **glasovi im se gomilaju** na istom pravcu
- prekinute instance i dalje skupljaju glasove svih vidljivih dijelova
- više instanci $\Rightarrow$ više pravaca s puno glasova
- šum samo raspodijeli glasove na nekoliko vrlo sličnih pravaca

Cijena:

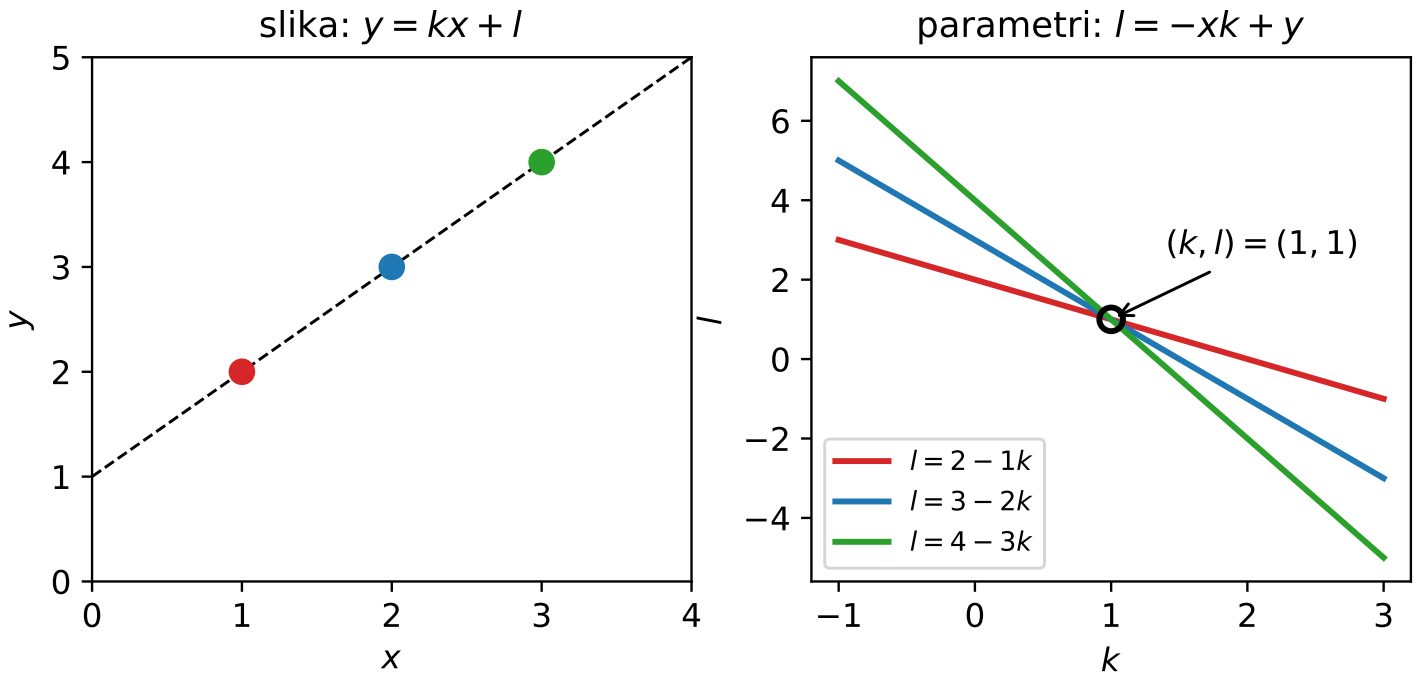
- moramo moći jednostavno pobrojati sve modele konzistentne s jednom točkom
- mogućih modela ne smije biti previše

Houghova transformacija: dualnost

Pravac u slici: $y = kx + l$, parametri (k, l)

Točka (x_i, y_i) je konzistentna sa svim pravcima za koje vrijedi $l = -x_i k + y_i$

- **točka u slici $\leftrightarrow$ pravac u prostoru parametara**
- kolinearne točke $\rightarrow$ pravci koji se sijeku u jednoj točki (k, l)



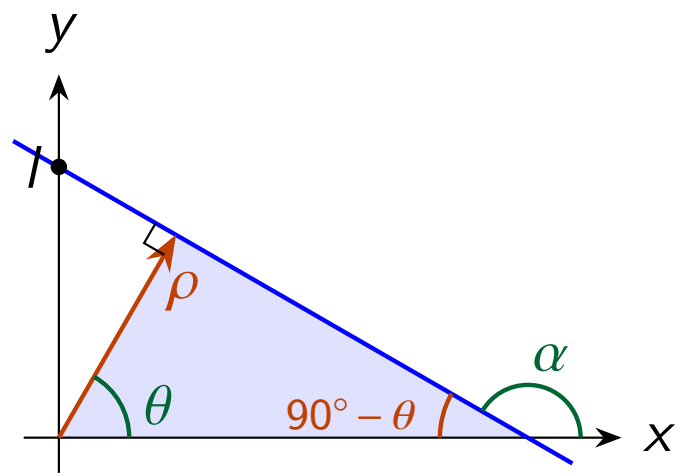
Houghova transformacija: nagib k preko θ

Problem: za okomite pravce $k \to \pm\infty$. Rješenje: reparametrizacija jednadžbe pravca preko kuta normale θ i udaljenosti od ishodišta ρ.

Kako izraziti k preko kuta normale θ? Poznato nam je da je k jednak tangensu kuta kojeg zatvara s osi apscisa: $k = \operatorname{tg}\alpha$.

α i $90° - \theta$ su susjedni kutovi:

$$\alpha + (90° - \theta) = 180° \implies \alpha = \theta + 90°$$



$$k = \operatorname{tg}\alpha = \frac{\sin\alpha}{\cos\alpha} = \frac{\sin(\theta + 90°)}{\cos(\theta + 90°)}$$

$$\sin(\theta + 90°) = \cos\theta$$

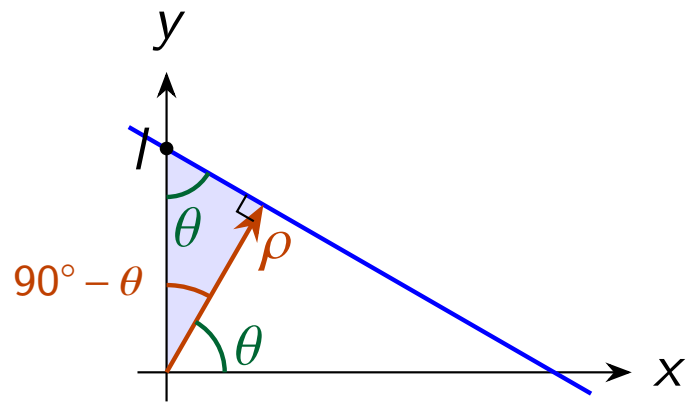
$$\cos(\theta + 90°) = -\sin\theta$$

$$\implies k = \frac{\cos\theta}{-\sin\theta} = -\frac{\cos\theta}{\sin\theta}$$

Houghova transformacija: odsječak l preko θ i ρ

Pravokutni trokut: ishodište, nožište normale, $(0, l)$

- kut uz ishodište $90° - \theta \Rightarrow$ kut u $(0, l)$ je θ
- nasuprot kutu θ je ρ, hipotenuza je l



$$\sin\theta = \frac{\rho}{l} \Rightarrow l = \frac{\rho}{\sin\theta}$$

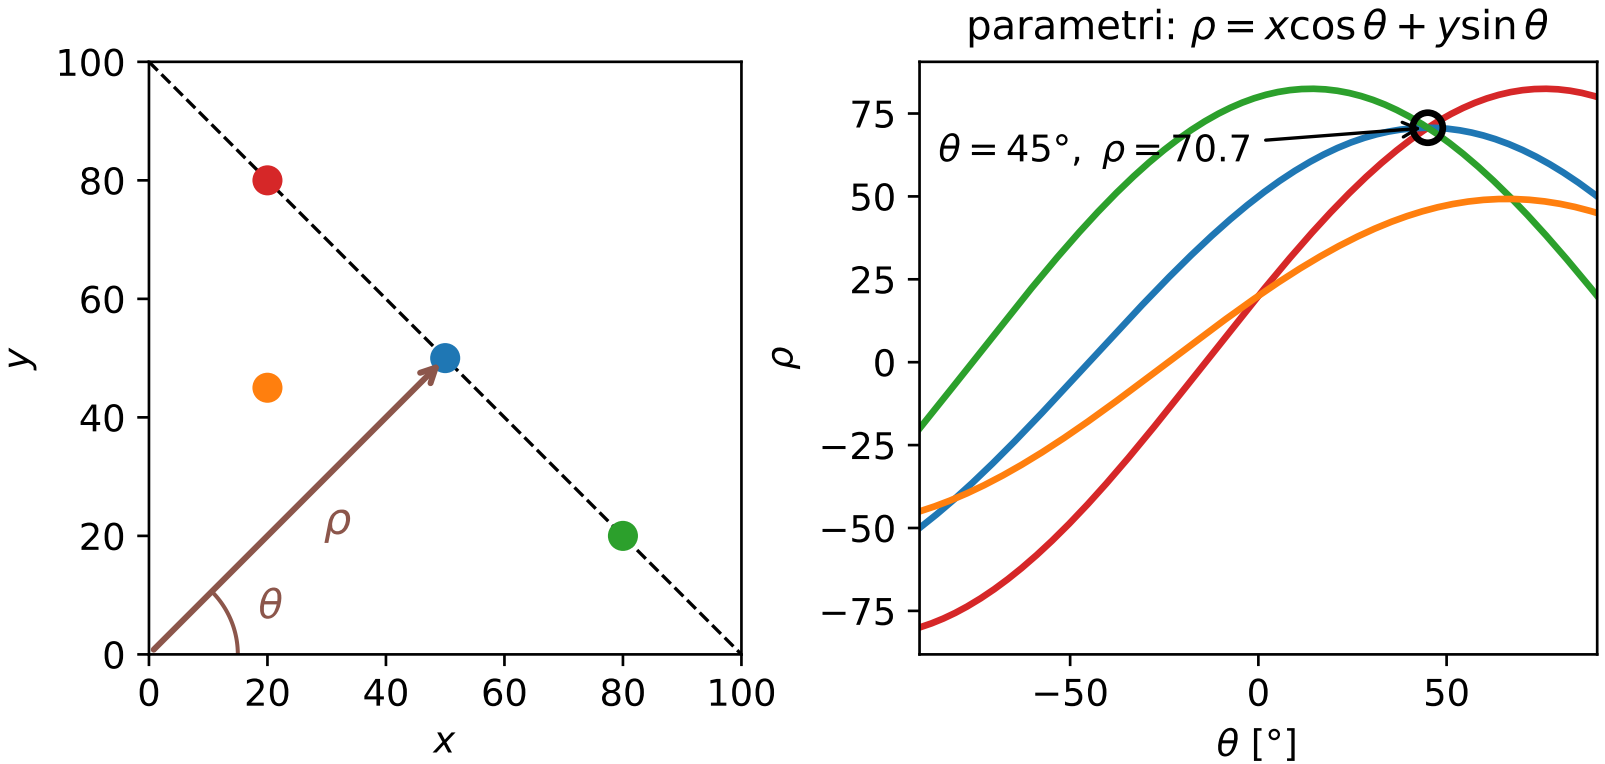
$$y = kx + l = -\frac{\cos\theta}{\sin\theta}x + \frac{\rho}{\sin\theta} \qquad \Big| \cdot \sin\theta$$

$$\rho = x\cos\theta + y\sin\theta$$

Izvod dijeli sa $\sin\theta$, ali rezultat vrijedi i za okomite pravce ($\theta = 0 \Rightarrow x = \rho$).
Za neusmjerene pravce dovoljno je $\theta \in [-90°, 90°)$, jer (θ, ρ) i $(\theta + 180°, -\rho)$ opisuju isti pravac; usmjereni pravci (polaritet ruba) trebaju $\theta \in [0°, 360°)$.

Houghova transformacija: sinusoide

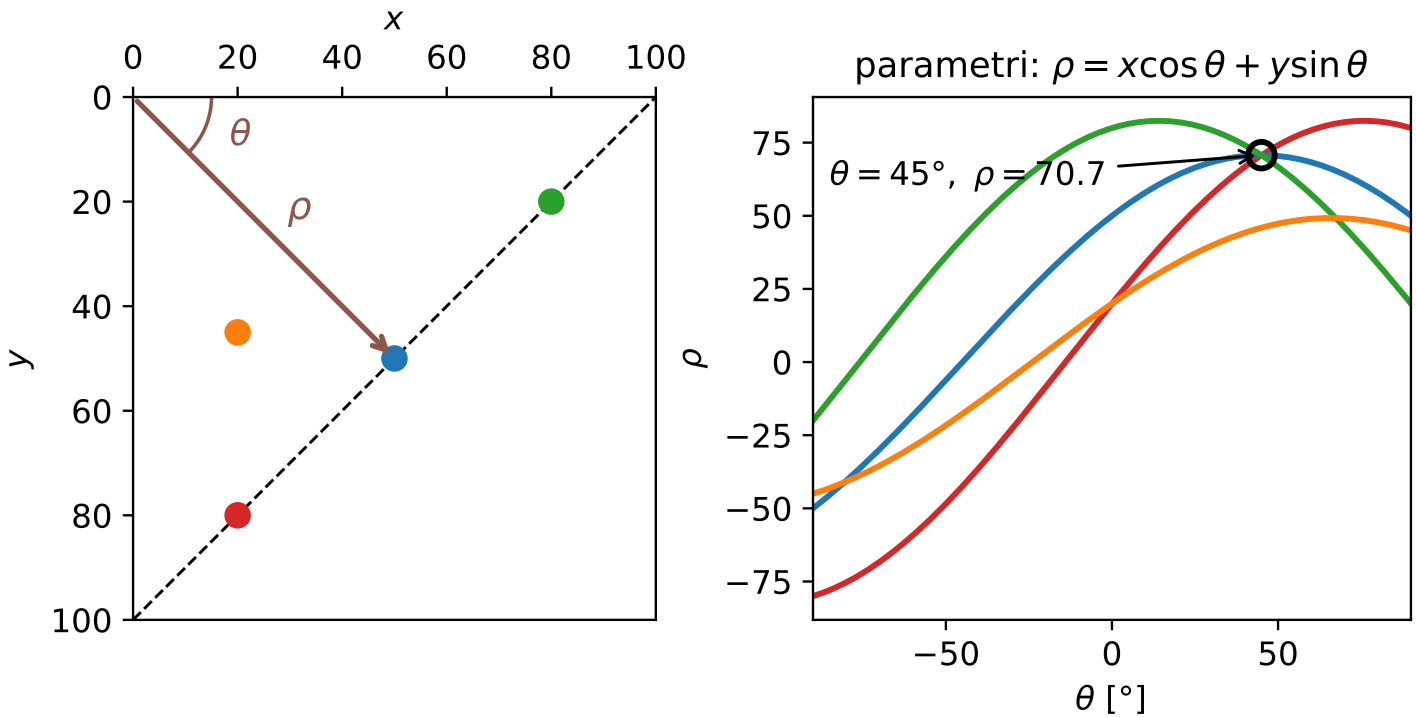
Točka (x_i, y_i) sada glasa po **sinusoidi** $\rho(\theta) = x_i \cos\theta + y_i \sin\theta$



- sinusoide kolinearnih točaka sijeku se u jednoj točki (θ, ρ)
- točka izvan pravca (narančasta) ne prolazi kroz to sjecište

Houghova transformacija: koordinate u slici

Ishodište u **gornjem lijevom kutu**, os y **prema dolje**



- jednadžba, sinusoide i sjecište su isti: **ništa bitno se ne mijenja**
- θ se i dalje mjeri od osi x prema osi y, ali u slici je to smjer kazaljke na satu

Houghova transformacija: algoritam

Houghova transformacija [hough62patent], oblik (θ, ρ) [duda72cacm]:

1. detektiraj rubove (npr. Canny)
2. inicijaliziraj akumulator $A[\theta, \rho] = 0$: $\theta \in [-90°, 90°)$, $|\rho| \leq \sqrt{W^2 + H^2}$, oba parametra su **ograničena**
3. za svaki rubni element (x, y):
   - za svaki θ_k iz diskretnog skupa:
     - $\rho = x \cos \theta_k + y \sin \theta_k$
     - $A[\theta_k, \text{bin_index}(\rho)]$ += 1
4. pronađi lokalne maksimume u A iznad praga

Houghova transformacija: lokalni maksimumi

Zbog šuma i diskretizacije, jedan pravac u slici često će rezultirati nakupinom susjednih ćelija visokog intenziteta u akumulatoru.

Ako bismo koristili samo usporedbu s pragom za odabir pravaca u akumulatoru, dobili bismo snop približno jednakih pravaca.

Potiskivanje nemaksimuma:

- ćelija ostaje samo ako je najveća u svom susjedstvu $k_\rho \times k_\theta$, ostale postavimo na 0
- susjedstvo određuje koliko blizu smiju biti dva različita pravca
- rubovi akumulatora su "zalijepljeni": (θ, ρ) i $(\theta + 180°, -\rho)$ su isti pravac, pa susjedstvo uz $\theta = \pm 90°$ prelazi na suprotni rub

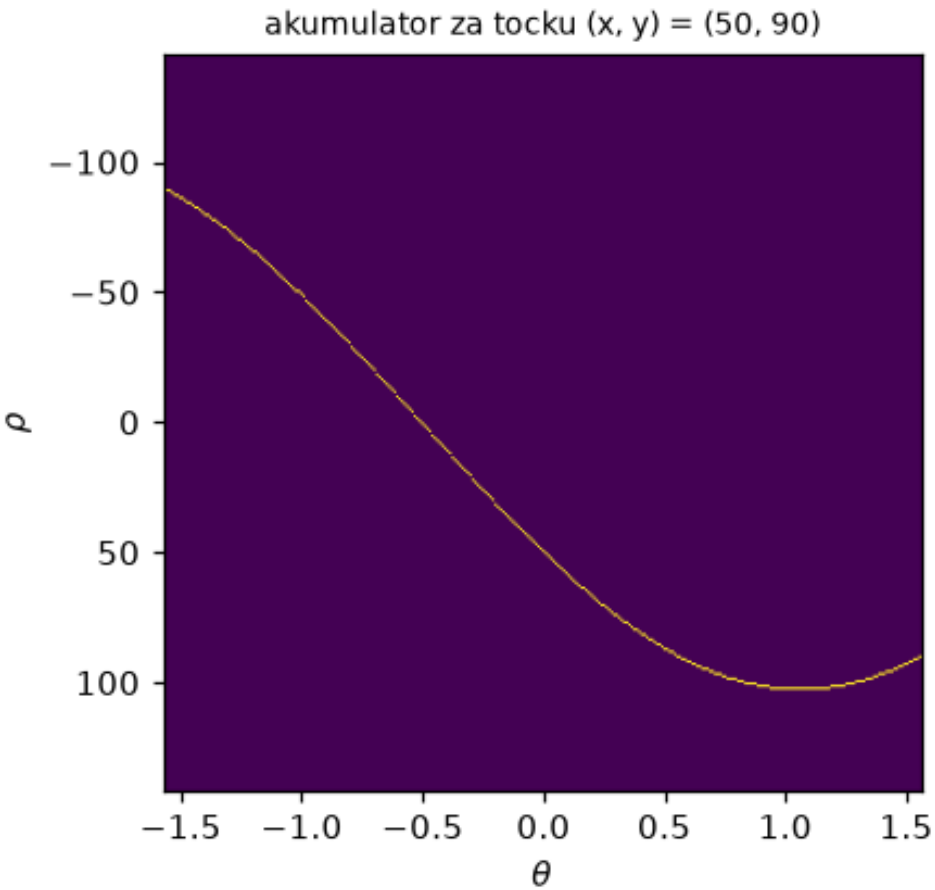
Houghova transformacija: prag

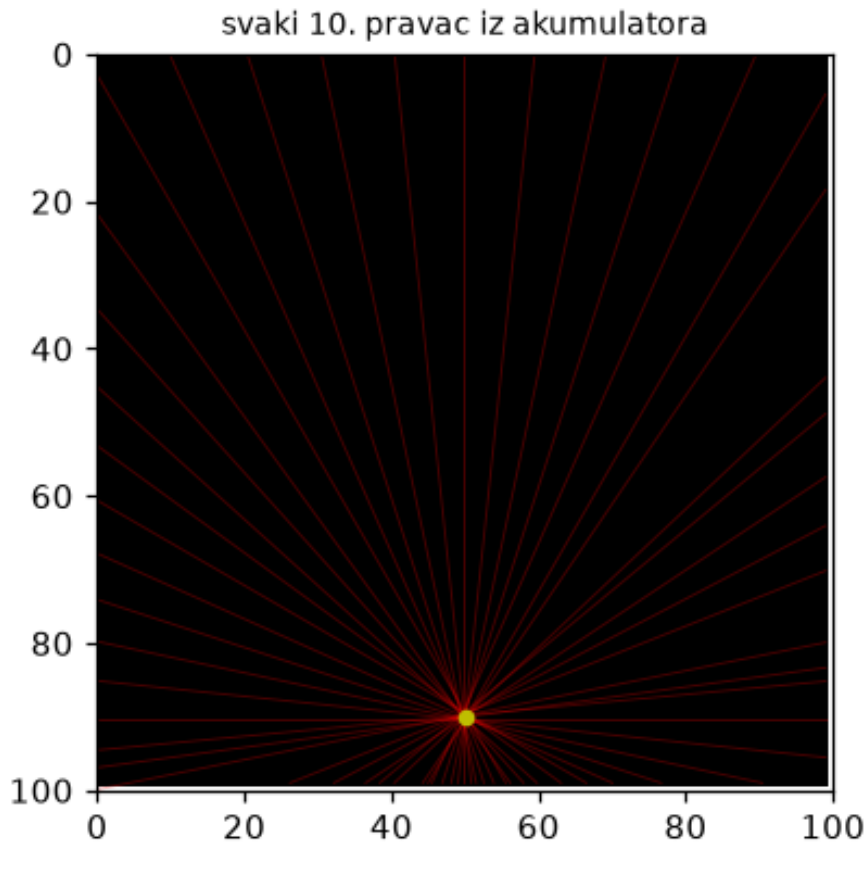
Broj glasova ćelije = broj piksela ruba na tom pravcu

- **apsolutni prag**: najmanja duljina pravca (u pikselima) koju želimo detektirati
- **relativni prag**: $\alpha \cdot \max A$, ne ovisi o veličini slike
- n **najjačih vrhova**: kad znamo koliko pravaca tražimo (sudoku: $n = 20$)

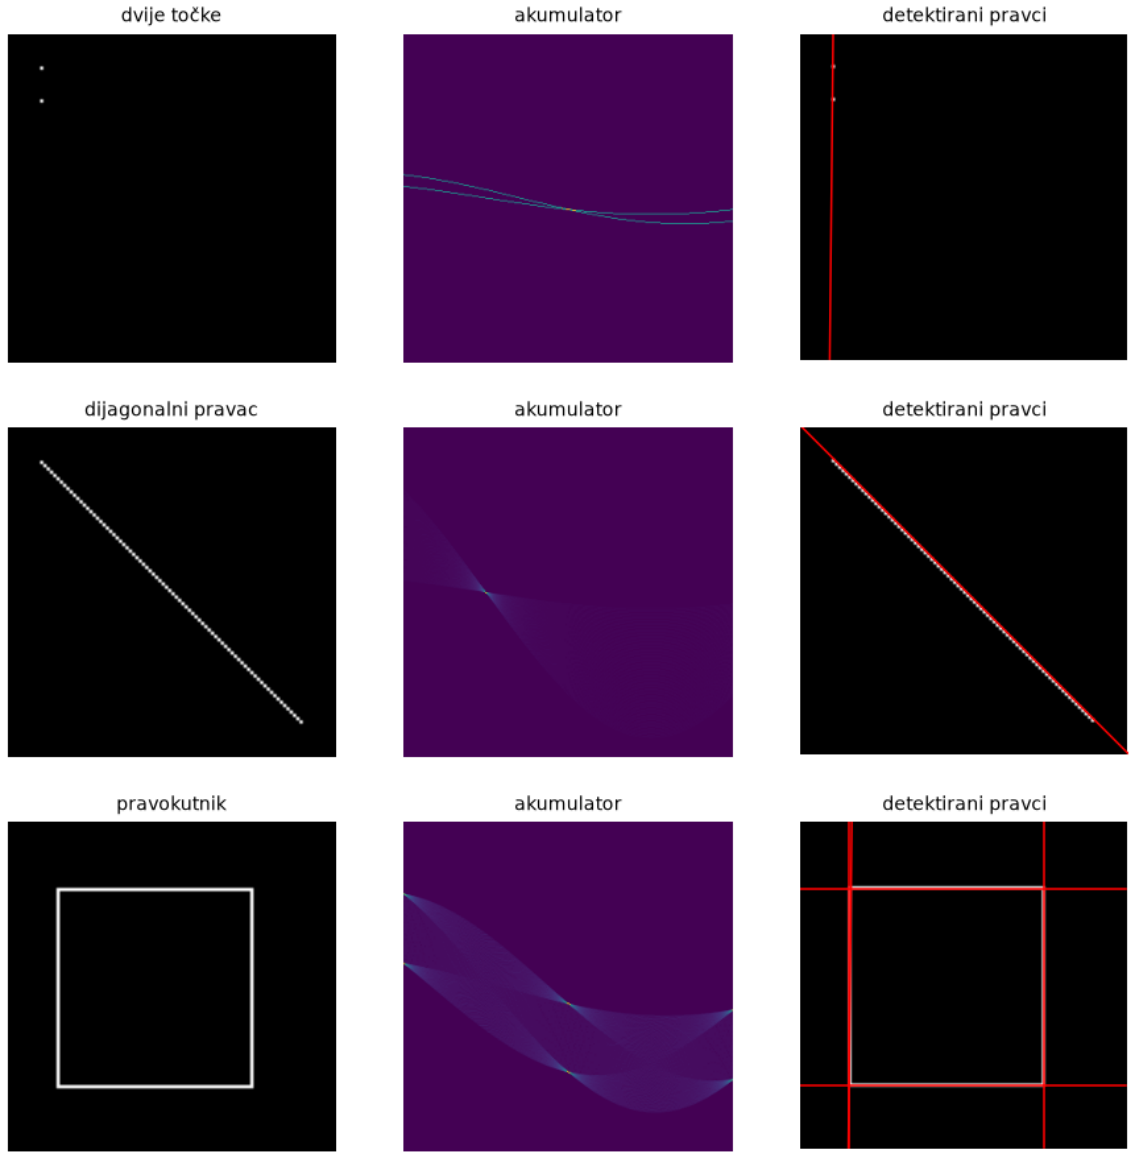
Previsok prag gubi kratke i prekinute pravce, prenizak daje lažne pravce iz teksture i šuma

Houghova transformacija: jedna točka

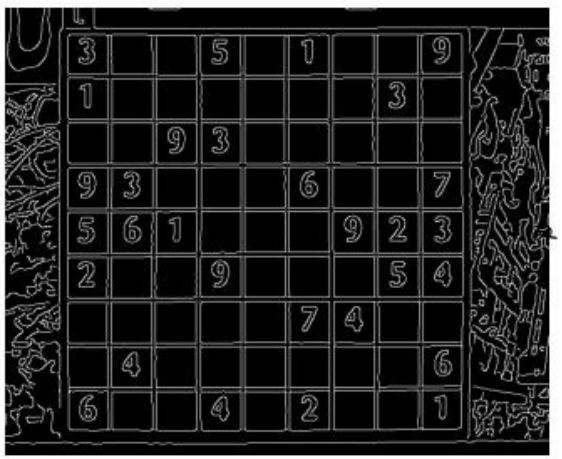


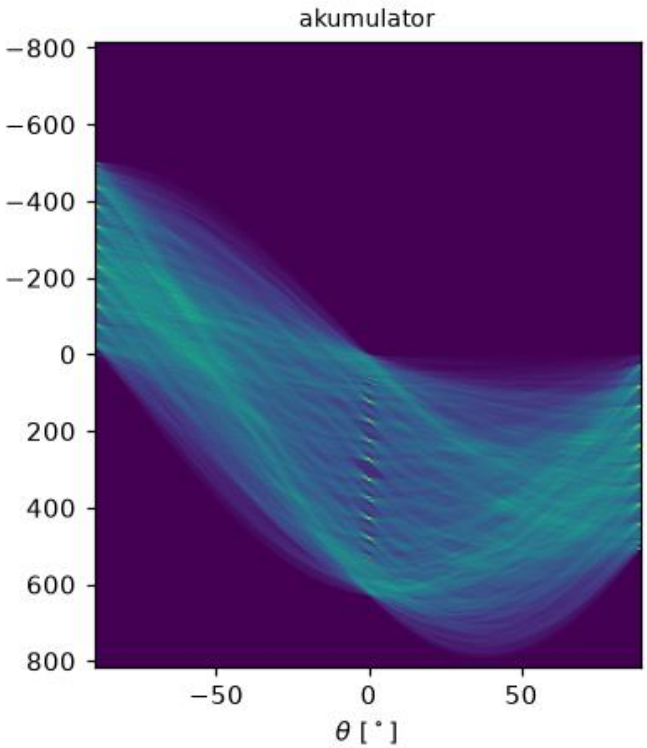


Houghova transformacija: sintetičke slike



Houghova transformacija: sudoku



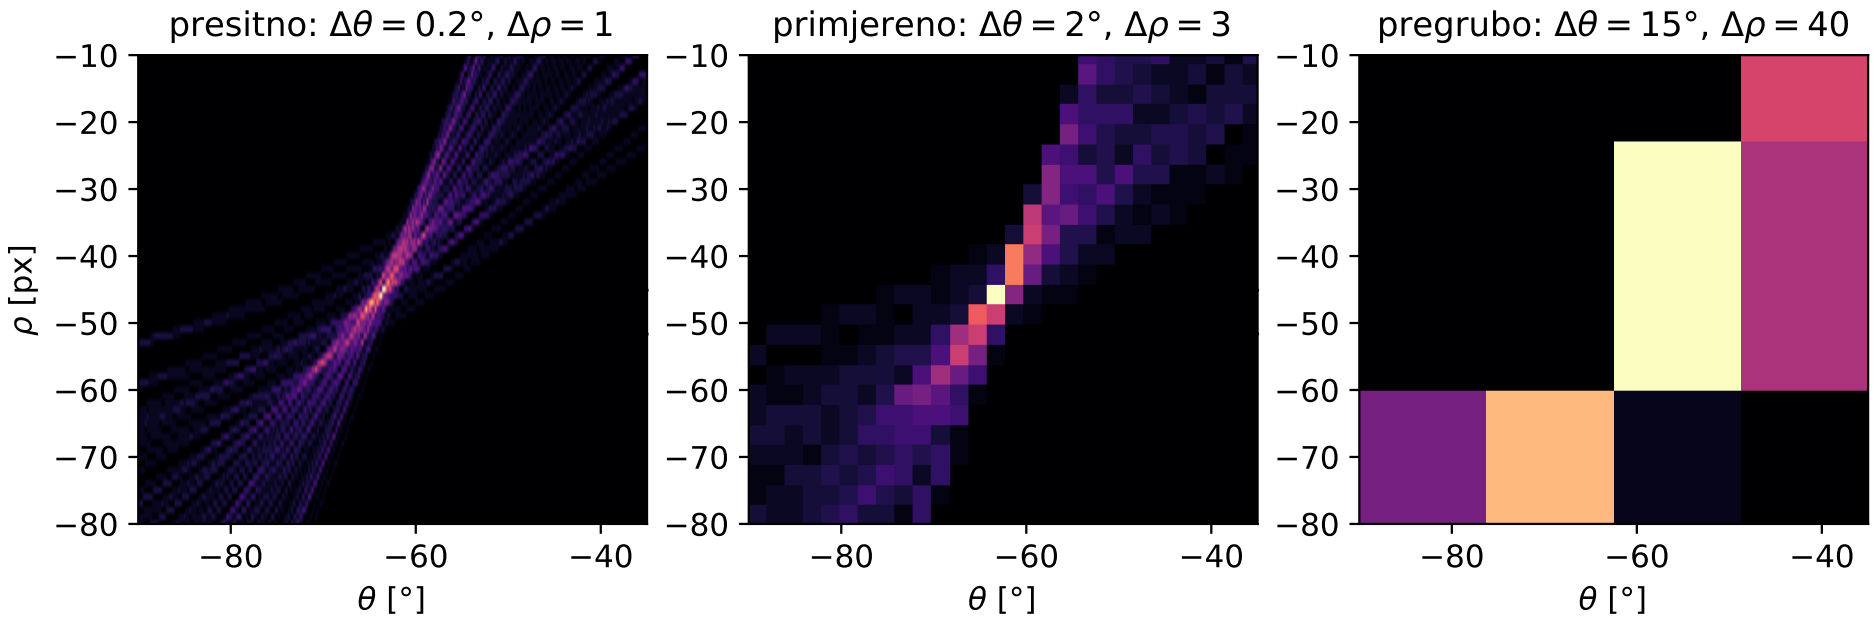




Houghova transformacija: Diskretizacija

Veličina ćelije akumulatora ključni je hiperparametar

- presitno: šum raspršuje glasove jednog pravca u više ćelija, vrh nestaje
- pregrubo: različiti pravci padaju u istu ćeliju, gubimo preciznost



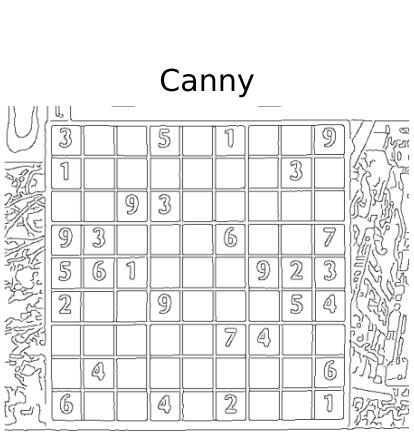
[šumoviti pravac, $\sigma = 2.5$ px]

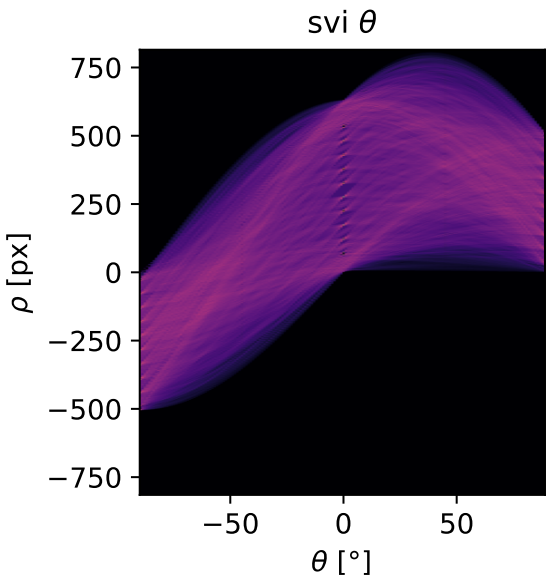
Uobičajeno: $\Delta\rho \approx 1$ px, $\Delta\theta \approx 1°$

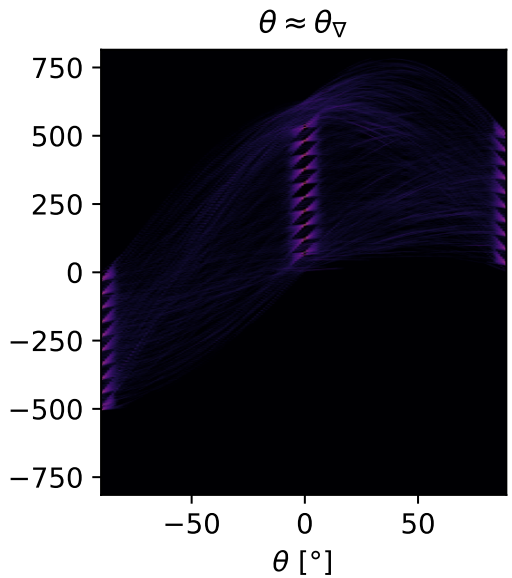
Houghova transformacija: smjer gradijenta

Osim lokacija, za rubove poznajemo i smjer gradijenta θ_∇.

- gradijent je okomit na rub, dakle paralelan s normalom pravca $\rightarrow \theta \approx \theta_\nabla$
- izgledno je da pravac kojeg tražimo prati rub, odnosno da je kut njegove normale približno jednak kutu gradijenta u točkama ruba
- to možemo iskoristiti tako da svaka točka ruba glasa samo u malom prozoru oko vrijednosti kuta gradijenta







Houghova transformacija: smjer gradijenta

Glasanje uz orijentaciju gradijenta:

- **brže** ažuriranje akumulatora zbog manje glasova po točki
- **manje lažnih vrhova**: točke glasaju samo za pravce s kojima su lokalno poravnate
- širina prozora ovisi o pouzdanosti procjene gradijenta

Dodatne inačice:

- otežani glasovi: $A \mathrel{+}= \|\nabla I\|$
- ograničen raspon θ kad znamo što tražimo (npr. vozne trake nikad nisu vodoravne)

Houghova transformacija: krivulje

Houghova transformacija nije ograničena samo na pravce: radi za svaku krivulju zadanu **jednadžbom s parametrima** $f(x, y; \mathbf{p}) = 0$

Isti recept:

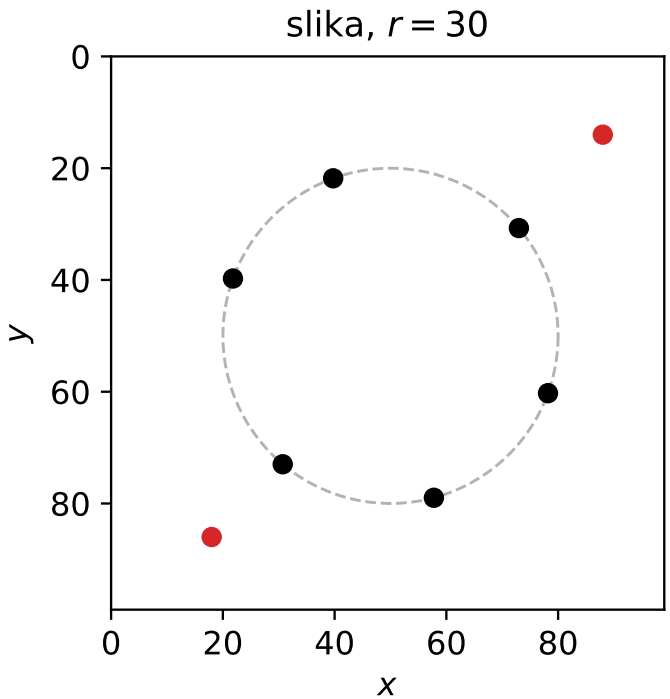
- svaka točka glasa za sve vrijednosti parametara $\mathbf{p}$ za koje krivulja prolazi kroz nju
- krivulje za koje glasa puno točaka su detekcije

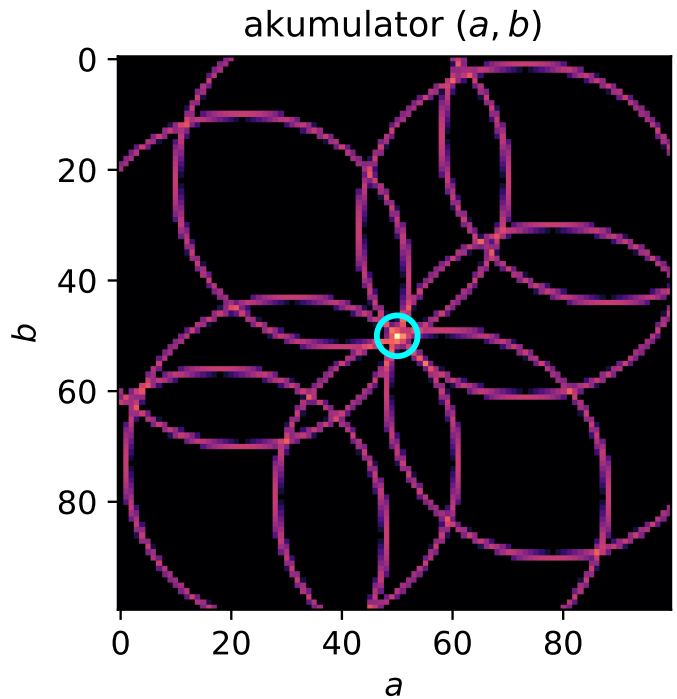
Funkcije s više paramatera značajno povećavaju kompleksnost i glasanje postaje znatno skuplje.

Houghova transformacija: Kružnice

Kružnica: $(x-a)^2 + (y-b)^2 = r^2$, tri parametra (a, b, r)

Ako je r poznat: točka (x_i, y_i) glasa za sva središta (a, b) na kružnici polumjera r oko sebe





Houghova transformacija: kružnice, nepoznat r

Ako r nije poznat akumulator je 3D, točka glasa po plaštu stošca. Smjer gradijenta može pojednostaviti ažuriranje akumulatora:

- Središte kružnice trebalo bi ležati na pravcu koji prolazi kroz razmatranu točku (x_i, y_i) i ima smjer jednak gradijentu ∇I.
- U 3D akumulatoru (a, b, r) točka tako glasa duž **dvije zrake**

$$(a, b) = (x_i, y_i) \pm r \frac{\nabla I}{\|\nabla I\|}, \qquad r \in [r_{\min}, r_{\max}]$$

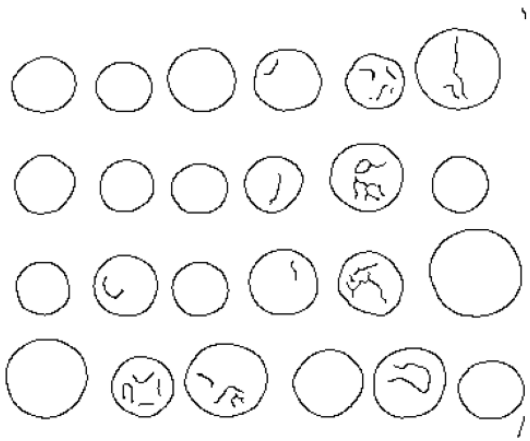
OpenCV `HoughCircles`:

- r se ne pamti: zrake projiciramo u ravninu (a, b), pa svaka točka glasa duž segmenta u 2D akumulatoru za središte
- za svako kandidatsko središte, r se određuje histogramom udaljenosti do svih točaka rubova

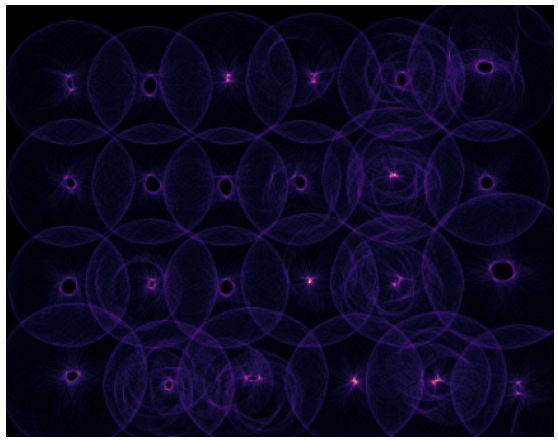
Houghova transformacija: primjer

Novčići: nepoznat polumjer $r \in [18, 35]$ px, 3D akumulator (a, b, r)

Canny



presjek akumulatora, $r = 24$



vrhovi u (a, b, r)



[skimage.data.coins]

- svaki presjek akumulatora pokazuje "kandidate" za jedan polumjer
- pravi novčići daju oštar vrh samo u presjeku točnog polumjera

Houghova transformacija: zaključak

Ključna ideja: glasanje

- svaka točka neovisno glasa za sve modele koji kroz nju prolaze
- modeli za koje glasa puno točaka su detekcije; grupiranje dobijemo besplatno
- robusno na šum, stršeće točke i prekide; prirodno pronalazi više instanci
- radi za svaku parametarsku krivulju, ali cijena brzo raste s brojem parametara

Postoje i napredne varijante Houghove transformacije koje detektiraju proizvoljne oblike [ballard81pr].

Pronalaženje kuteva

Značajka: istaknuti dio slike

- izgled i položaj **prepoznatljivi** iz različitih dijelova scene (kut, blob, ...)
- zbog efikasnije implementacije, najčešći kvadratni oblik (koriste se i pravokutnici, paralelogrami, krugovi, ...)

veličina značajke: kompromis između **otpornosti na zaklanjanje** i neprepoznatljivosti

svojstveno mjerilo i rotacija: noviji koncept, problemi u stvarnom vremenu (GPGPU!)

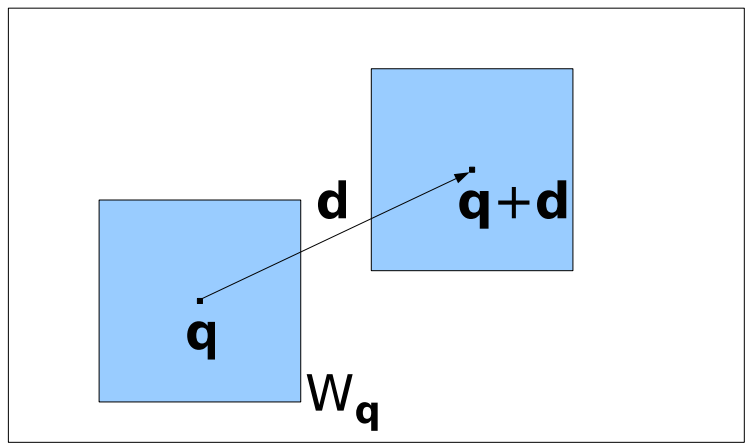
Pronalaženje kuteva

Harrisovi kutevi: unatoč poodmakloj dobi (1988), jedan od najefikasnijih pristupa s fiksnim mjerilom

Ideja: pronaći točke $\mathbf{q}_{zn}$ koje maksimiraju lokalnu prepoznatljivost susjedstva zadane veličine

Promotrimo ``autokorelacijsku funkciju'' (zapravo **SSD**):

$$E_{\mathbf{q}}(\mathbf{d}) = \sum_{x,y \in W(\mathbf{q})} [\mathrm{I}(x + d_x, y + d_y) - \mathrm{I}(x, y)]^2$$



$E_{\mathbf{q}}(\mathbf{d})$: različitost susjedstva točke $\mathbf{q}$, u ovisnosti o pomaku $\mathbf{d}$

Pronalaženje kuteva

Ideja: značajke su u točkama gdje $E_{\mathbf{q}}$ raste u svim smjerovima!

Tražimo kriterij koji će otkriti točke $\mathbf{q}(x_{zn}, y_{zn})$ gdje to vrijedi.

Rezultat: U svakoj točki slike računa se matrica **G**

- **G** sadrži lokalne iznose momenata drugog reda gradijenta slike

$$\mathbf{G}(\mathbf{q}) = \begin{bmatrix} \sum_W \mathrm{I}_x^2 & \sum_W \mathrm{I}_x \mathrm{I}_y \\ \sum_W \mathrm{I}_x \mathrm{I}_y & \sum_W \mathrm{I}_y^2 \end{bmatrix} = \begin{bmatrix} a & c \\ c & b \end{bmatrix} \tag{1}$$

Harrisov odziv r sada je: $r(\mathbf{q}) = ab - c^2 - k(a+b)^2$

Konačno, značajke su u lokalnim maksimumima odziva:

$\mathbf{q}_{zn} = max_{\mathbf{q}} r(\mathbf{q})$

Pronalaženje kuteva

Izvod Harrisove formule

Zapišimo E u vektorskom obliku:

$$E_{\mathbf{q}}(\mathbf{d}) = \sum_{x,y \in W(\mathbf{q})} [\mathrm{I}(x + d_x, y + d_y) - \mathrm{I}(x, y)]^2$$
$$= \sum_{\mathbf{q}_i \in W(\mathbf{q})} [\mathrm{I}(\mathbf{q}_i + \mathbf{d}) - \mathrm{I}(\mathbf{q}_i)]^2$$

Pronalaženje kuteva

Izvod Harrisove formule (2)

Neka je u svakoj točki $\mathbf{q}_i \in W_\mathbf{q}$ poznat gradijent:

$\mathbf{g}_i = \nabla \mathrm{I}(\mathbf{q}_i)^\top = [\mathrm{I}_x(\mathbf{q}_i), \mathrm{I}_y(\mathbf{q}_i)]^\top$

Razvijmo $\mathrm{I}(\mathbf{q}_i + \mathbf{d})$ po Tayloru oko $\mathbf{q}_i$:

$$
\begin{aligned}
E_\mathbf{q}(\mathbf{d}) &= \sum_{\mathbf{q}_i \in W_\mathbf{q}} [\mathrm{I}(\mathbf{q}_i + \mathbf{d}) - \mathrm{I}(\mathbf{q}_i)]^2 \\
&\approx \sum_{\mathbf{q}_i \in W_\mathbf{q}} [\mathrm{I}(\mathbf{q}_i) + \mathbf{g}_i^\top \mathbf{d} - \mathrm{I}(\mathbf{q}_i)]^2 = \sum_{\mathbf{q}_i \in W_\mathbf{q}} (\mathbf{g}_i^\top \mathbf{d})^2 \\
&= \sum_{\mathbf{q}_i \in W_\mathbf{q}} \mathbf{d}^\top (\mathbf{g}_i \mathbf{g}_i^\top) \mathbf{d} = \mathbf{d}^\top \Big(\sum_{\mathbf{q}_i \in W_\mathbf{q}} \mathbf{g}_i \mathbf{g}_i^\top \Big) \mathbf{d} = \mathbf{d}^\top \mathbf{G}\, \mathbf{d}
\end{aligned}
$$

G zbraja vanjske produkte gradijenata **svih točaka prozora**:

$\mathbf{G} = \sum_{\mathbf{q}_i \in W_\mathbf{q}} \mathbf{g}_i \mathbf{g}_i^\top$

Pronalaženje kuteva

Izvod Harrisove formule (3)

Matrica **G** je realna i simetrična pa se može dijagonalizirati **rotacijom**:

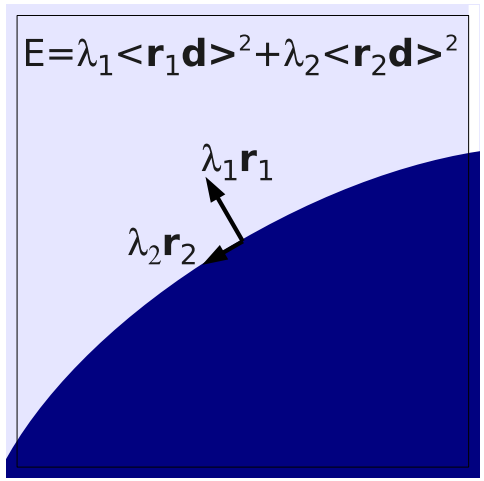
$$\mathbf{G} = \sum_{\mathbf{q}_i \in W_{\mathbf{q}}} \mathbf{g}_i \mathbf{g}_i^\top = \begin{bmatrix} \sum \mathrm{I}_x^2 & \sum \mathrm{I}_x \mathrm{I}_y \\ \sum \mathrm{I}_x \mathrm{I}_y & \sum \mathrm{I}_y^2 \end{bmatrix} = \mathbf{R}^\top \mathbf{D} \mathbf{R}$$

$\mathbf{R} = [\mathbf{r}_1, \mathbf{r}_2]^\top$: svojstveni vektori ($\mathbf{R}\mathbf{R}^\top = \mathbf{I}$), $\mathbf{D} = \mathrm{diag}(\lambda_1, \lambda_2)$: svojstvene vrijednosti

Sada kriterijsku funkciju možemo izraziti u koordinatama koje su poravnate s lokalnom strukturom slike:

$$E_{\mathbf{q}}(\mathbf{d}) = \mathbf{d}^\top \mathbf{R}^\top \mathbf{D} \mathbf{R}\, \mathbf{d} = (\mathbf{R}\mathbf{d})^\top \mathbf{D}\, (\mathbf{R}\mathbf{d}) = \mathbf{d}_{\mathrm{R}}^\top \mathbf{D}\, \mathbf{d}_{\mathrm{R}},$$

$$\mathbf{d}_{\mathrm{R}} = \mathbf{R}\mathbf{d} = [\mathbf{r}_1^\top \mathbf{d},\ \mathbf{r}_2^\top \mathbf{d}]^\top$$

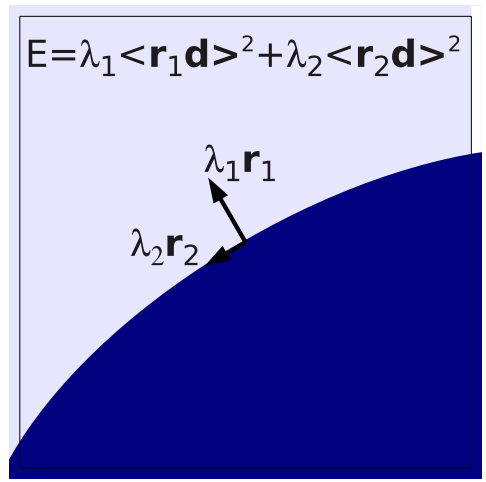


Pronalaženje kuteva

Izvod Harrisove formule (4)

U novim koordinatama, doprinosi komponenti pomaka **nezavisno** utječu na kriterijsku funkciju E!

$$
\begin{aligned}
E_{\mathbf{q}}(\mathbf{d}) &= \mathbf{d}^{\top} \cdot \mathbf{G} \cdot \mathbf{d} = \mathbf{d_R}^{\top} \cdot \mathbf{D} \cdot \mathbf{d_R} \\
&= \mathbf{d_R}^{\top} \cdot \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \cdot \mathbf{d_R} \\
&= \lambda_1 d_{R1}^2 + \lambda_2 d_{R2}^2 \\
&= \lambda_1 (\mathbf{r}_1^{\top} \mathbf{d})^2 + \lambda_2 (\mathbf{r}_2^{\top} \mathbf{d})^2
\end{aligned}
$$



Slika se lokalno brzo mijenja u svim smjerovima $\Leftrightarrow \lambda_1, \lambda_2$ veliki!

Pronalaženje kuteva

Harrisov odziv ``nagrađuje'' točke u kojima su veliki i λ_1 i λ_2:

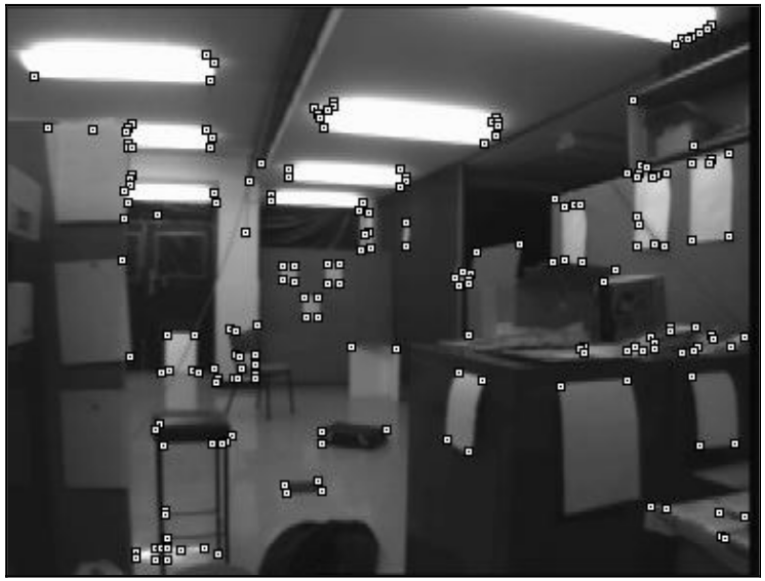
$$\mathbf{G} = \begin{bmatrix} \sum_W I_x^2 & \sum_W I_x I_y \\ \sum_W I_x I_y & \sum_W I_y^2 \end{bmatrix} = \begin{bmatrix} a & c \\ c & b \end{bmatrix}$$

$$\begin{aligned} r &= ab - c^2 - k \cdot (a+b)^2 \qquad k \in [0.04, 0.07] \\ &= \det(\mathbf{G}) - k \cdot (tr^2(\mathbf{G})) \\ &= \lambda_1 \lambda_2 - k \cdot (\lambda_1 + \lambda_2)^2 \end{aligned}$$

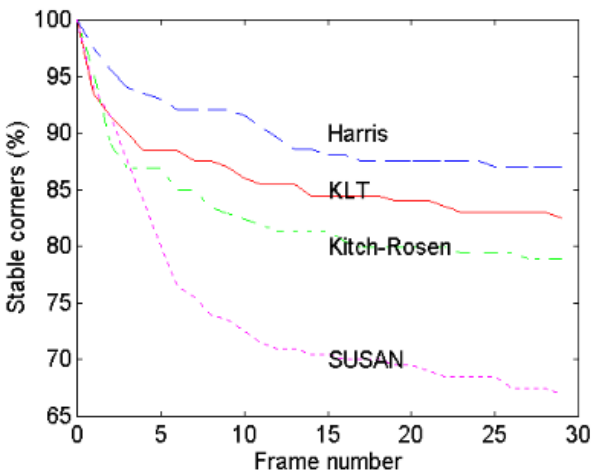
Konačni rezultat su lokalni maksimumi odziva

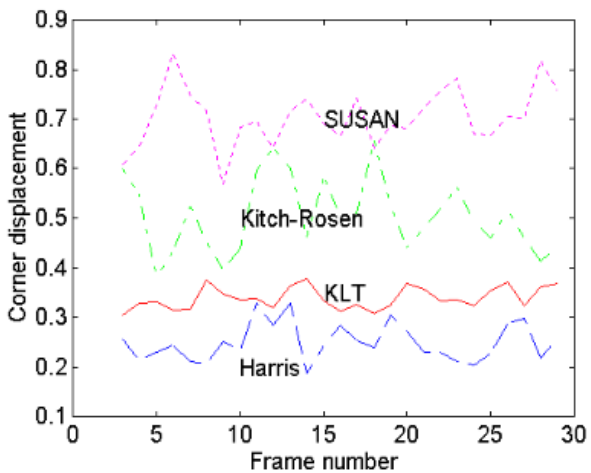
Potiskivanje ne-maksimalnih odziva dovodi do dobre lokalizacije značajki

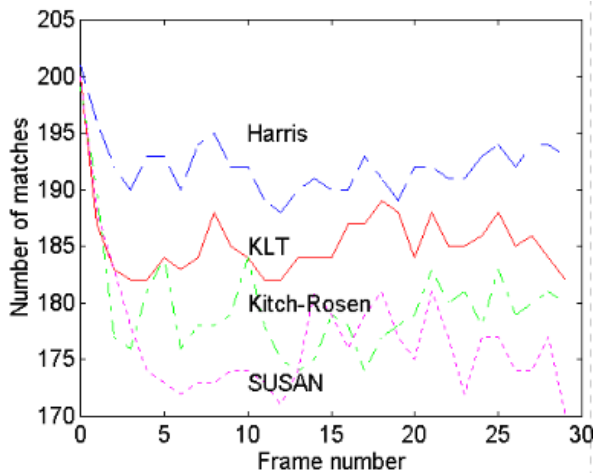
Pronalaženje kuteva



Broj značajki (a), lokalizacija (b), te uspješnost uparivanja (c):





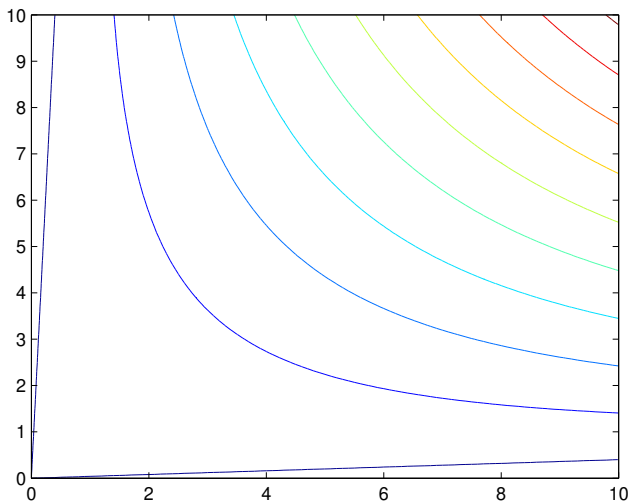


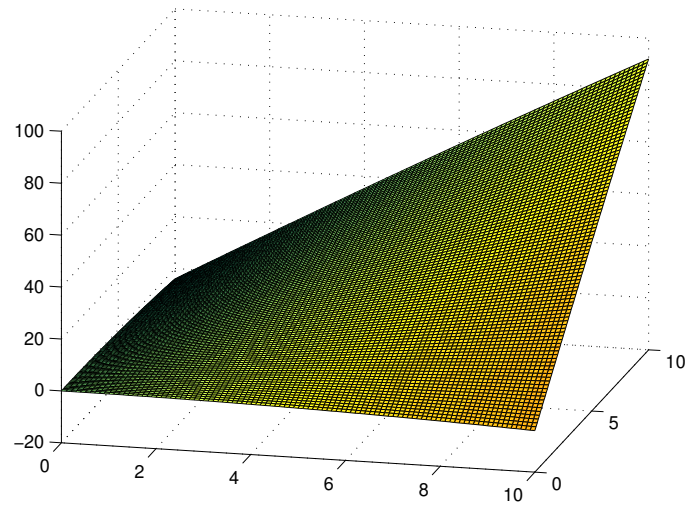
[tissainayagam04imavis]

Pronalaženje kuteva

Oblik funkcije odziva:

$$r = \lambda_1\lambda_2 - k \cdot (\lambda_1 + \lambda_2)^2$$

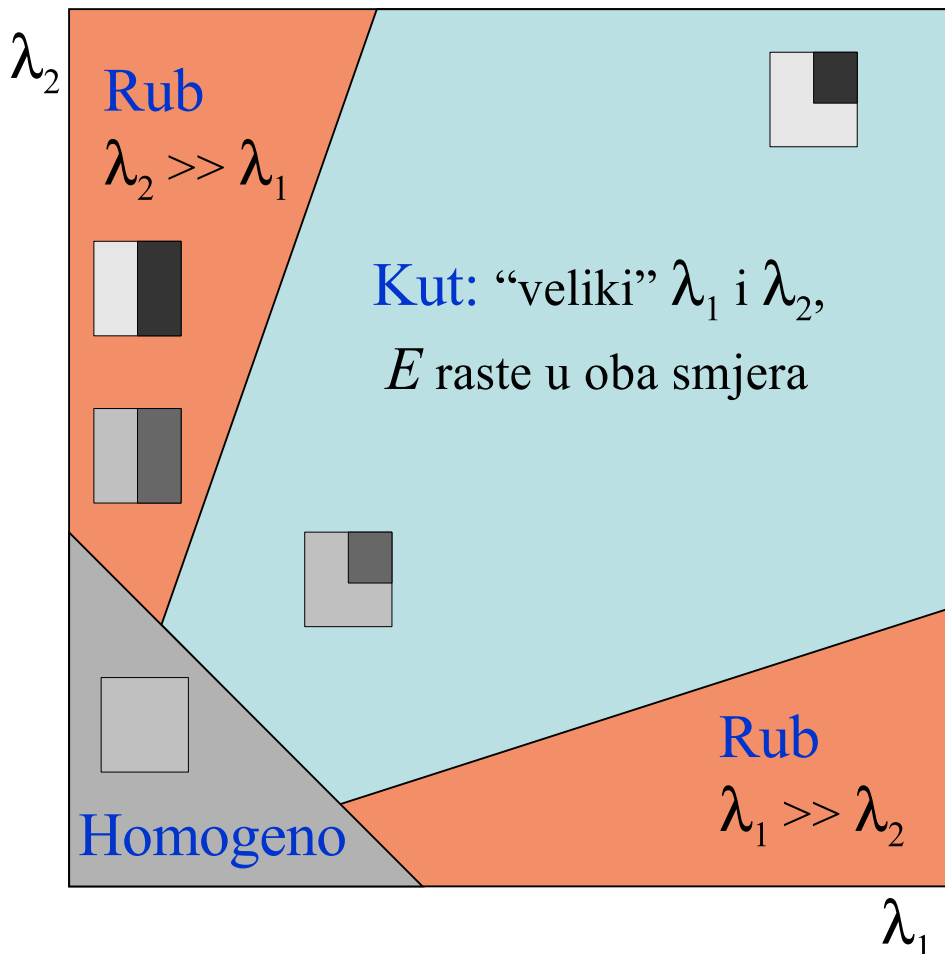




Pronalaženje kuteva

Oblik funkcije odziva (2):

$$r = \lambda_1\lambda_2 - k \cdot (\lambda_1 + \lambda_2)^2$$



Pronalaženje kuteva

Detalji:

- težinska funkcija? $\mathbf{G} = \sum_W w(x,y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$
- derivacijsko i integracijsko mjerilo?

Svojstva:

- odziv (pa onda i maksimum) invarijantan na rotaciju slike!
- dobra ponovljivost i lokalizacija rezultata
  (barem za jednostavne značajke)
- problem: odziv nije invarijantan na mjerilo!

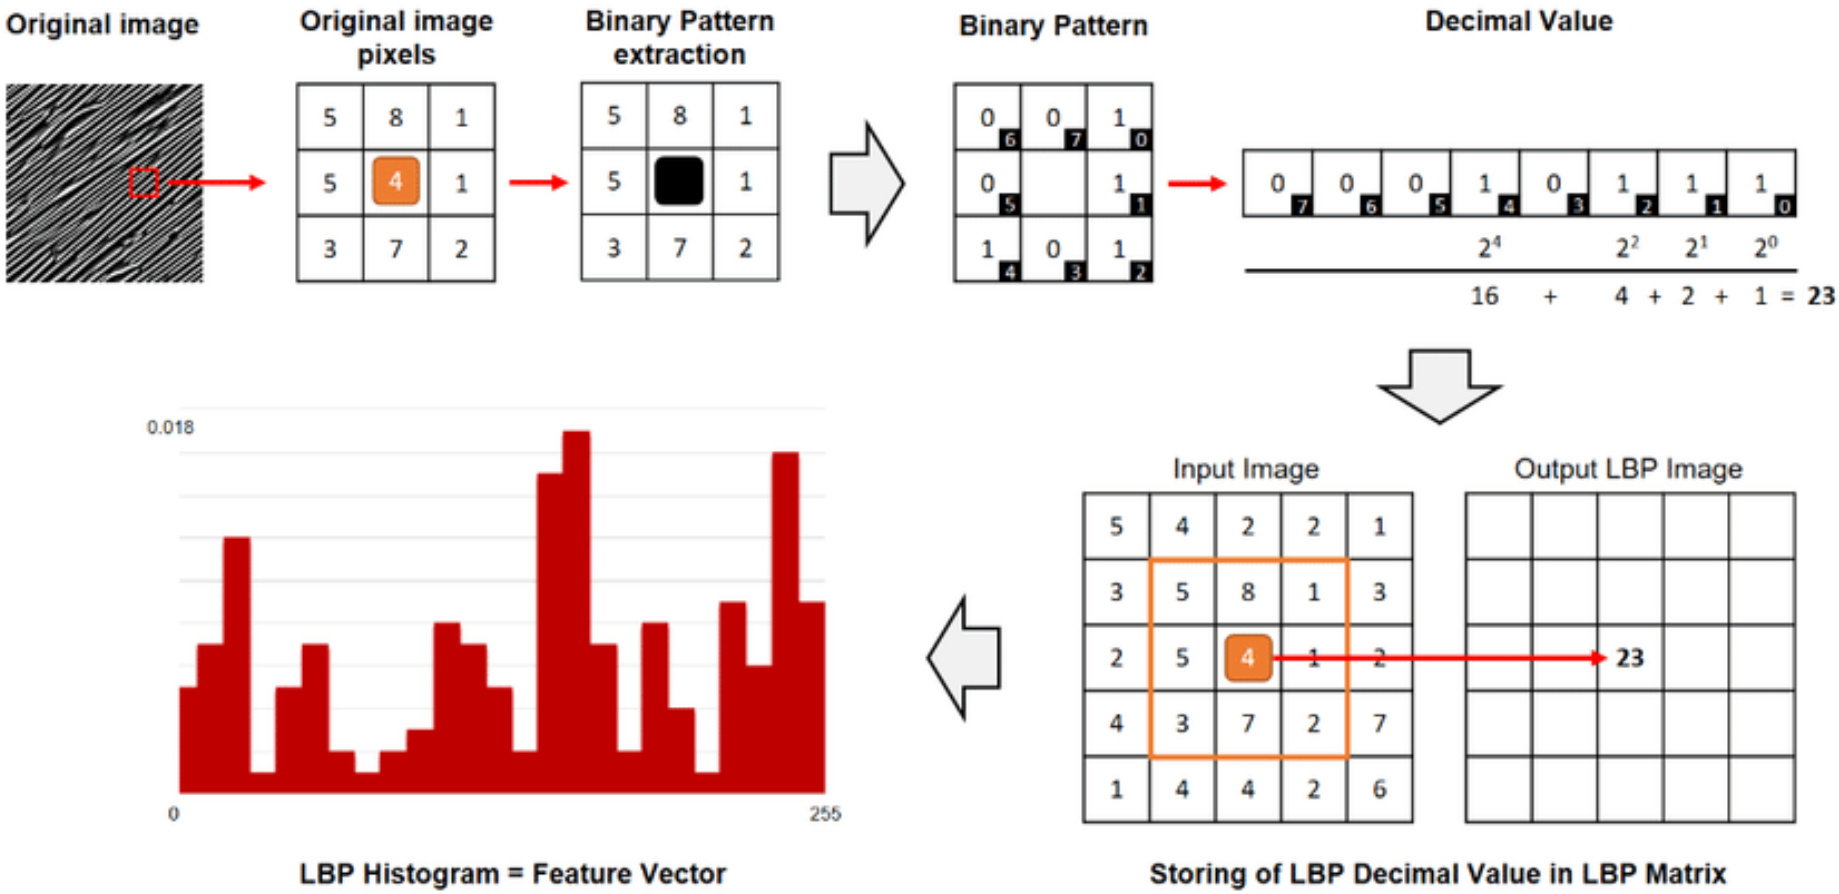
Alternative:

- FAST (brži); DoG, MSER, SURF (invarijantni na mjerilo, sporiji)

Lokalni binarni uzroci

- **LBP** (engl. local binary patterns)
- jednostavan operator za opis teksture
- neosjetljiv na promjene u osvjetljenju
- slična ideja: **Census** transformacija
- primjene
  - opis tekstura
  - podudaranje značajki
  - prisustvo rubova i kuteva

Lokalni binarni uzroci



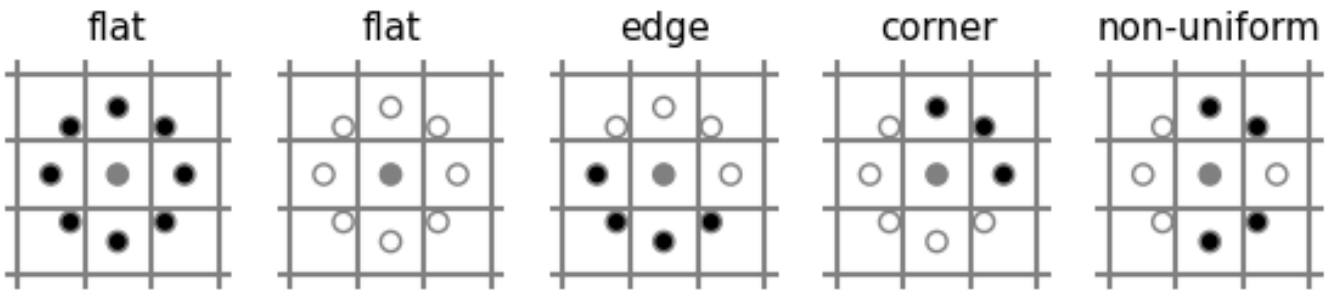
Lokalni binarni uzroci

Postupak: za svaki piksel u izvornoj (sivoj) slici:

- usporedi vrijednost piksela sa svim pikselima u nekom njegovom susjedstvu (tipično 3×3)
- ako je središnji piksel manji od piksela okoline, to označavamo s 0
- ako je središnji piksel veći od piksela okoline, to označavamo s 1
- rezultat: bitovni niz koji očitavamo nekim predefiniranim redoslijedom i pretvaramo u dekadski broj
- (kod analize tekstura slika se dijeli na ćelije i za svaku ćeliju konstruira se LBP histogram - opis lokalne teksture)

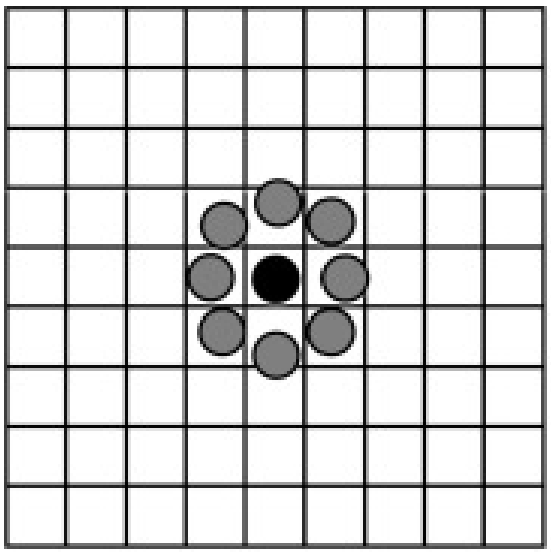
Lokalni binarni uzroci

- LBP enkodira prisustvo tipičnih značajki (rubova, kuteva, ...) u promatranom lokalnom području

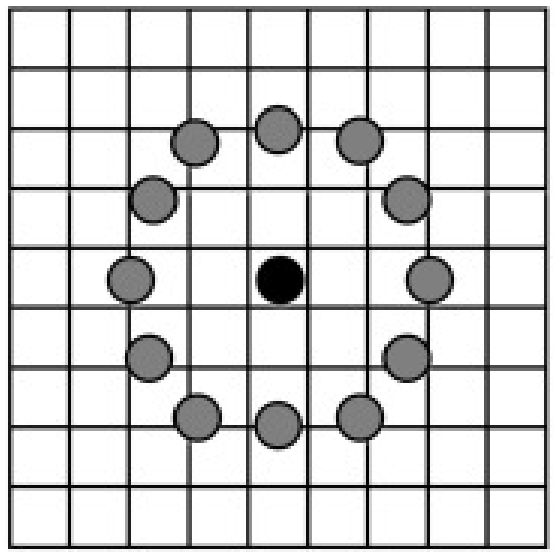


Lokalni binarni uzroci

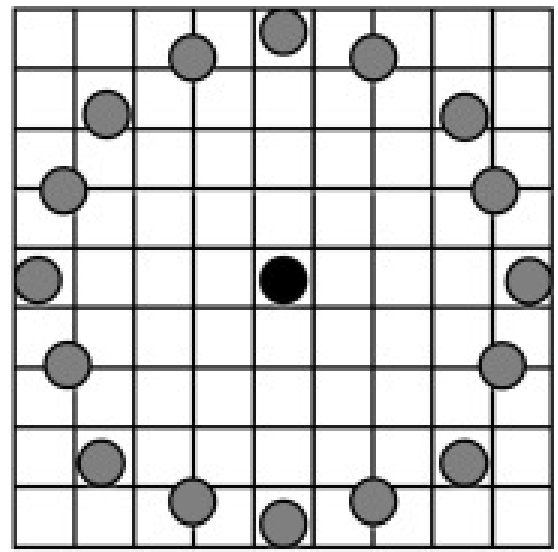
- Moguće su i drukčije veličine okoline



P=8, R=1



P=12, R=2



P=16, R=4

ZAHVALA

Ova predavanja proizišla su iz istraživanja koje je financirala Hrvatska zaklada za znanost projektom ADEPT.

http://adept.zemris.fer.hr