

Detekcija objekata

Algoritam Viole i Jonesa

Izv. prof. dr. sc. Zoran Kalafatić
Zoran.Kalafatic@fer.hr

ZEMRIS, 2025/26

Sadržaj predavanja

- Problem detekcije objekata
- Detekcija u pomičnom oknu
- Strojno naučeni klasifikator
- Algoritam Viole i Jonesa
- Mjere uspješnosti

Uvod

- u ulaznoj slici provjeriti prisutnost objekata nekog unaprijed određenog razreda (lica, osobe, prometni znakovi, ...)
- detektor bi trebao odrediti lokacije u slici za sve pronađene objekte




- detekcija objekata je preduvjet za razne zadatke računalnog vida
 - ▶ praćenje objekata na temelju detekcija u pojedinim slikama videa (*tracking-by-detection*)
 - ▶ inicijalizacija praćenja i povremena provjera napretka procesa praćenja
 - ▶ važan korak u raspoznavanju objekata u slikama

Heuristički pristupi

- u nekim slučajevima moguće je oblikovati vrlo jednostavan algoritam detekcije objekata korištenjem neki istaknutih značajki
- primjer – detekcija crvene lopte (ili prometnih znakova prema crvenom rubu)
 - ▶ korištenjem boje klasificira se svaki piksel (pripada objektu ili ne)
 - ▶ pronalaženje povezanih piksela, odbacivanje malenih područja
 - ▶ naknadna obrada pronađenih područja u slici koja potencijalno pripadaju traženom objektu (provjera oblika, veličine, izgleda)
- ovakvi jednostavni pristupi su previše specifični
- htjeli bismo općenitiji pristup koji bi mogao naučiti izgled traženih objekata na temelju primjera

Detekcija u pomičnom oknu


- tipičan pristup detekciji objekata



- detekcijsko okno se postavlja na svaku lokaciju u slici, izrezani komad slike proslijeđuje se binarnom klasifikatoru koji odlučuje je li to traženi objekt ili nije
- budući da objekti mogu biti na različitim udaljenostima od kamere, proces se ponavlja za različite veličine detekcijskog okna
- veliko računsko opterećenje – potrebno je obraditi ogroman broj detekcijskih okana (npr. za sliku 640×480 @ 10 veličina okna $\rightarrow 3 \cdot 10^6$ isječaka slike)

Strojno naučeni detektor objekata

- detektor objekata – binarni klasifikator
 - ▶ na ulazu dobiva isječak slike, izlučuje nekakav skup značajki (sirovi pikseli, vrijednosti dobivene nakon primjene nekog filtra, neka složenija vrsta opisnika – SIFT?)
 - ▶ računa nekakvu funkciju na temelju vrijednosti značajki
 - ▶ uspoređuje dobivenu vrijednost s neakvim pragom → donosi odluku (objekt ili ne)



- kako odabrati značajke?
- kako odabrati prikladnu klasifikacijsku (decizijsku) funkciju?

Učenje klasifikatora

- primjeri za učenje – pozitivni i negativni
- tijekom faze učenja, klasifikator pokušava pronaći decizijsku funkciju
 - ▶ nastoji pronaći parametre odabrane funkcije odlučivanja koja će razlikovati pozitivne od negativnih primjera u skupu za učenje
 - ▶ nadamo da će klasifikacijska funkcija dobro generalizirati, tj. dobro klasificirati i primjere koje nije vidjela pri učenju
- obično je potreba velik broj primjera za učenje (tisuće)
- proces učenja može dugo trajati – no to nije bitno, važna je konačna brzina detektora u primjeni

Algoritam Viole i Jonesa

Algoritam Viole i Jonesa


- podsjetimo se: detekcija kliznim oknom zahtijeva ispitivanje ogromnog broja isječka slike
- da bi se postigla razumna brzina obrade cijele slike, evaluacija pojedinog isječka mora biti ekstremno brza
- Viola i Jones su 2001. uspjeli konstruirati algoritam za detekciju objekata koji je na tipičnom tadašnjem računalu bio sposoban obraditi sliku u stvarnom vremenu

Algoritam Viole i Jonesa

ključne ideje:


- jednostavne pravokutne značajke – Haar-like features
- korištenje integralne slike za brzo računanje suma piksela u pravokutnim područjima, neovisno o veličini područja
- metoda za izgradnju klasifikatora kao skupa ekstremno jednostavnih *slabih* klasifikatora – boosting (ojačavanje?)
- detektor kao kaskada klasifikatora – prvi klasifikatori izrazito jednostavni, brzo odbacuju isječke koji sigurno nisu traženi objekt, područja koja nalikuju na traženi objekt prolaze dublje kroz kaskadu → vrlo mali broj kandidata se detaljno razmatra

Kaskada klasifikatora



- kaskada klasifikatora organizirana je tako da prvi stupnjevi sadrže iznimno jednostavne klasifikatore, dok se složenost povećava sa svakim sljedećim stupnjem
- prvi klasifikatori kaskade izvode vrlo jednostavne testove i većina primjera prolazi u sljedeći stupanj
- primjeri koji očito ne predstavljaju objekt koji se želi detektirati odbacuju se vrlo rano u kaskadi i ne troše vrijeme
- samo dijelovi slike slični objektu (prema korištim kriterijima) prolaze dublje kroz kaskadu

Kaskada klasifikatora



- kako isječak slike napreduje kroz kaskadu, podvrgava se sve složenijim testovima, odnosno sve zahtjevnijim klasifikatorima
- samo isječci koji prođu kroz cijelu kaskadu prihvaćaju se kao detekcije objekta
- slike obično sadrže samo mali broj objekata — velika većina isječaka slike ne izgleda kao objekt koji pokušavamo detektirati → odgovarajući dijelovi slike lako se odbacuju jednostavnim testovima na početku kaskade
- u prosjeku, računaska zahtjevnost obrade pojedinog slikovnog isječka vrlo je niska

Treniranje kaskade klasifikatora

- svaki stupanj kaskade je binarni klasifikator
- svaki stupanj koristi primjere za učenje kako bi pronašao odgovarajuću funkciju odlučivanja koja razdvaja pozitivne od negativnih primjera
- ova kaskadna arhitektura specifična je po tome što svaki stupanj mora propuštati što je moguće više pozitivnih primjera, dok istovremeno odbacuje barem neke negativne
- negativni koji prođu kroz stupanj zapravo su lažni pozitivni (*false positives*) tog klasifikatora
- u algoritmu za treniranje kaskade zadaju se parametri koji definiraju zahtijevanu stopu detekcije svakog pojedinog stupnja (d_i) – minimalni postotak pozitivnih primjera koji prolaze klasifikator, i dopuštenu stopu lažnih detekcija (f_i) – maksimalni postotak propuštenih negativnih primjera

Treniranje kaskade klasifikatora

- ukupna stopa detekcije (D) i stopa lažnih pozitiva (F) cijele kaskade:

$$D = \prod_{i=1}^K d_i \quad F = \prod_{i=1}^K f_i$$


- ako su za sve stupnjeve zadani $d_i = 0.995$ i $f_i = 0.5$, kaskada s 20 stupnjeva postiže:

$$D = 0.995^{20} = 0.905 \quad F = 0.5^{20} = 9.54 \cdot 10^{-7}$$

- ispituje se ogroman broj isječaka slike (milijuni), pa FPR mora biti izuzetno mali!
- kaskada se trenira stupanj po stupanj
- pojedini stupanj se trenira primjerima (pozitivnim i negativnim) koji prolaze prethodne stupnjeve kaskade
 - ▶ s obzirom na to da svaki stupanj odbacuje značajan broj negativa, sa svakim dodanim stupnjem kaskade sve je teže prikupiti prikladne negativne primjere! → potreban je bogat “izvor” negativa

Pravokutne (Haar-like) značajke

- Viola i Jones su predložili korištenje značajki koje se temelje na računanju suma vrijednosti piksela u pravokutnim područjima slike i međusobnom oduzimanju tih suma



- u detekcijskom oknu može se smjestiti velik broj ovakvih značajki različitih veličina i položaja
- primjerice, u detekcijskom oknu veličine 24×24 piksela može se postaviti, odnosno generirati više od 160.000 takvih značajki (one nisu nezavisne, više ih je nego je potrebno, ali nije važno)
- postupak učenja treba odrediti najdiskriminativnije značajke iz tog golemog skupa

Integralna slika

- drugi trik koji je omogućio ekstremno brzo računanje ovih pravokutnih značajki je korištenje integralne slike
- pravokutne (Haar-like) značajke mogu se računati u konstantnom vremenu, neovisno o veličini detekcijskog okna i veličinama pojedinih pravokutnika
- svaki element integralne slike odgovara sumi vrijednosti piksela (u originalnoj slici), iznad i lijevo od položaja tog elementa


$$I(x, y) = \sum_{x' \leq x, y' \leq y} i(x', y')$$

- integralna slika može se izračunati jednim prolazom kroz sliku

$$I(x, y) = I(x, y-1) + I(x-1, y) - I(x-1, y-1) + i(x, y)$$

Integralna slika

- Korištenjem integralne slike, suma vrijednosti piksela bilo kojeg pravokutnog područja može se odrediti u konstantnom vremenu



$$\text{Suma}_{ABCD} = I(C) + I(A) - I(B) - I(D)$$

Izgradnja stupnjeva kaskade ojačavanjem

- cilj je trenirati kaskadu s postupno sve složenijim klasifikatorima
- klasifikator pojedinog stupnja gradi se kao kombinacija ekstremno jednostavnih *slabih* klasifikatora korištenjem “ojačavanja”
 - ▶ *slabi klasifikator* je klasifikator koji radi tek nešto bolje od slučajnog klasifikatora (bacanje novčića)
 - ▶ ojačavanje (*boosting*) je tehnika treniranja ansambla slabih klasifikatora koji onda zajedno djeluju kao *jaki* klasifikator
 - ▶ V&J su koristili popularni algoritam ojačavanja AdaBoost ("Adaptive Boosting", Freund i Schapire, 1998)
- slabe klasifikatore su oblikovali kao pojedinačne pravokutne (Haar-like) značajke, uspoređene s pragom, pri čemu se polaritetom može okrenuti znak nejednakosti

$$h_j(x) = \begin{cases} 1 & \text{ako } p_j f_j(x) < p_j \theta_j \\ 0 & \text{inače} \end{cases}$$

Boosting


- klasifikator jednog stupnja kaskade se postupno dograđuje, najprije pronalaženjem najdiskriminativnijeg slabog klasifikatora – pravokutne značajke, polariteta i praga s kojima se postiže najmanja klasifikacijska pogreška (x_j je primjer za učenje, y_j je točna oznaka razreda, w_j je težina pridružena primjeru):

$$\epsilon_k = \sum_{j=1}^n w_j |h_k(x_j) - y_j|$$

- inicijalno svi primjeri za učenje imaju jednake težine
 - prije sljedeće runde ojačavanja (dodavanja sljedećeg slabog klasifikatora) težine se podešavaju tako da se pogrešno klasificiranim primjerima težine povećaju
 - na taj način se tjera klasifikator da se više fokusira na teške primjere
- konačni jaki klasifikator je linearna kombinacija slabih klasifikatora s težinama koje se određuju na temelju točnosti svakog od njih


Primjer

- koristili smo algoritam Viole i Jonesa za detekciju trokutastih prometnih znakova



Višestruki odzivi detektora

- detektor obično generira veći broj odziva (detekcija) u okolini stvarne lokacije objekta (položaj, veličina)




- odzivi se grupiraju (na temelju preklapanja detekcijskih pravokutnika) i onda se pojedina grupa zamjenjuje prosječnim pravokutnikom
- broj odziva u grupi može se koristiti za filtriranje lažnih pozitiva (obično generiraju mali broj odziva jes samo malo slične na traženi objekt)

Histogrami orijentacija gradijenata kao značajke za detekciju objekata


Detekcija objekata korištenjem HOG deskriptora

- Dalal i Triggs (2005) predložili su prikaz objekata koji se traže korištenjem histograma orijentacija gradijenata (HOG deskriptor)
- orijentacije gradijenata vezane su za naglašene konture na objektu
- vrlo pogodne za detekciju osoba (pješaka), ali mogu se koristiti i za druge vrste objekata



HOG deskriptor

- izračunaju se gradijenti u slici (veličina i orijentacija), npr. korištenjem Sobelovog operatora
- detekcijsko okno (odnosno isječak slike) dijeli se u ćelije, za svaku ćeliju se određuje histogram gradijenata po orijentacijama – tipično 0 – 180° u 9 pretinaca
- histogrami svih ćelija se konkatenuiraju u vektor značajki



Treniranje klasifikatora

- slike s objektima (i bez njih) reprezentiraju se HOG deskriptorima kao vektorima značajki
- može se primijeniti bilo koji algoritam strojnog učenja za treniranje binarnog klasifikatora
- Dalal i Triggs su koristili stroj s potpornim vektorima (SVM), linearna varijanta im je dala dobre rezultate

Ubrzanje rada

- HOG detektor se primjenjuje u kliznom oknu
- o izvornom obliku detektor je značajno računski zahtjevniji (→ sporiji) od algoritma Viole i Jonesa
- mogu se iskoristiti neki trikovi po uzoru na V&J
- npr. HOG deskriptor može se efikasno računati primjenom integralnih histograma (Porikli, 2005)
- detektor temeljen na HOG deskriptoru može se također primjenjivati u kaskadnoj arhitekturi (Zhu, 2006)

Mjerenje uspješnosti

Mjere uspješnosti

- notacija:

TP – true positives (uspješne detekcije)

FP – false positives (lažne detekcije – dijelovi pozadine koje je detektor prijavio kao objekte)

TN – true negatives (ispravno klasificirani dijelovi pozadine)

FN – false negatives (propuštene detekcije)

- R – odziv (*recall, hit rate, sensitivity, true positive rate*)

$$R = \frac{TP}{TP + FN}$$

- P – preciznost (*precision*)


$$P = \frac{TP}{TP + FP}$$

Mjere uspješnosti

Predicted class			
		P	N
Actual Class	P Sensitivity Recall	True Positives (TP)	False Negatives (FN)
	N Specificity	False Positives (FP)	True Negatives (TN)
		Precision	


Mjere uspješnosti

- Kako odrediti TP, FP, TN, FN?
- Potreban je skup podataka s referentnim oznakama (*gtound truth*, GT) – za svaku sliku oznake položaja objekata (opisani pravokutnik, *bounding box*)
- Ne očekuje se idealno poravnanje – obično se određuje relativno preklapanje između detekcijskog okvira koji daje detektor i referentne oznake (IoU, *intersection-over-union*, omjer presjeka i unije), koje se zatim uspoređuje s pragom (tipično 50%)



Balansiranje preciznosti i odziva

- Precision-recall curve



Literatura

-  P. Viola and M. Jones, “Robust real-time object detection,” in *International Journal of Computer Vision*, vol. 57, 2004, pp. 137–154.
-  —, “Rapid object detection using a boosted cascade of simple features,” in *CVPR*, 2001, pp. I–I.
-  N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in *CVPR*, 2005, pp. 886–893.
-  F. Porikli, “Integral histogram: A fast way to extract histograms in cartesian spaces,” in *CVPR*, 2005, pp. 829–836.
-  Q. Zhu, Q. Zhu, S. Avidan, S. Avidan, M. chen Yeh, M. chen Yeh, K. ting Cheng, and K. ting Cheng, “Fast human detection using a cascade of histograms of oriented gradients,” in *CVPR*, 2006, pp. 1491–1498.