

Računalni vid

Stereoskopska rekonstrukcija rektificiranih slika algoritmom Semiglobal Matching

Marin Oršić

Fakultet elektrotehnike i računarstva
Sveučilište u Zagrebu



UNIVERSITY OF ZAGREB

Faculty of Electrical
Engineering and
Computing

Rektificirani stereo

Izračun volumena cijene

Semiglobal Matching_[hirschmuller08tpami]

Stereo rekonstrukcija omogućava određivanje udaljenosti piksela od kamere.

Razumijevanje trodimenzionalne strukture scene omogućava niz primjena:

- ▶ 3D rekonstrukcija (AR/VR, digitalizacija objekata),
- ▶ navigacija u robotici,
- ▶ kartiranje,
- ▶ mnoge druge.





Figure 12.2 Applications of stereo vision: (a) input image, (b) computed depth map, and (c) new view generation from multi-view stereo (Matthies, Kanade, and Szeliski 1989) © 1989 Springer; (d) view morphing between two images (Seitz and Dyer 1996) © 1996 ACM; (e–f) 3D face modeling (images courtesy of Frédéric Devernay); (g) z-keying live and computer-generated imagery (Kanade, Yoshida et al. 1996) © 1996 IEEE; (h–i) building 3D surface models from multiple video streams in Virtualized Reality (Kanade, Rander, and Narayanan 1997) © 1997 IEEE; (j) computing depth maps for autonomous navigation (Geiger, Lenz, and Urtasun 2012) © 2012 IEEE.

[szelinski22book]

Razmotrimo projekciju X-koordinate 3D točke u slikovnu ravninu:




[segvic3d]

Iz sličnosti trokuta možemo jednostavno izraziti:


$$q_x = |Oo| \cdot \frac{Q_x}{Q_z} = f \cdot \frac{Q_x}{Q_z}$$

Analogno možemo izvesti izraz za q_y .

Možemo izraziti jednostavan model stvaranja slike:




[segvic3d]



[segvic3d]

$$q_{Lx} = f \cdot \frac{Q_x}{Q_Z} \quad q_{Rx} = f \cdot \frac{Q_x - b}{Q_Z}$$

$$d = q_{Lx} - q_{Rx} = f \cdot \frac{b}{Q_Z}$$





[segvic3d]

Pretpostavke:




- ▶ rotacija $\mathbf{R}$ između kamera je $\mathbf{R} = \mathbf{I}$
- ▶ translacija $\mathbf{t}$ postoji samo po X-osi $\mathbf{t} = [b, 0, 0]$.
- ▶ $\mathbf{E} = [\mathbf{t}]_x \mathbf{R}$

Rektificirani stereo



$$q_{Lx} = f \cdot \frac{Q_x}{Q_Z} \quad q_{Rx} = f \cdot \frac{Q_x - b}{Q_Z}$$

$$d = q_{Lx} - q_{Rx} = f \cdot \frac{b}{Q_Z}$$



[kreso13ms]

Motivacija:


- ▶ Ograničiti prostor pretraživanja u algoritmu uparivanja: pretraživanje uzduž rektificiranih epipolarnih pravaca je računski jeftinije.
- ▶ Dostupni algoritmi za stereo rekonstrukciju pretpostavljaju rektificirani par stereo snimaka.

Motivacija:

- ▶ Ograničiti prostor pretraživanja u algoritmu uparivanja: pretraživanje uzduž rektificiranih epipolarnih pravaca je računski jeftinije.
- ▶ Dostupni algoritmi za stereo rekonstrukciju pretpostavljaju rektificirani par stereo snimaka.

Cilj rektifikacije stereo para jest:

- ▶ učiniti sve epipolarne pravce paralelnima s X-osi u obje slike, te
- ▶ sve koreponentne točke projicirati na istu Y-koordinatu.



Rektificirani stereo: primjer na KITTI slikama



Rektificirani stereo

Izračun volumena cijene

Semiglobal Matching_[hirschmuller08tpami]

- ▶ Rektifikacija podrazumijeva da su prave korespondencije uzduž X osi.
- ▶ Za gustu rekonstrukciju izražavamo sve moguće cijene uparivanja.
- ▶ Volumen cijene je struktura koja sadrži cijene uparivanja.



Volumen cijene $\mathbf{V}$ je trodimenzionalno polje realnih brojeva. Element na položaju (d, i, j) računa se kao:

$$\mathbf{V}_{dij} = \delta\left(f(\mathbf{I}^L, (i, j)), f(\mathbf{I}^R, (i, j - d))\right)$$

Funkcija $f(\mathbf{I}, (i, j))$ radi transformaciju slikovnih vrijednosti oko koordinate (i, j) u slici $\mathbf{I}$:

$$f: \mathbb{R}^{h \times w \times C} \times \mathbb{N}_0^2 \mapsto \mathbb{R}^F$$

Funkcija δ izražava mjeru udaljenosti slikovnih okana:

$$\delta: \mathbb{R}^F \times \mathbb{R}^F \mapsto \mathbb{R}$$

Neke metode za izražavanje f i δ mogu biti:

Metoda	$f(I, [i, j])$	δ
SAD	$I_{[i-k:i+k, j-k:j+k]}$	L1 udaljenost
Census	$\llbracket I_{[i, j]} > I_{[i', j']} \rrbracket$	Hammingova udaljenost


Stvaranje volumena cijene

Neke metode za izražavanje f i δ mogu biti:

Metoda	$f(I, [i, j])$	δ
SAD	$I_{[i-k:i+k, j-k:j+k]}$	L1 udaljenost
Census	$\llbracket I_{[i,j]} > I_{[j',j']} \rrbracket$	Hammingova udaljenost



Primjer:	$I^R =$	32	64	96	$I^L =$	22	54	86
		32	64	96		22	54	86
		32	32	96		22	22	86

Metoda	$f(I, [i, j])$	δ
SAD	$[32 \ 64 \ 96 \ 32 \ \mathbf{64} \ 96 \ 32 \ 32 \ 96]$ $[22 \ 54 \ 86 \ 22 \ \mathbf{54} \ 86 \ 22 \ 22 \ 86]$	90
Census	$[0 \ 0 \ 1 \ 0 \quad 1 \ 0 \ 0 \ 1]$ $[0 \ 0 \ 1 \ 0 \quad 1 \ 0 \ 0 \ 1]$	0








[segvic3d]










Stvaranje volumena cijene



Stvaranje volumena cijene





Stvaranje volumena cijene



Stvaranje volumena cijene

$\arg \min_d \mathbf{V}_{dij}$ će ostvariti procjenu dispariteta na temelju lokalnih svojstava.



Rektificirani stereo

Izračun volumena cijene

Semiglobal Matching_[hirschmuller08tpami]

Dobar prvi izbor u razmatranju stereo rekonstrukcije (`cv::StereoSGBM`)




Fig. 9. Disparity images calculated by SGM (top) and C-SGM (bottom), which includes the intensity consistent disparity selection postprocessing step.

Koraci algoritma su:

- ▶ izračun cijene uparivanja (volumena cijene),
- ▶ agregacija cijena,
- ▶ izračun dispariteta, te
- ▶ popravljjanje dispariteta.

Izvorna metoda predlaže mjeru uzajamne informacije između dvije slike.

Implementacije odabiru druge formulacije (SAD, Census).

Optimizacijski kriterij nastoji smanjiti cijenu uparivanja uz pretpostavke o lokalnoj strukturi scena:

$$E(D) = \sum_{\mathbf{p}} \left(C(\mathbf{p}, D_{\mathbf{p}}) + \sum_{\mathbf{q} \in N_{\mathbf{p}}} P_1 \llbracket |D_{\mathbf{p}} - D_{\mathbf{q}}| = 1 \rrbracket + \sum_{\mathbf{q} \in N_{\mathbf{p}}} P_2 \llbracket |D_{\mathbf{p}} - D_{\mathbf{q}}| > 1 \rrbracket \right)$$

Optimizacijski kriterij nastoji smanjiti cijenu uparivanja uz pretpostavke o lokalnoj strukturi scena:

$$E(D) = \sum_{\mathbf{p}} \left(C(\mathbf{p}, D_{\mathbf{p}}) + \sum_{\mathbf{q} \in N_{\mathbf{p}}} P_1 [\|D_{\mathbf{p}} - D_{\mathbf{q}}\| = 1] + \sum_{\mathbf{q} \in N_{\mathbf{p}}} P_2 [\|D_{\mathbf{p}} - D_{\mathbf{q}}\| > 1] \right)$$

Problem je NP potpun u dvije dimenzije.

SGM uvodi optimizacijski kriterij manje složenosti.

SGM cijenu agregira u 8 ili 16 glavnih smjerova $\mathbf{r}$:

$$L_{\mathbf{r}}(\mathbf{p}, d) = C(\mathbf{p}, d) + \min \left\{ \begin{array}{l} L_{\mathbf{r}}(\mathbf{p} - \mathbf{r}, d) \\ L_{\mathbf{r}}(\mathbf{p} - \mathbf{r}, d - 1) + P1 \\ L_{\mathbf{r}}(\mathbf{p} - \mathbf{r}, d + 1) + P1 \\ \min_i L_{\mathbf{r}}(\mathbf{p} - \mathbf{r}, i) + P2 \end{array} \right\} - \min_k L_{\mathbf{r}}(\mathbf{p} - \mathbf{r}, k)$$

Za svaki piksel $\mathbf{p}$ se doprinosi smjerova zbrajaju:

$$S(\mathbf{p}, d) = \sum_r L_r(\mathbf{p}, d)$$

Početna procjena mape dispariteta $D_{b\mathbf{p}}$ je $\min_d S(\mathbf{p}, d)$.

Provjerom konzistencije između lijevog i desnog para moguće je odrediti zaklanjanja odnosno pogrešna uparivanja:

$$D_{\mathbf{p}} = \begin{cases} D_{b\mathbf{p}} & \llbracket |D_{b\mathbf{p}} - D_{m\mathbf{q}}| \leq 1 \rrbracket, \\ D_{\text{inv}} & \text{inače.} \end{cases}$$

- ▶ Rektifikacija stereoskopskog para pojednostavljuje gustu rekonstrukciju.
- ▶ SGM je i danas dobar prvi izbor.
- ▶ Brze izvedbe su izazov čak i uz moderno sklopovlje.